Knowledge-Based System Adaptif untuk Perhitungan PPh 21 dengan Akuisisi Pengetahuan Berbantuan LLM dari Regulasi dan Kebijakan Perusahaan

Obi Kastanya
6025252015@student.its.ac.id

Mahathir Muhammad
6025252008@student.its.ac.id

Program Studi Teknik Informatika, Institut Teknologi Sepuluh Nopember, Surabaya, Indonesia

Abstrak—Perhitungan PPh 21 harus mengikuti perubahan regulasi dan kebijakan perusahaan, tetapi aturannya umumnya tertanam di kode program atau spreadsheet, sehingga setiap perubahan menuntut pemrograman ulang dan dapat menggeser hasil periode lama tanpa terdeteksi. Penelitian formalisasi hukum pajak berbantuan large language model (LLM) membangun basis aturan dari nol untuk satu keadaan hukum, sehingga belum diketahui apakah pembaruan berulang oleh LLM menjaga hasil periode lama dan apakah kesalahannya merambat dari satu perubahan ke perubahan berikutnya. Penelitian ini mengusulkan knowledge-based system adaptif yang menyimpan pengetahuan sebagai legal knowledge graph temporal dua lapis, yaitu lapisan regulasi dan lapisan kebijakan perusahaan, dan menjalankan seluruh perhitungannya dengan inference engine deterministik. Pembaruan knowledge base disusun LLM dari dokumen regulasi atau kebijakan, lalu disaring lima gerbang verifikasi dan dipilih lewat konsensus perilaku. Evaluasinya memutar ulang perubahan regulasi PPh 21 pegawai tetap yang nyata pada 2023–2026, termasuk pergantian metode ke tarif efektif rata-rata, menguji perubahan yang belum pernah dilihat perancang, dan membandingkan usulan dengan pembanding serta ablasi. [Kalimat hasil: RA, SER dan CAR dengan selang kepercayaan 95%, OAR, dan recall analisis dampak.] [Kalimat implikasi.]

Kata Kunci—Akuisisi pengetahuan, knowledge-based system, knowledge graph, large language model, perubahan regulasi, PPh Pasal 21, rules as code

I. Pendahuluan

PPH Pasal 21 dipotong pemberi kerja setiap bulan dari penghasilan pegawai, sehingga kesalahan perhitungannya langsung muncul di slip gaji. Regulasinya juga sering berubah. Pada 2024 metode pemotongan disetahunkan menurut PER-16/PJ/2016 [1] diganti tarif efektif rata-rata (TER) bulanan [2], [3]. Pada 2025 terbit fasilitas PPh 21 ditanggung pemerintah (DTP) yang berlaku surut [4], lalu diperluas dan diperpanjang untuk 2026 [5], [6]. Batas upah iuran pensiun, yang menjadi pengurang penghasilan, juga berubah setiap tahun.

Dalam praktik, aturan pajak dan kebijakan payroll perusahaan tertanam bercampur di kode program atau spreadsheet. Audit pendahuluan atas spreadsheet payroll sebuah perusahaan menemukan konstanta regulasi di 254 sel rumus, dan uang lembur dicatat sebagai penghasilan tidak teratur, padahal regulasi menggolongkannya sebagai penghasilan teratur. Survei atas tujuh implementasi PPh 21 open source menemukan kesalahan terverifikasi di ketujuhnya. Akibatnya setiap perubahan regulasi menuntut pemrograman ulang, tidak ada bukti bahwa perubahan itu tidak menggeser hasil periode lama, dan kebijakan perusahaan yang menjadi melanggar tidak terdeteksi.

Knowledge-based system (KBS) dan gerakan rules as code memisahkan aturan dari kode [7], [8]. Pemisahan ini memindahkan beban ke pemeliharaan knowledge base, karena setiap perubahan hukum harus ditulis ulang sebagai aturan oleh orang yang memahami hukum sekaligus representasinya. Metode inkremental seperti Ripple-Down Rules menjaga kasus lama tetap benar, tetapi pakar manusia tetap menulis setiap perubahan [9].

Large language model (LLM) dapat mengubah teks peraturan menjadi representasi terstruktur [10], tetapi tidak andal untuk penalaran pajak yang menuntut ketepatan [11], [12]. Karena itu, formalisasi pajak berbantuan LLM memakai LLM untuk menyusun aturan dan engine deterministik untuk menghitung [13]–[16]. Karya-karya ini memformalkan satu keadaan hukum dari nol. Gagasan memakai LLM untuk memperbarui perangkat lunak pajak versi sebelumnya sudah diajukan, tetapi baru sebagai kajian tantangan teknis [17]. Pembaruan berulang juga berisiko. Penyuntingan pengetahuan LLM yang berurutan merusak pengetahuan lama [18], dan pada konsolidasi undang-undang dengan LLM, kemiripan teks hasilnya mencapai 93–99% tetapi kecocokan persisnya hanya 50,3% untuk satu amandemen dan 20,51% untuk rangkaian amandemen [19]. Belum ada penelitian yang mengukur, pada basis aturan yang dieksekusi, apakah pembaruan berulang dari LLM menjaga hasil periode lama, apakah kesalahannya merambat, dan bagaimana dampaknya terhadap kebijakan perusahaan.

Penelitian ini mengusulkan KBS adaptif untuk PPh 21 pegawai tetap (Gambar 1). Pengetahuan disimpan sebagai legal knowledge graph temporal dua lapis, yaitu lapisan regulasi dan lapisan kebijakan perusahaan, dan seluruh

Draf, 27 Oktober 2026. Hasil eksperimen belum tersedia; bagian yang menunggu hasil ditandai teks abu-abu dalam kurung siku.

aritmetika dijalankan inference engine deterministik. LLM menyusun kandidat pembaruan dari dokumen baru, lima gerbang verifikasi menyaringnya, dan sistem memilih satu kandidat lewat konsensus perilaku atau menolak memilih (abstain). Kebenaran diukur dari hasil perhitungan sampai rupiah dengan memutar ulang perubahan regulasi nyata secara berurutan (regulation replay).

Penelitian ini menjawab empat pertanyaan penelitian (RQ):

RQ1 Sejauh mana representasi temporal dua lapis dapat menyatakan perubahan regulasi dan kebijakan, termasuk jenis perubahan yang tidak diketahui saat dirancang, tanpa mengubah kode engine?

RQ2 Seberapa sering akuisisi berbantuan LLM menerapkan pembaruan yang benar, seberapa sering pembaruan salah lolos tanpa terdeteksi, dan berapa besar peran gerbang verifikasi?

RQ3 Pada rangkaian perubahan regulasi yang nyata, berapa peristiwa yang berhasil diterapkan otomatis, dan apakah kesalahan merambat antarperistiwa?

RQ4 Seberapa lengkap sistem menemukan kebijakan perusahaan yang terdampak atau menjadi melanggar setelah regulasi berubah?

Kontribusinya adalah (K1) representasi temporal dua lapis dengan resolusi konflik dan analisis dampak lintas lapis; (K2) metode akuisisi inkremental berbantuan LLM dengan gerbang verifikasi dan konsensus perilaku; (K3) definisi adaptivitas representasional dan operasional beserta protokol regulation replay yang memisahkan kesalahan baru dari kesalahan yang dipicu perambatan; dan (K4) artefak terbuka berupa knowledge base, korpus perubahan, dan test suite. Pola "LLM menyusun aturan, engine menghitung" tidak diklaim sebagai kebaruan. Kebaruannya terletak pada pembaruan inkremental knowledge base yang dieksekusi, yang dievaluasi pada rangkaian amandemen nyata beserta perambatan kesalahan dan dampaknya terhadap kebijakan perusahaan.

II. Latar belakang dan rumusan masalah

A. Perhitungan PPh 21 pegawai tetap

PPh 21 pegawai tetap dihitung dari bruto, yaitu penghasilan teratur seperti gaji, tunjangan, dan lembur, penghasilan tidak teratur seperti THR dan bonus, serta premi jaminan yang dibayar pemberi kerja [3]. Neto adalah bruto dikurangi biaya jabatan dan iuran pensiun pegawai. Penghasilan kena pajak (PKP) adalah neto setahun dikurangi penghasilan tidak kena pajak [20], dibulatkan ke bawah hingga ribuan rupiah, lalu dikenai tarif Pasal 17 yang terdiri atas lima lapisan dari 5% sampai 35% [21]. Sampai 2023, potongan bulanan dihitung dengan menyetahunkan penghasilan [1]. Sejak 2024, potongan Januari sampai November adalah TER dikali bruto bulanan, dengan kategori A, B, dan C menurut status PTKP [2], dan selisihnya terhadap PPh setahun dipotong di masa pajak terakhir [3]. Pada 2025–2026, PPh 21 pegawai di sektor tertentu ditanggung pemerintah [4], [6]. Tabel I merangkum dimensi yang menentukan besarnya pajak.

Tabel I
Dimensi perhitungan PPh 21 pegawai tetap yang dicakup

Dimensi	Nilai
Rezim	Disetahunkan (sampai 2023); TER (sejak 2024); TER dengan DTP (2025–2026)
Lapisan Pasal 17	5%, 15%, 25%, 30%, 35%
Kategori TER	A, B, C dengan 44, 40, dan 41 lapisan tarif bulanan
Status PTKP	TK/0–TK/3, K/0–K/3; menentukan kategori TER
Metode	Dipotong (gross), gross-up, ditanggung pemberi kerja
Pola kerja	Setahun penuh, masuk atau keluar di tengah tahun
Penghasilan	Teratur; tidak teratur (THR, bonus)

Penelitian ini terbatas pada pegawai tetap dengan satu pemberi kerja pada tahun pajak 2023–2026.

B. Kebijakan perusahaan dan batas kewenangannya

Perusahaan menetapkan komponen penghasilan, seperti prorata gaji, THR, dan tunjangan, lewat peraturan perusahaan atau perjanjian kerja bersama, sehingga kebijakan itu ikut menentukan PPh 21. Namun, perusahaan tidak boleh menyimpangi ketentuan wajib. Contohnya, PER-16/PJ/2016 dan PMK 168/2023 menggolongkan uang lembur sebagai penghasilan teratur [1], [3], sedangkan kebijakan payroll perusahaan yang diaudit mencatatnya sebagai penghasilan tidak teratur. Bila kebijakan bertentangan dengan ketentuan wajib, ketentuan regulasi yang berlaku (lex superior), dan konfliknya harus tercatat.

C. Jenis perubahan dan rumusan masalah

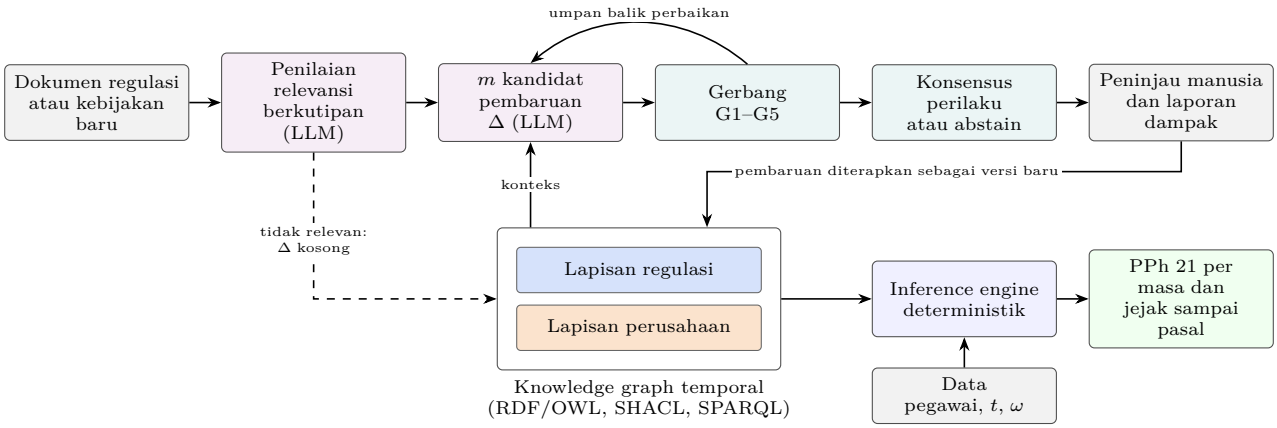
Perubahan dikelompokkan menjadi perubahan parameter, tabel tarif, klasifikasi penghasilan, aturan atau fasilitas baru, kondisi atau cakupan, pergantian metode, pencabutan, ketentuan berlaku surut, dan perubahan kebijakan perusahaan. Satu peristiwa dapat termasuk beberapa jenis, misalnya PMK 10/2025 yang menambah fasilitas baru sekaligus berlaku surut. Hasil dilaporkan per jenis, sehingga perubahan parameter yang mudah tidak digabung dengan pergantian metode.

Masukan masalah ini adalah knowledge base $\mathcal{K}_{n-1}$ yang benar untuk keadaan hukum sebelum peristiwa ke-n, beserta dokumen sumber peristiwa itu. Keluarannya adalah $\mathcal{K}_n$ yang benar untuk keadaan hukum sesudahnya, tanpa perubahan kode engine, tanpa perubahan hasil untuk masa sebelum perubahan berlaku, dan dengan laporan kebijakan perusahaan yang menjadi bertentangan dengan ketentuan wajib. Masalah ini berulang, karena $\mathcal{K}_n$ menjadi masukan untuk peristiwa berikutnya, sehingga kesalahan yang lolos dapat merambat.

III. Penelitian terkait

A. Rules as code dan sistem pajak berbasis aturan

Catala menerjemahkan undang-undang menjadi program dengan default logic dan menemukan bug pada implementasi resmi tunjangan keluarga Prancis [7]. DataLex dan Logical English menyediakan bahasa aturan yang dapat dieksekusi beserta penjelasannya [8], [22], dan



Gambar 1. Ikhtisar sistem. Baris atas adalah alur akuisisi pengetahuan; baris bawah adalah knowledge base dua lapis dan inference engine yang menghitung PPh 21. LLM hanya mengusulkan pembaruan dan tidak pernah menghitung pajak.

OpenFisca[1] menyimpan parameter pajak sebagai berkas bertanggal. Pada payroll, Dumancic dkk. memformalkan legislasi pajak dan jaminan sosial menjadi constraint untuk mencari kebijakan yang optimal [23], sedangkan sistem PPh 21 di Indonesia umumnya menanam rumus pajak di kode aplikasi [24], [25]. Pada semua karya ini pengetahuan ditulis manusia, dan pemisahan aturan negara dari kebijakan pemberi kerja tidak menjadi fokus.

B. Akuisisi pengetahuan dan formalisasi dengan LLM

Ripple-Down Rules menambah aturan secara inkremental dengan cornerstone case sebagai pengaman regresi [9], dan revisi hukum temporal membedakan saat ketentuan berlaku dari saat ia masuk ke sistem hukum [26]. Keduanya tetap bergantung pada pakar untuk menulis setiap perubahan. LLM mulai mengambil peran itu. NTOL menggabungkan LLM dengan penalar simbolik di atas knowledge graph statuta pajak India dan mencapai akurasi 80% pada 20 skenario [13]. LLM juga dipakai untuk menerjemahkan pasal Internal Revenue Code ke Prolog [14], hukum pajak ke Catala [15], dan penalaran pajak ke program logika [16]. Semua karya ini memformalkan satu keadaan hukum dari nol. Gagasan yang paling dekat diajukan Gogani-Khiabani dkk., yaitu LLM yang menerapkan perubahan dari publikasi otoritas pajak ke versi perangkat lunak sebelumnya, tetapi karya itu baru membahas tantangan teknisnya tanpa evaluasi atas rangkaian perubahan [17].

C. Pembaruan berulang dan representasi temporal

Penyuntingan pengetahuan LLM yang berurutan menimbulkan lupa bertahap dan merusak kemampuan umum model [18], [27], walaupun penyuntingan dengan bantuan temu kembali dapat lebih stabil [28]. Pada konsolidasi undang-undang, kemiripan teks yang tinggi menyembunyikan hasil yang salah, dan kesalahan bertambah pada rangkaian amandemen [19]. Evaluasi berbasis eksekusi seperti pass@k [29], [30] dan prediksi selektif [31] menjadi dasar metrik penelitian ini. Untuk representasi, knowledge graph norma berversi [32] dan standar ELI, OWL-Time, PROV-O, serta SHACL [33]–[36] menyediakan kosakata waktu dan asal-usul, tetapi belum dipakai untuk aturan yang dieksekusi dan diperbarui mesin. Tabel II merangkum posisi penelitian ini.

[1]https://openfisca.org

IV. Representasi pengetahuan dan inference engine

A. Model pengetahuan

Pengetahuan PPh 21 terdiri atas dua jenis. Pengetahuan struktural, seperti regulasi memuat pasal, aturan bersumber dari pasal, PMK baru mengubah PMK lama, dan kebijakan berkonflik dengan aturan wajib, disimpan sebagai legal knowledge graph RDF/OWL. Pengetahuan komputasional, seperti TER dikali bruto, pembulatan per pasal, dan gross-up sebagai fixed point, disimpan sebagai ekspresi pada node aturan dan dijalankan inference engine deterministik. Perhitungan tidak dipindahkan ke penalaran ontologi, karena OWL dan SWRL tidak menyediakan aritmetika eksak berpembulatan maupun iterasi fixed point. Prototipe engine yang dipakai ulang sudah tidak menghasilkan selisih yang tidak terjelaskan pada 1.213 nilai harapan dari 45 contoh perhitungan resmi.

Definisi 1 (Knowledge base). $\mathcal{K} = \langle \mathcal{O}, \mathcal{R}, \mathcal{P}, \mathcal{T} \rangle$ terdiri atas ontologi beserta individunya, himpunan aturan, parameter berversi, dan tabel berversi. Setiap aturan, parameter, dan tabel berada pada lapisan $\ell \in \{reg, prs\}$. Lapisan perusahaan disimpan sebagai named graph per perusahaan, sehingga beberapa perusahaan dapat memakai lapisan regulasi yang sama.

Definisi 2 (Aturan). Aturan adalah tupel

$$r = \langle id, \ell, \sigma, [t_s, t_e], t_c, \varphi, f \coloneqq e, src \rangle,$$

dengan sifat $\sigma \in \{wajib, tafsir, default, opsional\}$, masa berlaku $[t_s, t_e]$, tanggal pencatatan t_c, kondisi φ, fakta f yang dihasilkan dengan ekspresi e, dan pasal sumber src. Aturan wajib tidak dapat ditimpa lapisan perusahaan, sedangkan aturan default boleh ditimpa aturan opsional perusahaan.

Tabel II
Posisi penelitian terhadap karya terkait (– berarti tidak dinyatakan di abstrak atau bukan fokus karya tersebut)

Karya	Domain	Representasi	Penyusun pengetahuan	Pembaruan inkremental	Perambatan kesalahan diukur	Lapisan perusahaan
Catala [7]	pajak dan tunjangan (AS, Prancis)	DSL dengan default logic	manusia	–	–	–
Dumancic dkk. [23]	payroll (Belgia)	representasi formal ke constraint	manusia	–	–	–
NTOL [13]	PPh (India)	knowledge graph dan aturan simbolik	–	–	–	–
Yadamsuren dkk. [14]	IRC (AS)	Prolog	LLM	–	–	–
Lorenzo dkk. [15]	hukum pajak	Catala	LLM	–	–	–
Gogani-Khiabani dkk. [17]	perangkat lunak pajak (AS)	kode program	LLM (usulan)	gagasan	–	–
Penelitian ini	PPh 21 (Indonesia)	knowledge graph temporal dua lapis dan aturan yang dieksekusi	LLM dengan gerbang verifikasi	ya	ya	ya

Definisi 3 (Hasil perhitungan). $\mathit{hasil}(\mathcal{K}, x, t, \omega)$ adalah nilai fakta keluaran untuk kasus x pada masa pajak t, dihitung hanya dengan unsur $\mathcal{K}$ yang $t_c \le \omega$. Tanggal pengetahuan ω bermakna pengetahuan hukum, sehingga sebuah unsur dianggap diketahui sejak dokumen sumbernya terbit, bukan sejak pembaruannya disetujui. Fakta keluaran utamanya adalah PPh 21 yang dipotong per pegawai per masa, dalam rupiah bulat.

B. Ontologi dan validasi

Gambar 2 menunjukkan kelas dan relasi utama. Kosakatanya memakai ulang ELI untuk regulasi dan relasi amandemen, OWL-Time untuk masa berlaku, dan PROV-O untuk asal-usul serta waktu pencatatan [33]–[35]. Kebijakan perusahaan dimodelkan setara dengan regulasi, dan perbedaannya hanya pada lapisan dan otoritas penerbitnya. Shape SHACL [36] memvalidasi struktur graf, termasuk pembaruan yang diusulkan LLM. Pelanggaran struktural, seperti aturan regulasi tanpa pasal sumber, ditolak, sedangkan konflik kebijakan dengan aturan wajib dicatat sebagai peringatan. Query SPARQL dipakai untuk menemukan kebijakan yang terdampak perubahan regulasi.

C. Resolusi konflik antarlapis

Bila beberapa aturan menghasilkan fakta yang sama pada masa yang sama, engine mengeluarkan aturan yang dicabut eksplisit, lalu memilih pemenang dengan kunci leksikografis

$$\kappa(r) = \big(\mathit{sup}(r),\ \mathit{ovr}(r),\ \mathit{spec}(r),\ t_s(r),\ \mathit{prio}(r)\big). \quad (1)$$

Komponen *sup* mewakili lex superior, yaitu aturan wajib regulasi mengalahkan aturan perusahaan. Komponen *ovr* mewakili penimpaan sah, yaitu aturan opsional perusahaan mengalahkan aturan default. Komponen *spec* mewakili lex specialis, t_s mewakili lex posterior, dan *prio* adalah prioritas eksplisit. Bila tersisa lebih dari satu pemenang dengan nilai berbeda, engine berhenti dengan status AMBIGU dan tidak memilih diam-diam. Setiap kemenangan aturan wajib atas aturan perusahaan dicatat di jejak.

Algoritma 1 Inferensi untuk satu pegawai dan satu tahun pajak

Masukan: $\mathcal{K}$, data pegawai x, tahun pajak y, tanggal pengetahuan ω
Keluaran: nilai setiap fakta per masa beserta jejaknya
$R \leftarrow$ aturan dengan $t_c \le \omega$ yang masa berlakunya beririsan dengan y
keluarkan dari R aturan yang digantikan aturan lain di R
bangun graf dependensi fakta, hitung komponen terhubung kuat, urutkan topologis
untuk setiap komponen Q menurut urutan topologis lakukan
    jika Q bersiklus maka
        iterasi fixed point dari batas bawah dan atas
    selain itu
        untuk setiap instans (f, t) dengan $f \in Q$ lakukan
            pilih pemenang dengan kunci κ, evaluasi secara eksak
            catat nilai, pemenang, pasal, dan aturan yang ditolak
        akhir untuk
    akhir jika
akhir untuk
kembalikan nilai fakta dan jejak

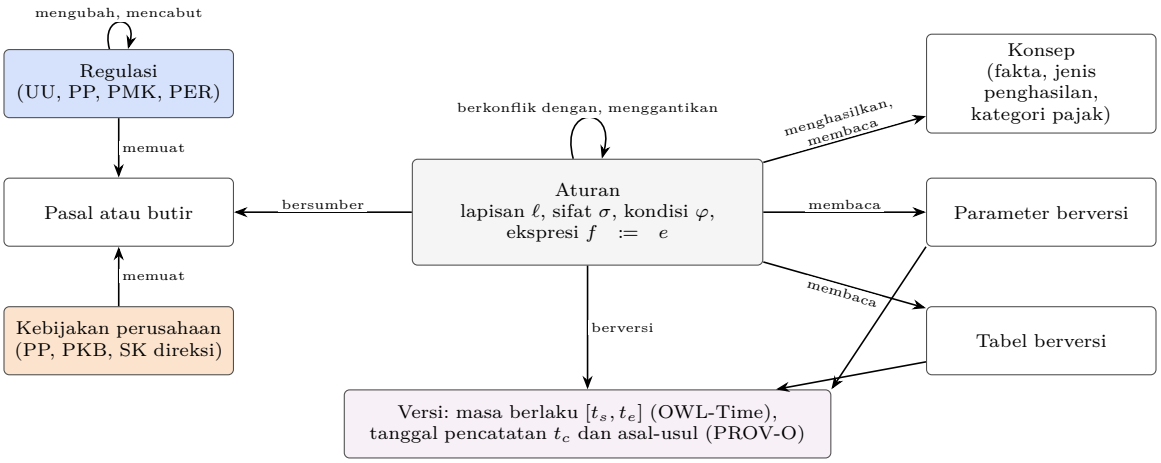
D. Inference engine

Algoritma 1 merangkum langkah inferensi. Komponen bersiklus hanya diizinkan bila memuat aturan fixed point, seperti gross-up, dengan tunjangan pajak $T = \mathrm{PPh}(B+T)$ untuk bruto B. Fungsi ini tidak turun dan memetakan rupiah bulat $\{0, \ldots, B\}$ ke dirinya sendiri, sehingga menurut teorema Knaster–Tarski titik tetapnya ada. Iterasi dari batas bawah dan atas menemukan titik tetap terkecil dan terbesar, dan bila keduanya berbeda, engine mencatat solusi ganda. Rupiah disimpan sebagai bilangan bulat dan tarif sebagai bilangan rasional, setiap pembulatan merujuk ke registri yang mencatat dasar hukumnya, dan setiap nilai keluaran disertai jejak sampai pasal sumber.

V. Akuisisi pengetahuan inkremental berbantuan LLM

A. Pembaruan dan adaptivitas

Definisi 4 (Peristiwa dan pembaruan). Peristiwa perubahan $\epsilon = \langle d, t_{terbit}, t_{berlaku}, \tau \rangle$ terdiri atas dokumen sumber, tanggal terbit, tanggal berlaku, dan jenis perubahan; ia berlaku surut bila $t_{berlaku} < t_{terbit}$. Pembaruan $\Delta = \langle \Delta^{+}, \Delta^{\sim}, \Delta^{-} \rangle$ berisi unsur yang ditambah, diubah, dan dicabut, dengan $\mathcal{K}' = \mathcal{K} \oplus \Delta$. Pembaruan emas $\Delta_n^{\star}$



Gambar 2. Ontologi knowledge base. Kebijakan perusahaan (oranye) dimodelkan setara dengan regulasi (biru); yang membedakan hanya lapisan dan otoritas penerbitnya.

disusun peneliti, sedangkan $\hat{\Delta}_n$ dihasilkan alur akuisisi. Pembaruan kosong adalah jawaban yang benar untuk dokumen yang tidak mengubah perhitungan.

Definisi 5 (Syarat adaptif). Untuk $\mathcal{K}' = \mathcal{K} \oplus \Delta$ dan himpunan kasus S:

- (A1) kode engine tidak berubah;
- (A2) $hasil(\mathcal{K}', x, t, \omega) = hasil(\mathcal{K}^\star, x, t, \omega)$ untuk $x \in S$, $t \geq t_{berlaku}$, $\omega \geq t_{terbit}$;
- (A3$_t$) hasil untuk $t < t_{berlaku}$ tidak berubah;
- (A3$_\omega$) hasil untuk $\omega < t_{terbit}$ tidak berubah;
- (A4) setiap kebijakan yang berkonflik dengan aturan wajib di $\mathcal{K}'$ dilaporkan.

Definisi 6 (Adaptivitas). Representasi adaptif secara representasional terhadap ϵ bila ada Δ dalam bahasa representasi yang memenuhi A1–A4 (RQ1). Sistem adaptif secara operasional bila $\hat{\Delta}$ yang dipilih alur akuisisi memenuhi A2, A3$_t$, dan A4 pada himpunan kasus evaluasi S^E (RQ2, RQ3).

A1 dan A3$_\omega$ berlaku karena arsitekturnya, sebab LLM hanya menyunting knowledge base, dan t_c setiap unsur baru diisi alur akuisisi dengan t_{terbit}, bukan oleh LLM. Tanpa ketentuan ini, LLM dapat mencatat aturan yang berlaku surut pada $t_{berlaku}$, sehingga hasil yang dihitung sebelum peraturannya terbit ikut berubah. Keduanya diperiksa sebagai invarian, sedangkan A2, A3$_t$, dan A4 diuji.

B. Alur akuisisi dan gerbang verifikasi

Alur akuisisi (Gambar 1) memotong dokumen per pasal, lalu LLM menilai apakah dokumen mengubah perhitungan PPh 21 dengan menyertakan kutipan pendukung. Dokumen yang tidak relevan menghasilkan pembaruan kosong. Untuk dokumen yang relevan, sistem menyusun konteks dari bagian graf yang disentuh dokumen, dan LLM menyusun m kandidat Δ secara independen, dengan kutipan sumber untuk setiap unsur. Setiap kandidat melewati gerbang G1–G5 (Tabel III). Kandidat yang gagal mendapat umpan balik dan boleh diperbaiki dalam jumlah putaran terbatas.

Tabel III
Gerbang verifikasi

ID	Pemeriksaan	Menjaga
G1	Struktur graf sesuai shape SHACL	validitas
G2	Setiap kutipan benar-benar ada di dokumen sumber, dan setiap tanggal di Δ muncul di kutipannya	dasar hukum
G3	Konsistensi statis: tipe, dependensi, konflik, anomali	A4
G4	Regresi pada S^G: hasil sebelum $t_{berlaku}$ tidak berubah	A3$_t$
G5	Non-vakuitas: setiap unsur baru mengubah minimal satu fakta keluaran atau menimbulkan konflik yang dilaporkan, dan unsur yang dicabut tidak lagi menyala	efek nyata

G5 diperlukan karena pembaruan kosong atau aturan yang tidak pernah menyala lolos G1–G4 tanpa menimbulkan regresi. Kebijakan yang dikalahkan aturan wajib tidak mengubah angka, tetapi tetap disimpan demi A4, sehingga konflik yang dilaporkan dihitung sebagai efek. Cek tanggal di G2 menutup kesalahan senyap berupa tanggal berlaku yang salah, yang lolos gerbang lain. Peran G4 setara dengan cornerstone case pada Ripple-Down Rules [9]. Kasus S^G dibangkitkan otomatis dengan menyasar kondisi unsur yang berubah, dan tidak beririsan dengan S^E yang dipakai untuk menilai sistem.

C. Pemilihan kandidat dan analisis dampak

Untuk setiap kandidat $\hat{\Delta}_j$ yang lolos semua gerbang, sistem menghitung vektor hasil

$$v_j = \big(hasil(\mathcal{K} \oplus \hat{\Delta}_j, x, t, \omega)\big)_{(x,t,\omega)\in S^G}. \qquad (2)$$

Kandidat dengan vektor yang sama dikelompokkan, dan wakil kelompok terbesar dipilih (konsensus perilaku). Bila dua kelompok terbesar sama besar, sistem abstain karena tidak ada dasar perilaku untuk memilih. Urutan kandidat diacak dan dicatat.Bila tidak ada kandidat yang lolos, sistem juga abstain dan meneruskan dokumen ke peninjau

manusia. Untuk analisis dampak, detektor menelusuri graf secara statis dan menandai kebijakan perusahaan sebagai terdampak bila nilai fakta keluarannya berubah, aturan pemenangnya berubah, atau kebijakan itu menjadi berkonflik dengan aturan wajib.

VI. Metodologi evaluasi

Evaluasi memakai empat prinsip. Setiap RQ punya satu metrik utama yang ditetapkan sebelum eksperimen. Kebenaran diukur dari hasil perhitungan sampai rupiah, bukan dari kemiripan bentuk aturan, dan rata-rata selisih seperti MAE tidak dipakai karena dapat menyembunyikan kasus yang salah. Data yang dipakai sistem terpisah dari data yang dipakai untuk menilainya. Karena jumlah peristiwa nyata kecil, hasil dilaporkan sebagai estimasi dengan selang kepercayaan eksak.

A. Desain dan pembagian data

Penelitian ini mengikuti design science research. Hipotesis, metrik, ambang, dan pembagian data didaftarkan ke layanan pra-registrasi sebelum eksperimen pada data uji. Data pengembangan terdiri atas regulasi fiktif, perubahan sebelum 2023, dan sebagian kecil kebijakan buatan, dan dipakai untuk merancang prompt dan gerbang sebelum keduanya dibekukan. Data uji adalah seluruh peristiwa nyata 2023–2026. Data uji prospektif adalah regulasi yang terbit sesudah pra-registrasi. Karena representasi dirancang ketika perubahan 2023–2026 sudah diketahui, klaim tanpa mengubah kode juga diuji pada perubahan struktural sintetis yang ditulis orang lain beserta contoh perhitungannya (perubahan tak terlihat), dan pada peristiwa prospektif.

B. Acuan dan ruang uji

Kebenaran $\mathcal{K}^\star$ divalidasi terhadap lima acuan: contoh perhitungan resmi dalam regulasi (GT1, sebagian disimpan sebagai holdout), kalkulator otoritas pajak (GT2), perhitungan manual independen (GT3), kalkulator pihak ketiga (GT4), dan contoh perhitungan kebijakan perusahaan (GT5). $\mathcal{K}^\star$ lalu menghasilkan nilai harapan S^E, yang ketajamannya diukur dengan mutation score [37] sebelum dipakai menilai pembaruan dari LLM. Ruang uji mencakup kombinasi 2-arah semua dimensi di Tabel I yang sah, setiap batas lapisan di tiga titik (tepat, di bawah, dan di atasnya), yaitu 48 titik untuk Pasal 17 pada empat tahun pajak dan 366 titik untuk 122 batas TER, serta sedikitnya 2.995 kasus acak dari distribusi upah BPS. Bila seluruh kasus acak lulus, laju kesalahan dapat diklaim di bawah 0,1% pada keyakinan 95%.

C. Korpus

Korpus uji berisi peristiwa perubahan nyata yang memengaruhi PPh 21 pegawai tetap pada 2023–2026 (Tabel IV). Korpus juga memuat dokumen pengecoh, yaitu regulasi pada periode yang sama yang tidak mengubah perhitungan, seperti ketentuan Coretax dan DTP untuk peserta pemagangan, dengan jawaban benar berupa pembaruan kosong. Dokumen kontrafaktual mengubah nilai dan tanggal di dokumen nyata untuk memeriksa apakah LLM membaca dokumen atau mengingat data latihnya. Kebijakan perusahaan diambil dari perjanjian kerja bersama yang dipublikasikan, dilengkapi kebijakan buatan untuk jenis konflik yang tidak muncul di dokumen nyata.

Tabel IV
Peristiwa perubahan nyata dalam korpus uji

Dokumen	Berlaku	Jenis
Batas upah iuran pensiun (tahunan)	Maret 2023–2026	parameter
PMK 66/2023 (natura)	Jul 2023	klasifikasi
PP 58/2023 dan PMK 168/2023	Jan 2024	metode, tabel tarif, pencabutan
PMK 10/2025 (terbit Februari)	Jan 2025	fasilitas baru, berlaku surut
PMK 72/2025	Okt 2025	kondisi atau cakupan
PMK 105/2025	Jan 2026	fasilitas baru

Tabel V
Pembanding dan ablasi

ID	Kondisi	RQ
B1	Praktik saat ini: riwayat perubahan kode kalkulator PPh 21 open source saat pergantian ke TER	RQ3
B2	LLM menghitung PPh 21 langsung dari dokumen	motivasi
B3	Satu kandidat, gerbang G1–G2 saja	RQ2, RQ3
B4	Banyak kandidat dengan anggaran setara, suara terbanyak, tanpa gerbang	RQ2
B5	Analisis dampak naif: tandai semua, dependensi tanpa eksekusi, penilaian LLM	RQ4
AB1	Formalisasi dari nol pada beberapa keadaan hukum terpilih	RQ2, RQ3
AB2–AB5	Tanpa konteks graf; tanpa G4 atau G5; cara pemilihan lain; skema biasa tanpa graf	RQ2, RQ4

D. Mode evaluasi dan pembanding

Pada mode terisolasi (RQ2), $\hat{\Delta}_n$ diterapkan pada $\mathcal{K}^\star_{n-1}$. Pada mode berantai (RQ3), $\hat{\Delta}_n$ diterapkan pada hasil pembaruan sistem sendiri, $\mathcal{K}^{\text{sis}}_{n-1}$. Kedua mode berjalan tanpa peninjau manusia, sehingga hasilnya adalah batas bawah kinerja. Setiap dokumen relevan berakhir sebagai benar-diterapkan, salah-diterapkan (kesalahan senyap), atau abstain. Tabel V memuat pembanding dan ablasi.

E. Hipotesis dan metrik utama

Tabel VI menghubungkan setiap RQ dengan hipotesis dan metrik utamanya. RA adalah proporsi perubahan yang dapat dinyatakan tanpa mengubah engine. Atas himpunan D dokumen sumber nyata yang relevan,

$$\text{SER} = \tfrac{1}{|D|}\textstyle\sum_{d\in D} \mathbf{1}[d \text{ salah-diterapkan}], \qquad (3)$$
$$\text{CAR} = \tfrac{1}{|D|}\textstyle\sum_{d\in D} \mathbf{1}[d \text{ benar-diterapkan}].$$

SER mengukur keamanan dan CAR mengukur kegunaan. Keduanya dilaporkan bersama, karena sistem yang selalu abstain punya SER nol tetapi tidak berguna. OAR adalah

Tabel VI
Keterlacakan RQ, hipotesis, dan metrik utama

RQ	Hipotesis	Metrik utama	Analisis	Eksperimen
–	Invarian A1 dan A3$_\omega$ tanpa pelanggaran	jumlah pelanggaran	pemeriksaan	semua
RQ1	H1: RA pada perubahan tak terlihat $\geq \theta_1$	RA; juga untuk perubahan nyata dan korpus kebijakan	proporsi, CI eksak Clopper–Pearson	E1
RQ2	H2a: batas atas SER $\leq \theta_2$. H2b: CAR lebih tinggi daripada B3 dan B4, dengan SER tidak lebih buruk (margin δ_S)	SER dan CAR per lapisan	CI eksak; selisih risiko berpasangan (Newcombe); non-inferioritas	E2
RQ3	H3a: OAR $\geq \theta_3$. H3b: kesalahan terpicu tidak melebihi batas derau pembangkitan	OAR dan I_n	CI eksak; deskriptif atas beberapa pengulangan	E3
RQ4	H4a: recall $\geq \theta_4$. H4b: F_2 lebih tinggi daripada setiap B5	recall dan F_2	bootstrap klaster per peristiwa	E4

proporsi peristiwa yang tidak memperkenalkan kesalahan baru pada mode berantai. Kesalahan terpicu pada peristiwa n adalah

$$I_n = E_n^{\text{ber}} \setminus \big(E_n^{\text{iso}} \cup H_n\big), \tag{4}$$

yaitu tupel yang salah pada mode berantai tetapi tidak salah pada mode terisolasi dan belum salah sebelumnya (H_n). Untuk RQ4, recall diutamakan karena kebijakan terdampak yang terlewat lebih berbahaya daripada peringatan palsu, dan $F_2 = 5PR/(4P + R)$ memberi bobot recall dua kali precision.

Ambang θ ditetapkan sesuai jumlah data. Contohnya, dengan sepuluh dokumen uji tanpa kesalahan, batas atas eksak SER pada keyakinan 95% hanya 26%, sehingga klaim SER $\leq$ 5% baru mungkin dengan sedikitnya 59 dokumen. Perbandingan antarkondisi dikoreksi dengan metode Holm per RQ, dan hasil dilaporkan per jenis perubahan. Metrik diagnostik, seperti pass@k, matriks konfusi per gerbang, laju hafalan pada dokumen kontrafaktual, dan selisih akhir dalam rupiah, dipakai untuk menjelaskan hasil, bukan untuk menguji hipotesis. Eksperimen E0 memvalidasi $\mathcal{K}^\star$ dan S^E dan menjadi prasyarat E1–E4.

VII. Hasil dan pembahasan

[Bagian ini diisi setelah E0–E4 dijalankan sesuai praregistrasi. Untuk setiap RQ dilaporkan metrik utama dengan CI 95% dan putusan hipotesisnya mengikuti Tabel VI, hasil per jenis perubahan dan per lapisan, perbandingan dengan pembanding dan ablasi, serta analisis kesalahan LLM menurut taksonomi yang ditetapkan sebelum pelabelan.]

A. Ancaman terhadap validitas

Acuan dan engine disusun tim yang sama, sehingga kesalahan yang sama dapat muncul di keduanya. Hal ini dimitigasi dengan acuan pihak ketiga, subset holdout contoh resmi, dan pengadjudikasi kedua. Representasi dirancang setelah perubahan 2023–2026 diketahui, sehingga klaim adaptivitas juga diuji pada perubahan tak terlihat dan peristiwa prospektif. Kecocokan dengan acuan belum tentu berarti kesesuaian hukum, karena penelitian ini tidak melibatkan pakar hukum pajak. Hasilnya terbatas pada satu yurisdiksi, satu jenis pajak, dan satu rangkaian perubahan dengan jumlah peristiwa yang kecil. Regulasi 2023–2026 juga mungkin ada di data latih LLM, dan hal ini diperiksa dengan dokumen kontrafaktual dan perbandingan hasil sebelum dan sesudah training cutoff model.

VIII. Kesimpulan

[Jawaban RQ1–RQ4 dengan metrik utama dan CI, tanpa mengulang abstrak, lalu penelitian lanjutan yang diturunkan dari keterbatasan.]

Pengungkapan penggunaan AI

Penyusunan draf naskah ini dibantu asisten AI Claude (Anthropic) untuk menyusun kalimat dari kerangka penelitian dan menyiapkan kode LaTeX. Seluruh isi, klaim, angka, dan rujukan diperiksa dan menjadi tanggung jawab penulis.

Daftar Pustaka

[1] Direktur Jenderal Pajak, "Peraturan Direktur Jenderal Pajak Nomor PER-16/PJ/2016 tentang Pedoman Teknis Tata Cara Pemotongan, Penyetoran dan Pelaporan Pajak Penghasilan Pasal 21 dan/atau Pajak Penghasilan Pasal 26 Sehubungan dengan Pekerjaan, Jasa, dan Kegiatan Orang Pribadi," 2016, salinan pindaian; diakses 1 Oktober 2026.

[2] Republik Indonesia, "Peraturan Pemerintah Nomor 58 Tahun 2023 tentang Tarif Pemotongan Pajak Penghasilan Pasal 21 atas Penghasilan Sehubungan dengan Pekerjaan, Jasa, atau Kegiatan Wajib Pajak Orang Pribadi," https://peraturan.bpk.go.id/Download/332609/PP%20Nomor%2058%20Tahun%202023.pdf, 2023, diakses 1 Oktober 2026.

[3] Menteri Keuangan Republik Indonesia, "Peraturan Menteri Keuangan Nomor 168 Tahun 2023 tentang Petunjuk Pelaksanaan Pemotongan Pajak atas Penghasilan Sehubungan dengan Pekerjaan, Jasa, atau Kegiatan Orang Pribadi," https://peraturan.bpk.go.id/Download/346093/2023pmkeuangan168.pdf, 2023, diakses 1 Oktober 2026.

[4] ——, "Peraturan Menteri Keuangan Nomor 10 Tahun 2025 tentang Pajak Penghasilan Pasal 21 atas Penghasilan Tertentu yang Ditanggung Pemerintah dalam rangka Stimulus Ekonomi Tahun Anggaran 2025," https://peraturan.bpk.go.id/Download/374407/2025pmkeuangan10.pdf, 2025, diakses 1 Oktober 2026.

[5] ——, "Peraturan Menteri Keuangan Nomor 72 Tahun 2025 tentang Perubahan atas Peraturan Menteri Keuangan Nomor 10 Tahun 2025," https://peraturan.bpk.go.id/Download/394197/72%20TH%202025.pdf, 2025, diakses 1 Oktober 2026.

[6] ——, "Peraturan Menteri Keuangan Nomor 105 Tahun 2025 tentang Pajak Penghasilan Pasal 21 atas Penghasilan Tertentu yang Ditanggung Pemerintah Tahun Anggaran 2026," https://peraturan.bpk.go.id/Download/404917/2025pmkeuangan105.pdf, 2025, diakses 1 Oktober 2026.

[7] D. Merigoux, N. Chataing, and J. Protzenko, "Catala: a programming language for the law," Proceedings of the ACM on Programming Languages, vol. 5, no. ICFP, pp. 1–29, 2021, doi: 10.1145/3473582.

[8] A. Mowbray, P. Chung, and G. Greenleaf, "Representing legislative Rules as Code: Reducing the problems of 'scaling up'," Computer Law & Security Review, vol. 48, p. 105772, 2023, doi: 10.1016/j.clsr.2022.105772.

[9] P. Compton and B. H. Kang, Ripple-Down Rules: The Alternative to Machine Learning. Chapman and Hall/CRC, 2021.

[10] S. Janatian, H. Westermann, J. Tan, J. Savelka, and K. Benyekhlef, "From Text to Structure: Using Large Language Models to Support the Development of Legal Expert Systems," in Legal Knowledge and Information Systems (JURIX 2023), ser. Frontiers in Artificial Intelligence and Applications, vol. 379. IOS Press, 2023, doi: 10.3233/faia230962.

[11] A. Blair-Stanek, N. Holzenberger, and B. Van Durme, "Can GPT-3 Perform Statutory Reasoning?" in Proceedings of the Nineteenth International Conference on Artificial Intelligence and Law. ACM, 2023, pp. 22–31, doi: 10.1145/3594536.3595163.

[12] J. J. Nay et al., "Large language models as tax attorneys: a case study in legal capabilities emergence," Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences, vol. 382, no. 2270, p. 20230159, 2024, doi: 10.1098/rsta.2023.0159.

[13] K. Veeramani, A. Joseph N, and P. M, "Neuro-symbolic reasoning engine for tax optimisation," Frontiers in Artificial Intelligence, vol. 9, May 2026, art. no. 1802755. [Online]. Available: https://doi.org/10.3389/frai.2026.1802755

[14] B. Yadamsuren, S. K. Platt, and M. Diaz, "LLM-assisted formalization for deterministic detection of statutory inconsistency in tax law," Artificial Intelligence and Law, Jul. 2026, published online Jul. 10, 2026; volume and issue not yet assigned. [Online]. Available: https://doi.org/10.1007/s10506-026-09525-6

[15] G. Lorenzo, A. Pietromatera, and N. Holzenberger, "Translating tax law to code with LLMs: A benchmark and evaluation framework," in Proceedings of the Natural Legal Language Processing Workshop 2025. Suzhou, China: Association for Computational Linguistics, Nov. 2025, pp. 31–47. [Online]. Available: https://aclanthology.org/2025.nllp-1.4/

[16] W. Jurayj, N. Holzenberger, and B. Van Durme, "Language models and logic programs for trustworthy tax reasoning," in Proceedings of the AAAI Conference on Artificial Intelligence, vol. 40, no. 45, 2026, pp. 38 688–38 698.

[17] S. Gogani-Khiabani, V. Dewangan, N. Olson, A. Trivedi, and S. Tizpaz-Niari, "Technical challenges in maintaining tax prep software with large language models," arXiv preprint arXiv:2504.18693, 2025, accepted to the 14th Annual IRS/TPC Joint Research Conference on Tax Administration (IRS-TPC 2024). [Online]. Available: https://arxiv.org/abs/2504.18693

[18] A. Gupta, A. Rao, and G. Anumanchipalli, "Model editing at scale leads to gradual and catastrophic forgetting," in Findings of the Association for Computational Linguistics: ACL 2024. Bangkok, Thailand: Association for Computational Linguistics, Aug. 2024, pp. 15 202–15 232. [Online]. Available: https://aclanthology.org/2024.findings-acl.902/

[19] M. Prior, A. Hof, N. Wais, and M. Grabmair, "Risks and limits of automatic consolidation of statutes," in Proceedings of the Natural Legal Language Processing Workshop 2025. Suzhou, China: Association for Computational Linguistics, Nov. 2025, pp. 396–407. [Online]. Available: https://aclanthology.org/2025.nllp-1.29/

[20] Menteri Keuangan Republik Indonesia, "Peraturan Menteri Keuangan Nomor 101/PMK.010/2016 tentang Penyesuaian Besarnya Penghasilan Tidak Kena Pajak," https://peraturan.bpk.go.id/Download/111866/PMK%20Nomor%20101%20Tahun%202016.pdf, 2016, diakses 1 Oktober 2026.

[21] Republik Indonesia, "Undang-Undang Nomor 7 Tahun 2021 tentang Harmonisasi Peraturan Perpajakan," https://peraturan.bpk.go.id/Download/178620/UU%20Nomor%207%20Tahun%202021.pdf, 2021, diakses 1 Oktober 2026.

[22] R. Kowalski and A. Datoo, "Logical English meets legal English for swaps and derivatives," Artificial Intelligence and Law, vol. 30, no. 2, pp. 163–197, 2022, doi: 10.1007/s10506-021-09295-3.

[23] S. Dumancic, W. Meert, S. Goethals, T. Stuyckens, J. Huygen, and K. Denies, "Automated Reasoning and Learning for Automated Payroll Management," Proceedings of the AAAI Conference on Artificial Intelligence, vol. 35, no. 17, pp. 15 107–15 116, 2021, doi: 10.1609/aaai.v35i17.17774.

[24] E. N. Ramadhani, W. Wiranto, and M. K. Giffary, "Perancangan Sistem Perhitungan Pajak Penghasilan Berbasis Web dengan Metode Gross Up," Riset dan E-Jurnal Manajemen Informatika Komputer (REMIK), vol. 6, no. 1, pp. 16–23, 2021, doi: 10.33395/remik.v6i1.11180.

[25] M. J. A. B. Kusuma, D. Armeliza, and T. E. Jaya, "Perancangan Sistem Terintegrasi untuk Otomatisasi Perhitungan PPh Pasal 21," Jurnal Akuntansi, Perpajakan dan Auditing, vol. 7, no. 1, pp. 85–96, 2026, doi: 10.21009/japa.0701.07.

[26] M. O. Moguillansky, D. C. Martinez, L. H. Tamargo, and A. Rotolo, "An approach to temporalised legal revision through addition of literals," Artificial Intelligence and Law, vol. 32, no. 3, pp. 621–666, 2024, doi: 10.1007/s10506-023-09363-w.

[27] J.-C. Gu et al., "Model editing harms general abilities of large language models: Regularization to the rescue," in Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Miami, Florida, USA: Association for Computational Linguistics, Nov. 2024, pp. 16 801–16 819. [Online]. Available: https://aclanthology.org/2024.emnlp-main.934/

[28] J. Seo et al., "KoLEG: On-the-fly Korean legal knowledge editing with continuous retrieval," in Findings of the Association for Computational Linguistics: EMNLP 2025. Suzhou, China: Association for Computational Linguistics, Nov. 2025, pp. 9191–9217. [Online]. Available: https://aclanthology.org/2025.findings-emnlp.489/

[29] M. Chen et al., "Evaluating large language models trained on code," arXiv preprint arXiv:2107.03374, 2021. [Online]. Available: https://arxiv.org/abs/2107.03374

[30] Y. Li et al., "Competition-level code generation with AlphaCode," Science, vol. 378, no. 6624, pp. 1092–1097, Dec. 2022.

[31] N. Varshney, S. Mishra, and C. Baral, "Investigating selective prediction approaches across several tasks in IID, OOD, and adversarial settings," in Findings of the Association for Computational Linguistics: ACL 2022. Dublin, Ireland: Association for Computational Linguistics, 2022, pp. 1995–2002. [Online]. Available: https://aclanthology.org/2022.findings-acl.158/

[32] H. de Martim, "An Ontology-Driven Graph RAG for Legal Norms: A Hierarchical, Temporal, and Deterministic Approach," in Legal Knowledge and Information Systems (JURIX 2025), ser. Frontiers in Artificial Intelligence and Applications. IOS Press, 2025, doi: 10.3233/faia251598.

[33] Publications Office of the European Union, "ELI ontology (European Legislation Identifier), version V1.5," EU Vocabularies, dataset http://publications.europa.eu/resource/dataset/eli, accessed: Oct. 27, 2026. [Online]. Available: https://op.europa.eu/en/web/eu-vocabularies/eli

[34] S. Cox and C. Little, "Time ontology in OWL," W3C Recommendation, 19 Oct. 2017, Oct. 2017. [Online]. Available: https://www.w3.org/TR/2017/REC-owl-time-20171019/

[35] T. Lebo, S. Sahoo, and D. McGuinness, "PROV-O: The PROV ontology," W3C Recommendation, 30 Apr. 2013, Apr. 2013. [Online]. Available: https://www.w3.org/TR/2013/REC-prov-o-20130430/

[36] H. Knublauch and D. Kontokostas, "Shapes constraint language (SHACL)," W3C Recommendation, 20 Jul. 2017, Jul. 2017. [Online]. Available: https://www.w3.org/TR/2017/REC-shacl-20170720/

[37] G. Petrović, M. Ivanković, G. Fraser, and R. Just, "Does Mutation Testing Improve Testing Practices?" in 2021 IEEE/ACM 43rd International Conference on Software Engineering (ICSE). IEEE, 2021, pp. 910–921, doi: 10.1109/icse43902.2021.00087.