Knowledge-Based System Adaptif untuk Perhitungan PPh 21 dengan Akuisisi Pengetahuan Berbantuan LLM dari Regulasi dan Kebijakan Perusahaan

Obi Kastanya

***Abstrak*—Perhitungan PPh Pasal 21 harus mengikuti perubahan regulasi dan kebijakan perusahaan, tetapi pada sistem *payroll* umumnya aturan itu tertanam di kode, sehingga setiap perubahan menuntut pemrograman ulang. Penelitian formalisasi hukum pajak berbantuan LLM membangun basis aturan dari nol untuk keadaan hukum pada satu waktu. Akibatnya belum diketahui apakah pembaruan berulang menjaga hasil periode lama dan apakah kesalahan merambat dari satu perubahan ke perubahan berikutnya. Penelitian ini mengusulkan *knowledge-based system* dengan *knowledge base* bitemporal dua lapis, yaitu lapis regulasi dan lapis kebijakan perusahaan, serta akuisisi pengetahuan inkremental berbantuan LLM. Setiap pembaruan diperiksa lima gerbang verifikasi, kandidat dipilih lewat konsensus perilaku, dan sistem menahan diri (*abstain*) bila tidak yakin. Evaluasinya terdaftar sebelum eksperimen dan mencakup pemutaran ulang 13 perubahan regulasi PPh 21 nyata 2023–2026 beserta 20 dokumen pengecoh, 16 perubahan yang tidak dilihat perancang, deteksi dampak lintas lapis, ablasi, dan model kedua. Representasi menyatakan 16 dari 16 perubahan tak terlihat tanpa mengubah kode *engine* (batas bawah satu sisi 95% sebesar 0,829). Pada 18 dokumen nyata, pembaruan salah yang diterapkan tanpa terdeteksi terjadi pada 3 dokumen (batas atas 0,377, di atas ambang 0,25), dan pembaruan benar pada 8 dokumen (CI 0,22–0,69). Pada mode berantai, 31 dari 33 peristiwa tidak menambah kesalahan baru (batas bawah 0,821), tetapi bila pembaruan dibangkitkan ulang dari basis sistem sendiri angkanya turun menjadi 23 dari 33 (batas bawah 0,540). *Recall* deteksi dampak lintas lapis 0,91 (CI 0,75–1,00).**

Kata Kunci*—Akuisisi pengetahuan, *knowledge-based system*, *knowledge graph*, *large language model*, perubahan regulasi, PPh Pasal 21, *rules as code

I. Pendahuluan

PPH Pasal 21 dipotong setiap bulan dari penghasilan pegawai, sehingga kesalahan perhitungan langsung memengaruhi setiap slip gaji. Regulasinya sering berubah. Dalam empat tahun pajak 2023–2026, korpus penelitian ini mencatat 13 peristiwa yang mengubah perhitungan PPh 21 pegawai tetap (Tabel V), tujuh di antaranya terbit pada 2025. Jenisnya beragam: nilai parameter seperti batas upah iuran Jaminan Pensiun, klasifikasi penghasilan seperti natura, fasilitas Pajak Ditanggung Pemerintah (DTP) dengan kriteria sektor, aturan pembulatan yang berlaku surut, dan pada 2024 pergantian metode perhitungan ke tarif efektif rata-rata (TER) [1], [2].

Pada praktik saat ini, aturan pajak dan kebijakan *payroll* tertanam bercampur di kode atau *spreadsheet* [3]–[5]. Akibatnya ada tiga masalah. Pertama, setiap perubahan regulasi menuntut pemrograman ulang. Di antara kalkulator PPh 21 sumber terbuka yang sudah ada sebelum PP 58/2023, satu memasukkan TER 26 hari sesudah peraturan terbit dan satu lagi baru 915 hari sesudahnya (Bagian VII-D). Kedua, tidak ada bukti bahwa perubahan itu tidak menggeser hasil periode lama. Ketiga, kebijakan perusahaan yang menjadi melanggar setelah regulasi berubah tidak terdeteksi.

Knowledge-based system (KBS) memisahkan pengetahuan dari kode [6], [7], tetapi memindahkan beban ke pemeliharaan *knowledge base*. Inilah *knowledge acquisition bottleneck*. Metode akuisisi inkremental seperti *Ripple-Down Rules* sudah lama ada, tetapi tetap membutuhkan pakar manusia untuk setiap perubahan [8].

Large language model (LLM) dapat menerjemahkan teks hukum menjadi aturan terstruktur [9], [10], tetapi tidak andal untuk perhitungan yang menuntut ketepatan dan dapat mengarang isi hukum [11]–[13]. Penelitian formalisasi pajak berbantuan LLM membangun basis aturan dari nol untuk keadaan hukum pada satu waktu. Penelitian penyuntingan pengetahuan LLM menunjukkan bahwa suntingan berurutan dapat merusak pengetahuan lama [14]. Sejauh penelusuran kami, belum ada penelitian yang mengukur tiga hal pada basis aturan yang dieksekusi: apakah pembaruan berulang dari LLM menjaga hasil periode lama, apakah kesalahan merambat dari satu perubahan ke perubahan berikutnya, dan bagaimana dampaknya terhadap lapisan kebijakan perusahaan.

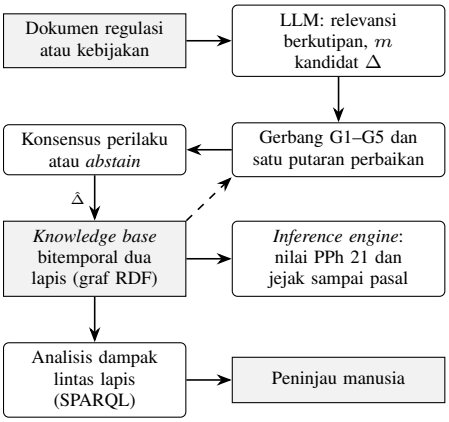
Penelitian ini mengusulkan KBS yang pengetahuannya disimpan sebagai *knowledge graph* bitemporal dua lapis dan dijalankan *inference engine* deterministik (Gambar 1). LLM tidak menghitung pajak. LLM hanya membaca dokumen regulasi atau kebijakan dan menyusun beberapa kandidat pembaruan Δ. Lima gerbang verifikasi menyaring kandidat, konsensus perilaku memilih satu, dan sistem *abstain* bila tidak ada kandidat yang meyakinkan. Analisis dampak statis atas graf melaporkan kebijakan perusahaan yang terdampak.

Penelitian ini menjawab empat pertanyaan penelitian.

RQ1 Adaptivitas representasi. Sejauh mana representasi pengetahuan temporal dua lapis dapat menyatakan perubahan regulasi dan kebijakan, termasuk jenis perubahan yang tidak diketahui saat representasi dirancang, tanpa mengubah kode *engine*?

RQ2 Akuisisi satu langkah. Seberapa sering akuisisi berbantuan LLM menerapkan pembaruan yang benar, seberapa sering ia menerapkan pembaruan salah tanpa terdeteksi, dan berapa besar peran gerbang verifikasi pada kedua angka itu?

RQ3 Adaptivitas operasional berantai. Pada rangkaian perubahan regulasi yang nyata, berapa peristiwa yang berhasil diterapkan otomatis, dan apakah kesalahan meram-



Gambar 1. Ikhtisar sistem. LLM hanya menyusun kandidat pembaruan. Perhitungan dijalankan *engine* deterministik atas *knowledge base*. Garis putus-putus menunjukkan KB yang menjadi konteks LLM dan basis gerbang.

bat dari satu peristiwa ke peristiwa berikutnya?

RQ4 Dampak lintas lapis. Seberapa lengkap dan tepat sistem mengidentifikasi kebijakan perusahaan yang terdampak atau menjadi melanggar setelah regulasi berubah?

Kontribusinya sebagai berikut.

K1 Representasi pengetahuan temporal dua lapis untuk perhitungan pajak penghasilan pegawai, dengan resolusi konflik antarlapis dan analisis dampak lintas lapis (RQ1, RQ4).

K2 Metode akuisisi pengetahuan inkremental berbantuan LLM dengan gerbang verifikasi, gerbang non-vakuitas, dan pemilihan kandidat berbasis konsensus perilaku (RQ2).

K3 Definisi adaptivitas representasional dan operasional, serta protokol *regulation replay* yang memisahkan kesalahan bawaan, kesalahan baru, dan kesalahan yang dipicu perambatan, beserta bukti empiris pada rangkaian perubahan PPh 21 yang nyata (RQ3).

K4 Artefak berupa *knowledge base*, korpus perubahan beserta pembaruan emas, *test suite* dengan *ground truth*, dan kode evaluasi.

Tabel VII menghubungkan setiap kontribusi dengan RQ, hipotesis, dan metrik utamanya.

Bagian II menjelaskan domain dan merumuskan masalah. Bagian III membahas penelitian terkait. Bagian IV dan V menjelaskan representasi dan metode akuisisi. Bagian VI menjelaskan metodologi evaluasi, Bagian VII melaporkan hasil, Bagian VIII membahasnya, dan Bagian IX menutup penelitian ini.

II. Latar belakang dan rumusan masalah

A. Perhitungan PPh 21 pegawai tetap

PPh 21 pegawai tetap dihitung dari penghasilan bruto, yaitu gaji, tunjangan, penghasilan tidak teratur seperti THR dan bonus, premi jaminan sosial yang dibayar pemberi kerja, dan sejak Juli 2023 natura. Bruto dikurangi biaya jabatan dan iuran pegawai yang menjadi pengurang, lalu penghasilan tidak kena pajak (PTKP) menurut status, sehingga diperoleh penghasilan kena pajak (PKP). Atas PKP setahun dikenakan tarif progresif Pasal 17 [15], [16]. Sampai 2023, PPh setiap masa dihitung dengan menyetahunkan penghasilan [17]. Sejak 2024, masa Januari sampai November memakai TER bulanan, yaitu tarif atas bruto bulanan menurut kategori A, B, atau C yang ditentukan status PTKP. Pada masa pajak terakhir, pajak setahun dihitung ulang dengan tarif Pasal 17 dan dikurangi potongan masa sebelumnya [1], [2]. Fasilitas DTP 2025–2026 menambah kriteria sektor dan batas penghasilan [18]–[20]. Tabel I merangkum dimensi yang menentukan besarnya pajak.

Tabel I
Dimensi perhitungan PPh 21 pegawai tetap yang dicakup

Dimensi	Nilai
Rezim	Disetahunkan (sampai 2023); TER (sejak 2024); TER dengan fasilitas DTP (2025–2026)
Lapisan Pasal 17	5%, 15%, 25%, 30%, 35% (4 lapisan sebelum UU HPP)
Kategori TER	A (44 lapisan), B (40), C (41), menurut lampiran PP 58/2023
Status PTKP	TK/0–TK/3, K/0–K/3; menentukan kategori TER
Metode	*Gross*, *gross-up*, ditanggung pemberi kerja
Pola kerja	Setahun penuh, masuk di tengah tahun, keluar di tengah tahun
Penghasilan	Teratur, tidak teratur (THR, bonus), natura, premi BPJS, zakat lewat pemberi kerja

Ruang lingkupnya adalah pegawai tetap pada pemberi kerja swasta atau BUMN, tahun pajak 2023–2026 untuk data uji dan tahun sebelumnya untuk data pengembangan. Pegawai tidak tetap, bukan pegawai, pensiunan, ASN, peserta magang, PPh 26, dan pegawai di IKN berada di luar lingkup. Batasan antardimensi ikut menentukan ruang uji. Contohnya, status PTKP menentukan kategori TER, dan fasilitas DTP hanya ada sejak 2025.

B. Kebijakan perusahaan dan batas kewenangannya

Perusahaan menentukan komponen penghasilan seperti prorata, THR, tunjangan, lembur, siapa yang menanggung pajak, dan pembagian iuran. Pilihan yang memang diserahkan kepada perusahaan, misalnya metode *gross*, *gross-up*, atau ditanggung pemberi kerja, bukan konflik. Perusahaan tidak boleh menyimpangi ketentuan wajib, misalnya klasifikasi jenis penghasilan atau penerusan fasilitas pemerintah kepada pegawai. Contoh konflik nyata ada pada PKB PT Wijaya Karya 2025–2026 Pasal 22 ayat (3), yang menyatakan insentif pajak pemerintah tidak diberikan kepada pegawai. Ketentuan ini berlawanan dengan PMK 10/2025 Pasal 5 ayat (1), yang mewajibkan PPh DTP dibayarkan tunai kepada pegawai [18]. Konflik ini laten, karena perusahaan itu bukan sektor penerima DTP. Taksonomi konflik penelitian ini memuat sepuluh jenis (C1–C10), misalnya klasifikasi menyimpang (C1), parameter usang (C6), dan hak minimum dilanggar (C10). Konflik yang diukur RQ4 adalah konflik *terpicu perubahan*, yaitu kebijakan yang tadinya sah menjadi berkonflik setelah regulasi berubah.

C. Jenis perubahan regulasi

Taksonomi perubahan disusun sebelum ada keluaran LLM. Setiap peristiwa diberi satu jenis utama: parameter (T1), tabel tarif (T2), klasifikasi penghasilan (T3), fasilitas baru (T4), perubahan cakupan (T5), perubahan masa (T6), pergantian metode (T7), pencabutan tanpa pengganti (T8), perubahan prosedur hitung seperti pembulatan (T9), dan perubahan kebijakan perusahaan (T10). Sifat tambahannya adalah berlaku

surut (S1), bersyarat (S2), sementara (S3), terdiri atas beberapa dokumen (S4), mengubah dokumen lain (S5), dan bergantung tabel lampiran (S6). Pengecoh juga diberi jenis, misalnya ketentuan administrasi (X1) dan subjek di luar lingkup (X2). Hasil dilaporkan per jenis, sehingga jenis mudah seperti parameter tidak digabung dengan jenis struktural.

D. Rumusan masalah

Masukannya adalah sistem yang benar untuk keadaan hukum sebelum suatu perubahan, beserta dokumen perubahan itu. Keluarannya adalah sistem yang benar untuk keadaan hukum sesudahnya, tanpa perubahan kode dan tanpa perubahan pada hasil yang tidak seharusnya berubah. Definisi formalnya ada di Bagian V-A.

III. Penelitian terkait

A. Rules as code dan formalisasi peraturan pajak

Catala menerjemahkan teks undang-undang ke bahasa pemrograman dengan pola kasus umum dan pengecualian berbasis *default logic*, dan evaluasinya menemukan *bug* pada implementasi resmi [7], [21]. Mlang menggantikan *compiler* warisan mesin pajak penghasilan Prancis [22]. Ekosistem yang sama memformalkan aritmetika tanggal [23] dan membangkitkan kasus uji dengan *concolic execution* [24]. DataLex [6], [25], Logical English [26], dan OpenFisca mengikuti prinsip yang sama. Meessen menunjukkan bahwa banyak keputusan normatif dibuat di dalam komponen teknis [27], dan Witt dkk. membedakan validasi teknis dari kesesuaian hukum [28]. Untuk *payroll*, Dumancic dkk. menyatakan legislasi pajak dan jaminan sosial secara deklaratif untuk optimasi kebijakan [29], dan Al-Hawari dkk. membangun sistem *payroll* berbasis aturan [30]. Di Indonesia, sistem PPh 21 umumnya prosedural [3]–[5], dan TER menimbulkan lebih bayar pada penghasilan tidak teratur [31]. Dalam semua karya ini pengetahuan ditulis manusia. Parameter berversi sudah ada, tetapi pembaruan oleh mesin belum dievaluasi.

B. Akuisisi pengetahuan inkremental

Ripple-Down Rules menambah aturan setiap kali pakar menemukan kasus yang salah, dan *cornerstone case* menjaga agar aturan baru tidak merusak kasus yang sudah benar [8]. Gerbang regresi G4 dalam penelitian ini setara dengan *cornerstone case*. Pada sisi logika hukum, perubahan hukum dan revisi teori dirumuskan dengan operator revisi berwaktu [32], revisi *defeasible logic* terbukti sulit secara komputasi [33], dan konsekuensi janggal dapat ditelusuri ke aturan penyebabnya [34]. Dalam kelompok ini pakar manusia tetap menulis setiap perubahan.

C. LLM untuk formalisasi hukum dan pajak

Kelompok ini paling dekat dengan penelitian ini. LLM dipakai untuk mengubah teks hukum menjadi struktur yang mendukung sistem pakar hukum [9], untuk menyusun aturan DMN bagi kantor akuntan [10], dan untuk menurunkan relasi metamorfik bagi perangkat lunak pajak [35], [36]. Kemampuan LLM menerapkan hukum pajak meningkat antargenerasi, tetapi belum setara ahli [11], [12], dan alat riset hukum komersial masih berhalusinasi [37]. Karya-karya ini memformalkan dari nol untuk keadaan hukum pada satu waktu.

D. Pembaruan berulang oleh LLM dan evaluasinya

Penyuntingan pengetahuan LLM secara berurutan merusak kemampuan model setelah banyak suntingan [14]. Evaluasi berbasis eksekusi dengan n kandidat dan pemilihan satu jawaban, yang dikenal sebagai $n@k$, berasal dari pembangkitan kode [38]. Prediksi selektif memungkinkan model menahan jawaban ketika tidak yakin, dan kinerjanya diukur sebagai pasangan risiko dan cakupan [39]. Ketiganya menjadi dasar metrik RQ2 dan RQ3. Metrik tersebut belum diterapkan pada basis aturan hukum yang dieksekusi dan berversi waktu.

E. Representasi temporal dan knowledge graph hukum

De Martim memodelkan norma sebagai karya dengan ekspresi berversi agar jawaban tidak anakronistik [40], dan Kharraz dkk. mendefinisikan konflik pada logika normatif berwaktu [41]. Penelitian ini memakai ulang standar ELI, OWL-Time, dan PROV-O untuk dokumen, masa berlaku, dan provenans.

F. Konflik norma, verifikasi knowledge base, dan pengujian perangkat lunak pajak

Deteksi konflik norma [42], [43], anomali *rule base* [44], dan pengujian perangkat lunak pajak yang sulit karena acuan kebenarannya tidak tersedia [45], [46] menjadi dasar rancangan *ground truth* penelitian ini. Demikian juga *property-based testing* [47], [48] dan *mutation analysis* [49], [50]. Karya-karya tersebut dipakai sebagai dasar rancangan, bukan sebagai kontribusi.

Tabel II merangkum posisi penelitian ini. Tanda "–" berarti aspek itu tidak dilaporkan sebagai fokus publikasi yang dirujuk.

IV. Representasi pengetahuan dan *inference engine*

A. Model pengetahuan

Pengetahuan dibagi dua. Pengetahuan struktural, yaitu dokumen hukum dan pasalnya, aturan, parameter, tabel, konsep fakta, kebijakan perusahaan, versi, serta relasi bersumber, menghasilkan, membaca, mengungguli, mengubah, dan berkonflik, disimpan sebagai *knowledge graph* RDF/OWL dengan validasi SHACL dan kueri SPARQL. Pengetahuan komputasional berupa ekspresi perhitungan disimpan sebagai atribut *literal* pada simpul aturan dan dijalankan *inference engine*. Alasannya, pertanyaan tentang asal-usul aturan, fakta yang dibacanya, dan kebijakan yang bergantung padanya adalah pertanyaan graf yang dijawab tanpa menjalankan perhitungan. Analisis dampak (RQ4), gerbang G3, dan pemeriksa anomali memakainya. Sebaliknya, aritmetika pajak menuntut ketepatan rupiah, pecahan eksak, titik pembulatan, dan iterasi titik tetap untuk *gross-up*, yang tidak praktis dinyatakan sebagai *triple*. Dengan pembagian ini, perubahan regulasi hanya menyentuh data graf.

Tabel II
POSISI PENELITIAN TERHADAP KARYA TERKAIT

Karya	Domain	Representasi	Penyusun pengetahuan	Pembaruan inkremental	Perambatan kesalahan diukur	Lapisan perusahaan	Evaluasi
Catala [7], [21]	pajak dan tunjangan	DSL dengan *default logic*	manusia	–	–	–	temuan *bug* implementasi resmi
DataLex [6], [25]	legislasi umum	bahasa aturan semi-alami dan *inference engine*	manusia	–	–	–	–
Dumancic dkk. [29]	*payroll*	representasi formal ke *constraint*	manusia	–	–	–	pemakaian di lembaga jaminan sosial
Ripple-Down Rules [8]	umum	aturan dengan pengecualian	pakar manusia	ya	–	–	*cornerstone case*
Janatian dkk. [9]	sistem pakar hukum	struktur dari teks	LLM	–	–	–	penilaian manusia
Makowski & Trąbka [10]	akuntansi pajak	DMN	AI generatif dan manusia	–	–	–	studi kasus
De Martim [40]	norma hukum	graf norma berversi	–	versi norma	–	–	–
Sistem PPh 21 Indonesia [3]–[5]	PPh 21	aplikasi prosedural atau *spreadsheet*	manusia	–	–	–	–
Penelitian ini	PPh 21	*knowledge graph* temporal dua lapis dan aturan yang dapat dieksekusi	LLM dengan gerbang	ya	ya	ya	*regulation replay*

Definisi 1 (*Knowledge base*)**.** *$\mathcal{K} = \langle \mathcal{O}, \mathcal{R}, \mathcal{P}, \mathcal{T}, \mathcal{C}, \mathcal{D} \rangle$ terdiri atas ontologi konsep, rekaman aturan, rekaman parameter berversi, versi tabel, batasan wajib, dan dokumen sumber beserta provenans pembaruan. Setiap unsur $\mathcal{R}$ berada pada lapisan $\ell \in \{reg, prs\}$. Parameter, tabel, dan batasan hanya ada di lapisan regulasi. Setiap aturan perusahaan milik tepat satu kebijakan P_j, sehingga $\mathcal{K} = \mathcal{K}_{reg} \oplus \bigcup_j P_j$, dan untuk kasus x hanya kebijakan $P(x)$ yang disebut data kasus yang dipasang.*

Definisi 2 (Aturan)**.** *Rekaman aturan $r = \langle id, \ell, \sigma, \kappa, [t_s, t_e], t_c, \varphi, f := e, ov, src \rangle$ memuat identitas, lapisan, sifat $\sigma \in \{$wajib, default, opsional$\}$, lingkup $\kappa \in \{$masa, tahun$\}$, masa berlaku, tanggal pencatatan t_c (tanggal terbit dokumen sumber), kondisi, fakta yang dihasilkan beserta ekspresinya, daftar aturan yang dikalahkannya, dan sumber berupa dokumen, pasal, dan kutipan. Rekaman tidak pernah disunting di tempat. Operasi add, change, dan remove menambah rekaman baru, dengan remove berupa rekaman nisan.*

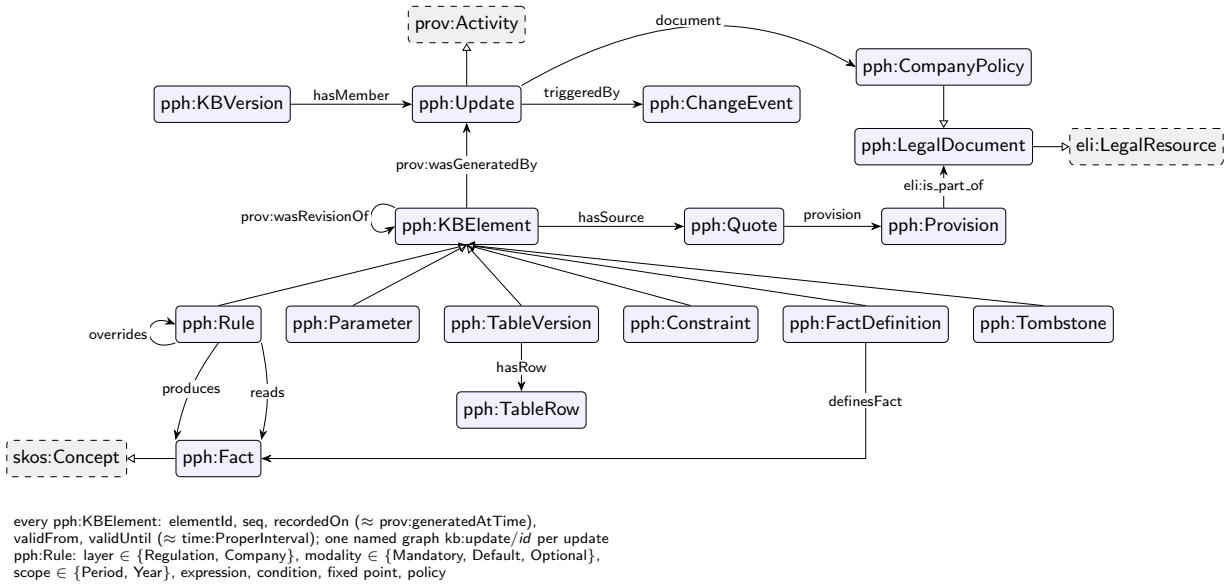
Definisi 3 (Hasil perhitungan)**.** *$hasil(\mathcal{K}, x, t, \omega)$ adalah nilai fakta keluaran untuk kasus x pada masa pajak t, dihitung dengan $\mathcal{K}_{reg}$ sebagaimana diketahui pada tanggal ω ditambah lapisan $P(x)$. Kasus adalah satu pegawai tetap pada satu pemberi kerja untuk satu tahun pajak. Fakta utama adalah PPh 21 terutang per masa. Fakta pendukung yang dinilai mencakup PPh DTP, bruto, tunjangan pajak, take home pay, premi dan iuran BPJS, serta fakta masa pajak terakhir seperti bruto setahun, biaya jabatan, PTKP, PKP, PPh setahun, dan pengembalian kepada pegawai. Selain nilai, engine mengeluarkan laporan konflik dan jejak setiap fakta.*

Ontologi (Gambar 2) memakai ulang ELI untuk dokumen dan pasal, OWL-Time untuk masa berlaku, dan PROV-O untuk provenans rekaman dan pembaruan. Setiap pembaruan disimpan sebagai satu *named graph* di *triple store* GraphDB, dan sidik jari SHA-256 setiap versi dicatat di graf metadata.

Bahasa ekspresi. Ekspresi adalah subset ekspresi Python satu baris dengan 27 fungsi terdaftar, misalnya `round(x, satuan, mode)`, `param`, `lookup`, `bracket`, `progressive`, `in_table`, dan agregat masa seperti `sum_periods` dan `cumulative`. Literal pecahan biner, atribut, *lambda*, argumen bernama, fungsi tak terdaftar, dan nama fakta di luar kosakata ditolak saat *parse*. Tipe dasarnya *money* (rupiah bulat), *exact*, *rate*, *int*, *bool*, *category*, dan *date*. Semua aritmetika eksak, dan pembulatan hanya terjadi lewat `round` dengan mode dari parameter berversi, sehingga perubahan pembulatan seperti PER-11/PJ/2025 adalah pembaruan data. Batasan ini juga membatasi keluaran LLM. Kandidat yang memakai fungsi atau fakta di luar kosakata tertolak di G1 atau G3.

Semantik temporal. Ada dua sumbu waktu. Waktu berlaku $[t_s, t_e]$ dibandingkan dengan tanggal evaluasi, yaitu tanggal 1 masa untuk aturan lingkup masa atau irisan dengan rentang kerja setahun untuk aturan lingkup tahun. Waktu pengetahuan t_c adalah tanggal terbit dokumen. Pertanyaan pada ω hanya melihat rekaman dengan $t_c \leq \omega$, sehingga $\mathcal{K}$ bitemporal. Untuk regulasi berlaku surut ($t_s < t_c$), pertanyaan dengan $\omega \geq t_c$ menghasilkan *nilai seharusnya*. Mekanisme penyelesaiannya, misalnya pembayaran tunai DTP Januari pada penggajian berikutnya, dicatat di jejak tetapi tidak dinilai, karena bergantung pada apa yang benar-benar dipotong pada tanggal penggajian.

Bentuk kanonik dan batas ekspresivitas. Ekspresi dinormalisasi dengan mengurutkan operan komutatif, melipat konstanta, dan menormalkan perbandingan, sehingga unsur dapat dicocokkan pada metrik diagnostik. Kebenaran utama tetap diukur dari perilaku. Representasi sengaja tidak dapat menyatakan hubungan antarpegawai atau antar-pemberi kerja, perhitungan lintas tahun pajak, satuan masa selain bulan, persamaan simultan beberapa fakta, kewajiban prosedural tanpa angka, pertimbangan yang tidak tercermin di data kasus, dan kurs valas. Penambahan fungsi baru adalah perubahan *engine*. Penambahan fakta, parameter, tabel, atau atribut kasus bukan



Gambar 2. Ontologi *knowledge base*. Kelas utama adalah dokumen hukum, pasal, kutipan, unsur KB (aturan, parameter, versi tabel, batasan, nisan, definisi fakta), konsep fakta, kebijakan perusahaan, peristiwa perubahan, pembaruan, dan versi KB.

perubahan *engine*.

B. Resolusi konflik antarlapis

Bila lebih dari satu aturan aktif untuk fakta yang sama pada konteks yang sama, *engine* memilih pemenang dengan tiga asas berurutan. *Lex superior* memberi peringkat 4 untuk aturan regulasi wajib, 3 untuk aturan perusahaan, 2 untuk aturan regulasi opsional yang diadopsi kebijakan, dan 1 untuk aturan regulasi *default*. Bila aturan perusahaan yang aktif kalah dari aturan wajib dengan nilai berbeda, *engine* mencatat konflik (A4). *Lex specialis* dinyatakan sebagai relasi eksplisit `overrides` antaraturan, bukan diturunkan dari sintaks kondisi, dan relasi ini harus asiklik. *Lex posterior* memenangkan aturan dengan t_s paling akhir, lalu tanggal pencatatan rekaman pertama paling akhir, agar revisi metadata aturan lama tidak membuatnya menang kembali. Bila masih tersisa beberapa aturan dengan nilai berbeda, fakta itu tidak terdefinisi dan *engine* melaporkan `UnresolvedConflict`. Hierarki peraturan (UU, PP, PMK, PER) tidak dipakai *engine*. Pertentangan antartingkat dinyatakan dengan `overrides` di pembaruan. Batasan wajib, misalnya THR paling sedikit satu bulan upah, dievaluasi setelah semua fakta dihitung, dan pelanggarannya dilaporkan dengan kode konflik.

C. Inference engine

Engine menghitung satu kasus untuk seluruh tahun pajak (Algoritma 1). Evaluasi berbasis permintaan dengan memo setara dengan menelusuri graf dependensi fakta secara topologis. Aturan *gross-up* bertanda titik tetap dihitung dengan iterasi dari batas bawah sampai konvergen ke titik tetap terkecil. Bila pembulatan membuat iterasi masuk siklus, dipilih nilai terkecil dalam siklus yang menutup pajaknya sendiri. Siklus lain adalah galat `CircularDefinition`. Jejak setiap fakta memuat aturan pemenang, aturan yang kalah beserta alasannya, sumber hukum, fakta yang dibaca, serta parameter dan versi tabel yang dipakai.

Algoritma 1 Inferensi untuk satu pegawai dan satu tahun pajak

Require: $\mathcal{K}$, kasus x, tanggal pengetahuan ω
1: $R_\omega \leftarrow$ rekaman terakhir per id dengan $t_c \le \omega$, tanpa nisan; pasang lapisan $P(x)$
2: verifikasi statis R_ω (sekali per versi)
3: **for** setiap fakta keluaran f dan konteks c (masa atau tahun) **do**
4: $\quad kandidat \leftarrow$ aturan untuk f yang berlaku pada tanggal evaluasi c
5: $\quad aktif \leftarrow$ kandidat dengan kondisi φ benar
6: $\quad r^* \leftarrow$ resolusi(*lex superior*, *specialis*, *posterior*); catat konflik
7: $\quad v \leftarrow e_{r^*}(c)$, atau titik tetap terkecil bila r^* bertanda titik tetap
8: $\quad$ periksa tipe; simpan memo dan jejak
9: **end for**
10: evaluasi batasan wajib; catat pelanggaran
11: **return** nilai, laporan konflik, jejak

V. Akuisisi pengetahuan inkremental berbantuan LLM

A. Pembaruan dan adaptivitas

Definisi 4 (Peristiwa perubahan)**.** $\epsilon = \langle d, t_{terbit}, t_{berlaku}, \tau \rangle$ *terdiri atas dokumen sumber, tanggal terbit (tanggal diundangkan bila ada), tanggal mulai berlaku hukum, dan jenis perubahan. Peristiwa berlaku surut bila* $t_{berlaku} < t_{terbit}$*. Rangkaian* $\epsilon_1, \ldots, \epsilon_N$*, termasuk pengecoh, diurutkan menurut* t_{terbit}*.*

Definisi 5 (Pembaruan)**.** $\Delta = \langle \Delta^+, \Delta^\sim, \Delta^- \rangle$ *berisi unsur yang ditambah, diubah, dan dicabut, dengan* $\mathcal{K}' = \mathcal{K} \oplus \Delta$*.*

Penerapan ketat menolak add untuk id yang sudah ada dan change untuk id yang belum ada. Pembaruan emas memenuhi $\mathcal{K}^\star_n = \mathcal{K}^\star_{n-1} \oplus \Delta^\star_n$. Δ kosong adalah jawaban benar untuk pengecoh.

Definisi 6 (Syarat adaptif)**.** *Untuk $\mathcal{K}' = \mathcal{K} \oplus \Delta$ dan himpunan kasus S: (A1) Invariansi kode. Kode engine tidak berubah. (A2) Kesesuaian. $hasil(\mathcal{K}', x, t, \omega) = hasil(\mathcal{K}^\star, x, t, \omega)$ untuk $x \in S$, $t \geq t_{berlaku}$, dan $\omega \geq t_{terbit}$. (A3$_t$) Isolasi masa. Hasil untuk $t < t_{berlaku}$ tidak berubah, untuk semua ω. (A3$_\omega$) Isolasi pengetahuan. Hasil untuk $\omega < t_{terbit}$ tidak berubah. (A4) Konsistensi lintas lapis. Laporan konflik $\mathcal{K}'$ sama dengan laporan konflik $\mathcal{K}^\star$ untuk kasus yang memuat kebijakan.*

Definisi 7 (Adaptivitas representasional)**.** *Representasi adaptif terhadap ϵ bila* ada Δ *dalam bahasa representasi yang memenuhi A1–A4. Ini sifat representasi, dibuktikan dengan menyusun $\Delta^\star$ (RQ1).*

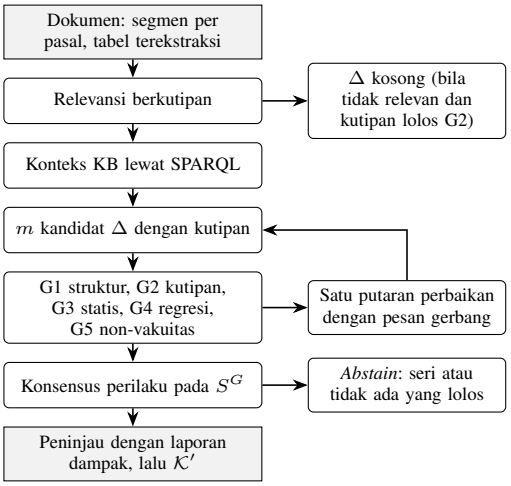
Definisi 8 (Adaptivitas operasional)**.** *Sistem adaptif secara operasional terhadap ϵ bila pembaruan $\hat{\Delta}$ yang* dipilih alur akuisisi *memenuhi A2, A3$_t$, dan A4 pada seluruh S^E. Satu observasi salah sudah membuat $\hat{\Delta}$ salah. Ini sifat alur akuisisi, diukur sebagai laju atas peristiwa (RQ2, RQ3).*

A1 berlaku karena arsitekturnya, sebab LLM hanya menyunting *knowledge base*. A3$_\omega$ berlaku karena konstruksi, sebab G2 mewajibkan setiap rekaman dicatat dengan $t_c = t_{terbit}$. Keduanya diperiksa sebagai invarian. A1 diperiksa dengan sidik jari SHA-256 paket *engine*, bahasa ekspresi, dan semantik rekaman terhadap manifes yang dibekukan. Syarat yang bergantung pada LLM, yaitu A2, A3$_t$, dan A4, yang diuji.

B. Alur akuisisi

Gambar 3 menunjukkan alurnya. (1) Teks dokumen diambil sekali, dikunci dengan SHA-256, lalu dipotong per pasal. Tabel lampiran diekstraksi sekali oleh alat ekstraksi tabel, dan LLM merujuknya dengan id, pemetaan kolom, dan penyaring baris tanpa menyalin baris. Segmen dipilih dengan skor leksikal dari label KB dan istilah pajak sampai anggaran 14.000 token. (2) LLM menilai relevansi dengan kutipan pendukung, tanggal berlaku, dan subjek. Bila dokumen dinilai tidak relevan dan kutipannya lolos G2, sistem menerapkan Δ kosong. (3) Konteks KB disusun lewat SPARQL, yaitu kosakata fakta, katalog fungsi, rekaman yang labelnya cocok dengan segmen, dan tetangga satu langkahnya. (4) LLM menyusun m kandidat secara independen, setiap unsur disertai kutipan. (5) Kandidat melewati G1–G5, dan kandidat yang gagal mendapat satu putaran perbaikan dengan pesan gerbang. (6) Kandidat yang lolos dikelompokkan menurut perilakunya, yaitu nilai fakta keluaran dan laporan konflik pada gabungan S^G semua kandidat yang lolos. Kelompok terbesar menang. Seri antara dua kelompok terbesar, atau tidak ada kandidat yang lolos, berarti *abstain*. (7) Dalam operasi, peninjau manusia memeriksa pembaruan dengan laporan dampak. (8) Pembaruan berlaku sebagai versi baru *knowledge base*.

Tabel tarif lampiran, misalnya tarif TER, tidak disalin LLM. Alat ekstraksi tabel yang deterministik dipakai, dan pilihan ini dicatat di pra-registrasi. Cara ini memisahkan kemampuan memahami aturan dari kemampuan menyalin angka.



Gambar 3. Alur akuisisi pengetahuan inkremental.

Tabel III
GERBANG VERIFIKASI DAN SYARAT YANG DIJAGANYA

ID	Pemeriksaan	Syarat
G1	Skema keluaran, penerapan ketat, dan 15 *shape* inti serta 12 batasan SHACL-SPARQL atas $\mathcal{K}'$	validitas
G2	Kutipan ≥ 20 karakter adalah *substring* teks yang dinormalisasi; setiap bilangan ≥ 100, pecahan, dan tanggal baru muncul di kutipan unsurnya; $t_c = t_{terbit}$	keberadaan kutipan, A3$_\omega$
G3	Verifikasi statis ekspresi, graf dependensi asiklik kecuali titik tetap, tanpa rujukan menggantung; peringatan anomali	A4
G4	Regresi pada S^G: hasil sebelum $s(\Delta)$ dan hasil dengan $\omega < t_{terbit}$ tidak berubah; tanpa galat *engine* baru	A3$_t$
G5	Non-vakuitas untuk Δ tidak kosong: setiap unsur yang ditambah atau diubah mengubah minimal satu fakta keluaran atau laporan konflik pada S^G sesudah $s(u)$; unsur yang dicabut pernah menyala; tanggal dan subjek dari penilaian relevansi tercermin	menolak pembaruan tanpa efek

C. Gerbang verifikasi

Tabel III merangkum gerbang. Untuk G4 dan G5, setiap unsur u diberi *tanggal mulai efek* $s(u)$, yaitu tanggal pertama di mana rekaman yang berlaku untuk id-nya dapat berbeda antara $\mathcal{K}$ dan $\mathcal{K}'$. Dengan begitu, pembaruan yang menutup masa berlaku aturan lama tidak keliru dianggap regresi.

Tanpa G5, pembaruan kosong atau aturan yang tidak pernah menyala lolos semua gerbang, karena keduanya tidak menimbulkan regresi. Putaran perbaikan yang hanya menerima umpan balik regresi bahkan dapat mendorong kandidat ke arah itu. Pembaruan kosong hanya dapat diterapkan lewat penilaian relevansi yang berkutipan, sehingga G5 tidak bertentangan dengan dokumen pengecoh.

S^G dibangkitkan per kandidat dari $\mathcal{K} \oplus \hat{\Delta}$ dan hasil penilaian relevansi, tanpa membaca emas atau S^E. Generator menyasar tahun dan bulan sekitar $s(u)$, ambang di kondisi dan tabel pada $b-1$, b, dan $b+1$ lewat pencarian biner atas gaji pokok, variasi atribut kasus yang muncul di kondisi, pola kerja masuk dan keluar, serta komponen tidak teratur dan natura. Ukurannya paling banyak 300 kasus per kandidat. Setiap kasus S^G memuat komponen penanda senilai 7 rupiah

yang tidak pernah dipakai S^E, dan irisan kunci kanonik kedua himpunan diperiksa kosong. Syarat pembekuan gerbang adalah laju penolakan keliru nol atas seluruh $\Delta^\star$ pengembangan.

D. Analisis dampak lintas lapis

Kebijakan P *terdampak* oleh peristiwa ϵ_n bila, pada kasus S^E yang memuat P, (a) nilai fakta yang dihasilkan aturan P berubah untuk minimal satu observasi sesudah $t_{berlaku}$, (b) aturan pemenang suatu fakta yang dihasilkan atau dibaca P berubah, atau (c) muncul entri konflik baru yang melibatkan P. Label (a) dan (b) diturunkan dari eksekusi $\mathcal{K}^\star_{n-1} \oplus P$ dan $\mathcal{K}^\star_n \oplus P$, sedangkan detektor bekerja statis pada graf, sehingga label tidak tautologis. Detektor menghitung F_Δ, yaitu fakta yang dihasilkan unsur Δ dan fakta yang dihasilkan aturan pemakai parameter atau tabel di Δ, lalu penutup hilirnya lewat `pph:reads`. Aturan P yang membaca fakta di penutup itu dengan masa berlaku beririsan ditandai (a). Aturan P yang menghasilkan fakta yang sama dengan aturan Δ ditandai (b), dan (c) bila aturan Δ itu wajib. Kuerinya ditulis dalam SPARQL dan dibekukan sebelum E4.

E. Konfigurasi LLM

Model utama adalah Claude Opus 5.5 dengan *training cutoff* Juni 2026 (pengenal API `claude-opus-5-5`), dipakai dengan *effort* `medium` untuk relevansi dan `high` untuk penyusunan dan perbaikan. Model kedua adalah `gpt-6.1-sol` (*cutoff* 30 April 2026) dengan *reasoning effort* `high`. Parameter *sampling* tidak dapat diatur pada kedua model, sehingga keragaman kandidat berasal dari *sampling* bawaan. Keluaran memakai *structured output* dengan skema datar versi 2. Skema versi 1 ditolak API karena tata bahasa terkompilasinya terlalu besar. Awalan bersama, yaitu instruksi, skema, segmen, tabel, dan konteks KB, disimpan dengan *prompt caching*. Panggilan eksperimen dijalankan pada 28–29 Oktober 2026 dan dicatat lengkap, yaitu *prompt*, keluaran mentah, token, biaya, durasi, dan hasil setiap gerbang, sehingga semua analisis dapat diulang tanpa memanggil LLM lagi. Sebagian besar token keluaran adalah penalaran, dengan rasio karakter JSON per token keluaran 1,1–1,5.

VI. Metodologi evaluasi

Evaluasi memakai lima prinsip. Setiap RQ punya satu metrik utama yang ditetapkan sebelum eksperimen. Kebenaran diukur dari perilaku hasil perhitungan, bukan dari kemiripan bentuk aturan. Data yang dipakai sistem terpisah dari data penilainya. Alat ukur divalidasi sebelum dipakai. Karena jumlah peristiwa nyata kecil, hasil dilaporkan sebagai estimasi dengan selang kepercayaan eksak.

A. Desain penelitian dan pra-registrasi

Penelitian ini mengikuti *design science research*. Hipotesis, metrik utama, ambang, pembagian data, kasus uji, dan rencana analisis dikunci dengan *tag* git `prareg` sebelum peristiwa uji pertama dijalankan. Alur akuisisi, *prompt*, gerbang, generator S^G, dan aturan konsensus dibekukan dengan *tag* `alur-beku`, *engine* dengan `engine-v1`, dan emas dengan `emas-v1`. Analisis terdiri atas tiga jenis. Pemeriksaan invarian mencakup A1 dan A3$_\omega$. Analisis konfirmatori menguji hipotesis dengan metrik utama. Analisis eksploratori memakai metrik diagnostik.

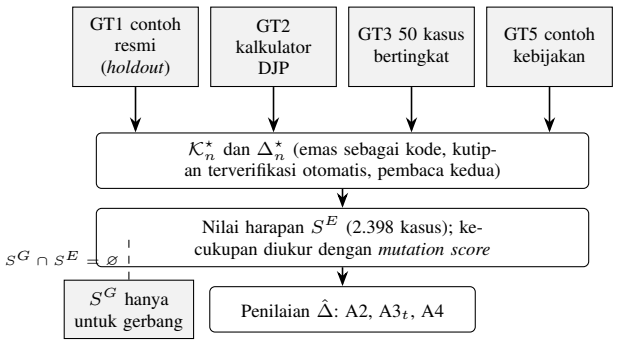
Anggaran awal LLM adalah USD 15 untuk seluruh penelitian. Anggaran itu habis sesudah strata utama E2, E3, dan E4. Sesudah hasil awal terlihat, peneliti menambah anggaran dan menulis amandemen 1 (*tag* `prareg-amandemen-1`) sebelum jalan tambahan mana pun. Amandemen tidak mengubah alur, *engine*, emas, S^E, ambang, atau δ_S. Karena hasil awal sudah terlihat, amandemen ini *tidak buta*. Jalan yang ditambahkan lewat amandemen adalah sembilan pengecoh sisa sehingga H3a diuji pada $N = 33$ sesuai rancangan, jalan terisolasi kedua untuk batas derau H3b, rantai pembangkitan ulang untuk komponen kontekstual H3b, sensitivitas $m = 5$, model kedua, strata kontrafaktual dan kebijakan buatan, ablasi AB1, AB2, dan AB5, pembanding B2, analisis kontaminasi, dan label ketepatan kutipan. Kecuali tiga yang pertama, semuanya berstatus eksploratori. Detektor dampak v2 dan penyelarasan kunci konflik pada penilai A4 juga dibuat sesudah hasil awal terlihat.

B. Pembagian data dan kronologi

- **Pengembangan.** 13 peristiwa 2012–2022 (D01–D13), lima regulasi fiktif (FR01–FR05), dan PKB TPK Koja 2012. Data ini dipakai untuk merancang *prompt*, gerbang, dan aturan pemilihan, lalu ketiganya dibekukan.
- **Uji.** 13 peristiwa nyata 2023–2026 (E01–E13), 20 pengecoh, lima PKB nyata, 14 kebijakan buatan, empat dokumen kontrafaktual, dan 16 perubahan tak terlihat. Peristiwa uji tidak pernah dijalankan alur sebelum *tag* `prareg`, diperiksa dari log panggilan. Representasi, *engine*, dan $\mathcal{K}^\star$ disusun dengan mengetahui peristiwa ini, dan akibatnya ditangani di Bagian VI-C.
- **Uji prospektif.** Regulasi yang terbit sesudah *tag* `prareg` dipantau. Sampai naskah ini ditulis belum ada peristiwa prospektif yang relevan.

C. Bias pandangan belakang

Representasi dan *engine* dikembangkan ketika semua perubahan dalam rentang uji sudah terbit, sehingga klaim *tanpa mengubah kode* untuk peristiwa itu lemah. Ada dua mitigasi. Pertama, riwayat *engine* dipublikasikan, dan 16 kemampuan *engine* dipetakan ke regulasi yang membutuhkannya. Kedua, 16 perubahan struktural sintetis (U01–U16) ditulis oleh agen terpisah yang hanya membaca taksonomi perubahan, lalu disegel dengan manifes *hash* sebelum representasi dibekukan. Setiap perubahan disertai teks dan contoh hitungan, seluruhnya 100 contoh. Perubahan itu dihitung berhasil (RA $= 1$) hanya bila Δ yang disusun mereproduksi seluruh contoh tanpa mengubah *engine*. Δ disusun dan diuji oleh agen pelaksana lain yang tidak ikut merancang representasi, dan hasilnya diperiksa ulang oleh agen peninjau ketiga. Perancang hanya menerima hasil.



Gambar 4. Rantai kepercayaan *ground truth*. Acuan memvalidasi emas, emas menghasilkan nilai harapan S^E, dan S^E menilai pembaruan dari LLM.

D. Rantai kepercayaan dan validasi instrumen

Semua angka RQ2–RQ4 bergantung pada $\mathcal{K}^\star$ dan S^E, sehingga keduanya divalidasi lebih dulu sebagai instrumen (E0). Gambar 4 menunjukkan rantainya.

1) **Acuan.** GT1 adalah contoh perhitungan resmi di lampiran regulasi, dibagi menjadi bagian pengembangan dan 14 berkas *holdout* yang hanya dibuka sekali. GT2 adalah kalkulator PPh 21 resmi DJP, dengan 20 kasus bulanan dan 15 kasus masa pajak terakhir. GT3 adalah 50 kasus bertingkat 2023–2026 yang dihitung langkah demi langkah dari teks regulasi dengan penghitung terpisah dari *engine*. GT5 adalah 21 contoh hitungan dari klausul lima PKB nyata. Implementasi pihak ketiga (GT4) dikumpulkan, tetapi tidak masuk validasi yang dilaporkan di sini.
2) **Adjudikasi selisih.** Setiap selisih diputuskan sebagai kesalahan KB, kesalahan acuan, atau ambiguitas hukum. Titik yang regulasinya diam atau ambigu diputuskan dalam 18 tafsir perhitungan (K1–K18) dan tafsir semantik berlaku surut.
3) **Uji *engine*.** *Engine* diuji terpisah dengan uji unit atas aritmetika, 12 uji resolusi konflik dengan pemenang hukum yang diketahui, uji mutasi SHACL dan G3, serta pemeriksaan kesetaraan dengan *engine* prototipe.
4) **Kecukupan S^E.** *Mutation score* terfokus-Δ per peristiwa dihitung atas mutan yang tidak setara, dengan ambang 0,80. Peristiwa di bawah ambang ditambah kasus terarah.
5) **Keandalan $\Delta^\star$.** Dua agen peninjau independen tanpa konteks penyusun mengodekan ulang $\Delta^\star$ secara buta dari teks dokumen, lalu membandingkannya dengan emas. Kesepakatan dilaporkan dengan Krippendorff's α.
6) **Syarat lulus E0.** Tidak ada selisih berstatus *KB salah* yang belum diselesaikan pada tahun uji, dan *mutation score* mencapai ambang.
7) **Protokol koreksi emas.** Bila keluaran LLM atau peninjauan menyingkap kesalahan emas, emas diperbaiki dengan *commit* bertanda, S^E dibangun ulang, semua kondisi dan semua jalan dinilai ulang, dan jumlah koreksi dilaporkan. Koreksi tidak boleh dibuat hanya pada peristiwa tempat usulan kalah.

E. Ruang uji

S^E berisi 2.398 kasus pegawai-tahun dari tiga kriteria (Tabel IV). Cakupan kombinatorial berbatasan mencakup seluruh kombinasi 2-arah yang sah menurut batasan antardimensi. Cakupan batas menguji setiap batas lapisan TER dan Pasal 17 di $b-1$, b, dan $b+1$. Batas Pasal 17 berada pada PKP sesudah pembulatan, sehingga kasusnya dibangkitkan terbalik dari PKP ke bruto. Sampel operasional diambil acak dari sel upah provinsi dan lapangan usaha BPS. Kasus kebijakan berjumlah 120–180 per kebijakan untuk 19 kebijakan, dan 21 kasus terarah ditambahkan dari analisis mutan dan koreksi emas.

Tabel IV
RUANG UJI S^E DAN CAKUPANNYA

Kriteria	**Kasus per tahun**	**Cakupan**
Batas lapisan Pasal 17	15	2023–2026
Batas lapisan TER (A, B, C)	321	2024–2026
Kombinasi 2-arah berbatasan	42–45	100%
Kombinasi 3-arah berbatasan	(kasus yang sama)	62–64%
Sampel operasional acak (BPS)	300	2023–2026
Jumlah kasus regulasi	2.398	
Kasus kebijakan	19 kebijakan $\times$ 120–180	

F. Korpus

1) Peristiwa perubahan nyata: Tabel V memuat ke-13 peristiwa uji, termasuk empat surat batas upah Jaminan Pensiun tahunan, karena iuran pensiun pegawai adalah pengurang PPh 21. Satu dokumen semula digolongkan pengecoh administrasi, yaitu PER-11/PJ/2025. Saat spesifikasi disusun ternyata dokumen itu mengubah pembulatan PPh 21 sejak Masa Januari 2025, sehingga dipindah menjadi peristiwa uji E13. Rantai emas utama berisi 37 pembaruan dengan 282 rekaman, ditambah 27 pembaruan sisi untuk regulasi fiktif dan kebijakan.

2) Dokumen pengecoh: Korpus memuat 20 pengecoh, yaitu regulasi yang menyebut PPh 21 atau iuran tetapi tidak mengubah perhitungan pegawai tetap. Contohnya ketentuan administrasi Coretax, DTP untuk peserta magang, dan rekomposisi iuran JKK untuk JKP yang tidak mengubah bruto (PP 49/2023, P01). Jawaban yang benar untuk pengecoh adalah pembaruan kosong.

3) Dokumen kontrafaktual: Empat dokumen kontrafaktual dibuat dengan mengubah nilai atau ambang di dokumen nyata secara konsisten, dan $\Delta^\star$-nya diturunkan secara terprogram. Varian kontrafaktual dihitung satu kelompok dengan dokumen sumbernya dan menambah presisi, bukan sampel independen.

4) Perubahan tak terlihat: Ke-16 perubahan mencakup jenis T1–T10, misalnya kategori TER keempat (U03), iuran Tapera sebagai pengurang baru (U04), tunjangan internet berplafon (U05), fasilitas DTP baru dengan syarat usia (U06), status PTKP efektif baru (U08), dasar TER dibulatkan ke ribuan (U11), dan dua perubahan lapisan perusahaan (U14, U15). Semua dokumen perubahan bertanggal sesudah 25 Februari 2026, sehingga basisnya selalu rantai emas lengkap.

5) Kebijakan perusahaan: Lima PKB nyata yang terbuka untuk umum menjadi strata kebijakan uji. Empat belas kebijakan buatan melengkapi jenis konflik yang tidak muncul di PKB nyata, termasuk tiga kontrol negatif tanpa konflik. Kedua

Tabel V
KORPUS PERISTIWA PERUBAHAN DAN HASIL E2 USULAN (B BENAR, S SALAH, A *abstain*)

No.	Dokumen	Berlaku	Jenis	$\lvert\Delta^\star\rvert$	E2
E01	Surat BPJS TK, batas upah JP 2023	2023-03	T1	1	B
E02	PMK 66/2023 (natura)	2023-07	T3	15	S
E03	PP 58/2023 (TER)	2024-01	T2, T7; S4, S6	7	B
E04	PMK 168/2023 (juklak TER)	2024-01	T7, T3; S4	14	A
E05	Surat BPJS TK, batas upah JP 2024	2024-03	T1	1	B
E06	PMK 10/2025 (DTP padat karya)	2025-01	T4; S1–S3	15	A
E07	PP 7/2025 (keringanan JKK)	2025-02	T1; S1–S3	2	S
E08	Surat BPJS TK, batas upah JP 2025	2025-03	T1	1	B
E13	PER-11/PJ/2025 (pembulatan)	2025-01	T9; S1	1	B
E09	PP 36/2025 (perpanjangan JKK)	2025-08	T6; S1–S3, S5	2	B
E10	PMK 72/2025 (DTP pariwisata)	2025-10	T5; S1–S3, S5	5	B
E11	PMK 105/2025 (DTP 2026)	2026-01	T4; S2, S3	11	S
E12	Surat BPJS TK, batas upah JP 2026	2026-03	T1	1	B
P01–P21	20 pengecoh (X1–X5)	–	tidak relevan	0	1 S
PKB	5 PKB nyata (WIKA, Centex, AVCO, Taekwang, Sansan)	–	T10	14–35	5 A
SP	14 kebijakan buatan	–	T10	1–7	5 B, 6 S, 3 A
CF	4 kontrafaktual (dari E01, E02, E06, E11)	–	T1, T3, T4	–	1 B, 1 S, 2 A
U	16 perubahan tak terlihat	–	T1–T10	–	–
D, FR	13 pengembangan, 5 fiktif	2013–2022	T1–T9	0–20	–

kelompok dilaporkan terpisah. Setiap dokumen kebijakan juga menjadi masukan akuisisi (E2), dengan $\Delta^\star$ yang disusun dan diperiksa dengan cara yang sama seperti dokumen regulasi.

G. Mode evaluasi dan hasil per dokumen

- **Mode terisolasi (RQ2).** $\hat{\Delta}_n$ diterapkan pada $\mathcal{K}^\star_{n-1}$ dan dinilai pada S^E_n.
- **Mode berantai (RQ3).** $\hat{\Delta}_n$ diterapkan pada $\mathcal{K}^{\text{sis}}_{n-1}$, yaitu hasil pembaruan sistem sendiri. Rantai dimulai dari $\mathcal{K}^\star_0$ (rekaman sampai 2022) dan memakai 150 kasus S^E per tahun. Ada dua cara memperoleh $\hat{\Delta}_n$. Pada rantai *transplantasi*, $\hat{\Delta}_n$ adalah hasil E2 terisolasi yang dipindah ke $\mathcal{K}^{\text{sis}}_{n-1}$, dengan penerapan longgar bila perlu. Pada rantai *pembangkitan ulang*, $\hat{\Delta}_n$ dibangkitkan dengan $\mathcal{K}^{\text{sis}}_{n-1}$ sebagai konteks, sesuai Definisi 8 sepenuhnya.
- Kedua mode berjalan tanpa peninjau manusia, sehingga kandidat terpilih langsung diterapkan. Hasilnya adalah batas bawah kinerja. Peneliti tidak bertindak sebagai peninjau karena mengetahui jawaban emas.
- Setiap dokumen relevan berakhir sebagai benar-diterapkan, salah-diterapkan (kesalahan senyap), atau *abstain*. Dokumen relevan yang dinilai tidak relevan dihitung salah-diterapkan.
- Pengecoh tidak masuk SER dan CAR. Relevansi diukur lewat laju positif palsu pada pengecoh dan laju pembaruan terlewat pada dokumen relevan.
- ***Abstain* pada mode berantai.** Pada varian *tetap*, KB lama dipertahankan. Pada varian *peninjau sempurna*, $\Delta^\star_n$ disisipkan.
- **Satu hasil per dokumen.** Analisis konfirmatori memakai jalan pertama pada setiap dokumen nyata. Jalan tambahan dan varian kontrafaktual dilaporkan sebagai strata terpisah.

Tabel VI
PEMBANDING DAN ABLASI

ID	Kondisi	RQ
Pembanding		
B1	Praktik saat ini: riwayat *commit* kalkulator PPh 21 sumber terbuka di sekitar pergantian ke TER	motivasi
B2	LLM menghitung PPh 21 langsung dari 26 dokumen yang berlaku pada 100 kasus operasional 2025	motivasi
B3	Kandidat pertama yang lolos G1–G2, tanpa perbaikan (*pass@1*)	RQ2
B4	Suara terbanyak menurut perilaku atas m kandidat awal, tanpa gerbang	RQ2
B5	Analisis dampak: (i) tandai semua kebijakan yang menyentuh fakta di penutup hilir F_Δ; (ii) pemindaian teks ekspresi tanpa graf	RQ4
Ablasi (model utama)		
AB1	Formalisasi dari nol pada keadaan hukum 2023 dan 2024: basis hanya kosakata fakta, masukan seluruh dokumen yang berlaku	RQ2, RQ3
AB2	Tanpa konteks *knowledge base*	RQ2
AB3	Tanpa G5, tanpa G4, atau tanpa putaran perbaikan	RQ2
AB4	Pemilihan pertama lolos, konsensus, atau seleksi sempurna	RQ2
AB5	Validasi skema biasa dibanding *shape* SHACL	RQ2

H. Pembanding dan ablasi

Tabel VI merangkum kondisi pembanding. B3, B4, AB3, dan AB4 dihitung dari kandidat dan log gerbang yang sama dengan usulan, tanpa panggilan LLM baru. B4 memakai m kandidat awal, lebih sedikit daripada usulan yang juga memakai putaran perbaikan.

I. Hipotesis dan metrik utama

Tabel VII memuat hipotesis, metrik utama, dan ambangnya. Setiap ambang ditetapkan pada atau di atas batas terbaik yang dapat dicapai jumlah sampel yang direncanakan. Contohnya, dengan 18 dokumen tanpa kesalahan, batas atas eksak SER sebesar 0,153, sehingga $\theta_2 = 0{,}25$ masih dapat dicapai dengan satu kesalahan (batas atas 0,238).

1) Definisi metrik utama:

- **RA (RQ1).** Proporsi perubahan yang dapat dinyatakan sebagai Δ yang mereproduksi seluruh contoh tanpa mengubah *engine*. Untuk peristiwa nyata dan kebijakan, RA dilaporkan sebagai bukti konstruktif $\Delta^\star$ beserta kecocokannya dengan acuan. Hanya perubahan tak terlihat yang menguji H1.
- **SER dan CAR (RQ2).** Dihitung atas himpunan D yang berisi 13 regulasi dan 5 PKB nyata, satu hasil per dokumen. $\text{SER} = \frac{1}{|D|}\sum_d \mathbf{1}[\text{salah-diterapkan}]$, $\text{CAR} = \frac{1}{|D|}\sum_d \mathbf{1}[\text{benar-diterapkan}]$, dan $\text{ABS} = 1 - \text{SER} - \text{CAR}$. SER mengukur keamanan dan CAR mengukur kegunaan. Keduanya dilaporkan bersama, karena sistem yang selalu *abstain* punya SER nol tetapi tidak berguna. Dari keduanya diturunkan cakupan CAR + SER dan risiko selektif SER/(CAR + SER) [39].
- **OAR (RQ3).** Proporsi peristiwa yang tidak memperkenalkan kesalahan baru dalam mode berantai. A2, A3$_t$, dan A4 dinilai pada $S^E_{\le n}$, gabungan kasus semua keadaan sampai peristiwa n, di luar observasi H_n yang sudah salah sebelum peristiwa itu. Tanpa pengecualian H_n, satu kesalahan lama terhitung ulang di setiap peristiwa berikutnya.
- **Kesalahan terpicu (RQ3).** $I_n = E^{\text{ber}}_n \setminus (E^{\text{iso}}_n \cup H_n)$, yaitu tupel yang salah pada mode berantai tetapi tidak salah pada mode terisolasi dan belum salah sebelumnya. Komponen mekanis diperoleh dengan memindahkan $\hat{\Delta}_n$

Tabel VII
KETERLACAKAN KONTRIBUSI, RQ, HIPOTESIS, DAN METRIK UTAMA

RQ	Hipotesis	Metrik utama	Analisis	Eksperimen
–	Invarian A1 dan A3$_\omega$ tanpa pelanggaran	jumlah pelanggaran	pemeriksaan	semua
RQ1 (K1)	H1: batas bawah satu sisi 95% RA perubahan tak terlihat $\geq \theta_1 = 0{,}70$	RA, proporsi perubahan yang dapat dinyatakan tanpa mengubah *engine*	Clopper–Pearson	E1
RQ2 (K2)	H2a: batas atas satu sisi 95% SER usulan $\leq \theta_2 = 0{,}25$. H2b: CAR usulan lebih tinggi daripada B3 dan B4, dan SER usulan tidak lebih buruk dengan margin $\delta_S = 0{,}10$	SER dan CAR atas 18 dokumen nyata	Clopper–Pearson; McNemar eksak satu sisi; selisih berpasangan dengan CI Newcombe; Holm	E2
RQ3 (K3)	H3a: batas bawah satu sisi 95% OAR $\geq \theta_3 = 0{,}75$. H3b: kesalahan terpicu tidak melebihi batas derau	OAR atas 33 peristiwa; kesalahan terpicu I	Clopper–Pearson; deskriptif terhadap batas derau	E3
RQ4 (K1)	H4a: batas bawah CI 95% *recall* $\geq \theta_4 = 0{,}70$. H4b: F_2 detektor lebih tinggi daripada B5(i) dan B5(ii)	*Recall* dan F_2 atas pasangan kebijakan dan peristiwa	*bootstrap* klaster per peristiwa; Holm	E4

terisolasi ke $\mathcal{K}^{\text{sis}}_{n-1}$. Komponen kontekstual diperoleh dari pembangkitan ulang. Batas derau diperkirakan dari selisih dua jalan terisolasi yang independen.

- ***Recall* dan F_2 (RQ4).** Dihitung atas pasangan kebijakan dan peristiwa, dengan $F_2 = 5PR/(4P+R)$. *Recall* diutamakan karena kebijakan terdampak yang terlewat lebih berbahaya daripada peringatan palsu. Pembanding *tandai semuanya* menghasilkan $F_2 = 5\pi/(4\pi+1)$ untuk prevalensi π.

2) Metrik diagnostik: Metrik diagnostik bersifat eksploratori dan tidak menguji hipotesis. Untuk instrumen, metriknya adalah selisih terhadap acuan menurut adjudikasi dan *mutation score*. Untuk RQ1, akurasi resolusi konflik dan kelengkapan jejak. Untuk RQ2, *pass@1*, *pass@m*, dan *1@m* pada kandidat sebelum perbaikan, dengan $\text{pass@}j = 1 - \binom{m-c}{j} / \binom{m}{j}$, efisiensi pemilihan $\eta = (1@m - \text{pass@}1)/(\text{pass@}m - \text{pass@}1)$ [38], laju hafalan pada kontrafaktual, kontaminasi, laju positif palsu relevansi, ketepatan kutipan, dan biaya. Untuk RQ3, persistensi kesalahan dan jumlah tupel salah di akhir rangkaian. Untuk RQ4, presisi dan Cohen's κ antara label eksekusi dan label manual.

J. Analisis statistik

Proporsi dilaporkan dengan CI eksak Clopper–Pearson. Perbandingan biner berpasangan antarkondisi memakai selisih risiko dengan CI Newcombe dan uji McNemar eksak satu sisi. Non-inferioritas SER diterima bila batas atas CI selisih SER berpasangan kurang dari δ_S. Proporsi berklaster pada RQ4 memakai *bootstrap* klaster per peristiwa. Keluarga Holm didefinisikan per RQ: RQ2 berisi CAR terhadap B3, CAR terhadap B4, dan dua uji non-inferioritas, sedangkan RQ4 berisi selisih F_2 terhadap B5(i) dan B5(ii). Unit analisisnya adalah dokumen sumber nyata untuk RQ2 dan peristiwa untuk RQ3 dan RQ4. Jalan LLM, kandidat, dan varian kontrafaktual bersarang di dalam dokumen sumbernya. RQ3 bersyarat pada satu rangkaian nyata dengan $R = 1$, sehingga hasilnya dibaca secara deskriptif. Simulasi daya dengan *pass@1* kalibrasi menunjukkan bahwa dengan $N = 18$ dan $\alpha = 0{,}025$ sesudah Holm, uji McNemar baru mencapai daya 80% pada selisih CAR sekitar 0,45. H2b karena itu kurang daya untuk selisih yang realistis, dan kegagalan menolak tidak dibaca sebagai bukti kesetaraan.

K. Prosedur eksperimen

- **E0, validasi instrumen.** Prasyarat semua eksperimen lain (Bagian VI-D).
- **E1, adaptivitas representasi (RQ1).** Perubahan tak terlihat, peristiwa nyata, kebijakan, akurasi resolusi konflik, dan pemetaan riwayat *engine*.
- **E2, akuisisi terisolasi (RQ2).** 13 regulasi uji dengan $m = 3$ dan 5 PKB dengan $m = 2$, satu putaran perbaikan, *seed* urutan kandidat 20261027. Pengecoh dijalankan dengan $m = 1$ bila dinilai relevan. Kontrafaktual dan kebijakan buatan dengan $m = 2$. Model kedua untuk usulan dan B3 dengan m yang sama.
- **E3, *regulation replay* (RQ3).** 33 peristiwa (13 uji dan 20 pengecoh), dua varian *abstain*, dua cara memperoleh $\hat{\Delta}_n$, dan $R = 1$.
- **E4, analisis dampak (RQ4).** 134 pasangan kebijakan dan peristiwa dengan masukan $\Delta^\star$, dibandingkan dengan B5.
- **E5, motivasi.** B1 dan B2.

L. Biaya dan kelayakan

Rancangan semula dengan $m = 5$ di semua dokumen nyata, seluruh ablasi, dan model kedua diperkirakan di atas USD 30, padahal anggaran awal USD 15. Karena itu m utama diturunkan menjadi 3 untuk regulasi dan 2 untuk PKB, dan E3 memakai $R = 1$. Biaya terukur per dokumen adalah USD 0,12–1,87 untuk regulasi (termahal E04 dengan tabel TER), 0,47–0,90 untuk PKB, dan 0,04–0,45 untuk pengecoh. Pengeluaran akhir sekitar USD 81,6 untuk Claude dan USD 8,1 untuk OpenAI. Batch API tidak dapat dipakai, karena tidak satu pun permintaan diproses dalam 20–50 menit.

M. Kolaborator dan rencana cadangan

Penelitian ini dikerjakan peneliti tunggal. Peran yang dalam rancangan semula diisi kolaborator manusia diisi agen AI independen, yaitu agen yang terpisah dari penyusun dan tidak membawa konteks penyusunan: peninjau spesifikasi, pembaca kedua $\Delta^\star$, penulis perubahan tak terlihat, pelaksana dan peninjau E1, pengadjudikasi kebijakan buatan, dan pelabel ketepatan kutipan. Tidak ada pakar *payroll* atau praktisi pajak manusia yang memvalidasi emas maupun bahan pakar. Konsekuensinya dibahas di Bagian VIII-D.

N. Reproduksibilitas

Versi model dan tanggal akses dicatat. Seluruh *prompt*, keluaran LLM, biaya, dan hasil gerbang diarsipkan per jalan, dan teks dokumen dikunci dengan SHA-256. Kecuali teks PKB, yang tidak dipublikasikan ulang, semua analisis dapat diulang dari arsip tanpa memanggil LLM.

VII. Hasil

Tabel VIII merangkum putusan semua hipotesis. Subbagian berikut melaporkan validasi instrumen lebih dulu, lalu setiap RQ.

A. Validasi instrumen

Acuan pengembangan. KB emas cocok dengan GT3 pada 50/50 kasus dan 2.107/2.107 observasi. Pada GT1 pengembangan, 22/26 kasus cocok, dan 14 observasi selisih di empat kasus semuanya ralat contoh resmi yang sudah tercatat. Pada GT2, 15/20 kasus bulanan cocok. Kelima selisih sebesar Rp1 karena kalkulator DJP membuang pecahan, sedangkan PER-11/PJ/2025 Pasal 129 mewajibkan pembulatan ke rupiah terdekat. Untuk masa pajak terakhir, 90/90 baris cocok. Pada GT5, 67/79 observasi cocok, dan ke-12 selisih dijelaskan.

GT1 *holdout*. Dari 14 berkas, satu tidak punya transkripsi kanonik dan tiga di luar model kasus, sehingga 10 dibandingkan. Hasil awalnya 6/10 kasus dan 221/235 observasi. Adjudikasi menemukan dua kesalahan emas. Pertama, kriteria DTP PMK 10/2025 seharusnya memakai penghasilan tetap menurut kontrak, bukan yang dibayar sesudah sanksi. Kedua, aturan latar 2016 belum menangani pegawai pensiun yang bulan kerjanya sudah diketahui. Satu selisih lain berasal dari pengonversi acuan. Sesudah koreksi, hasilnya 8/10 kasus dan 232/235 observasi. Sisa selisih adalah pemetaan iuran pensiun (2 observasi, pajak tidak terpengaruh) dan pembulatan setengah rupiah (1 observasi).

Koreksi emas. Protokol koreksi emas dipakai tiga kali sesudah pembekuan, yaitu untuk kriteria DTP menurut kontrak, pegawai pensiun 2016, dan aturan metode pada empat kebijakan buatan (SP04, SP07, SP11, SP14). Satu alat ukur juga diperbaiki, yaitu penyelarasan kunci konflik pada penilai A4. Semua kondisi dinilai ulang sesudah setiap koreksi. Koreksi DTP tidak mengubah hasil usulan mana pun, dan koreksi 2016 tidak mengubah nilai harapan S^E.

Kecukupan S^E. Dari 290 mutan, S^E awal membunuh 157 (0,54 mentah), dan 116 kemungkinan setara. Skor atas mutan tidak setara 0,90 sebelum penambahan kasus terarah, dengan E06 (0,79) dan E11 (0,77) di bawah ambang. Sesudah 17 kasus terarah, skornya 1,00 pada semua peristiwa.

Keandalan $\Delta^\star$. Pada regulasi E01–E13 (73 unsur emas), pembaca kedua sepakat atas kehadiran unsur pada 82% satuan dan atas nilai pada 90%. Krippendorff's α untuk tanggal mulai berlaku unsur tambahan 0,79, dan untuk tanggal akhir 1,00. Pada kebijakan buatan, kesepakatan kehadiran 91%, nilai 100%, dan α kode konflik 0,73. Pembacaan kedua menghasilkan delapan koreksi emas regulasi. Ketepatan kutipan pada 28 unsur yang dilabeli agen independen adalah 23 mendukung dan 5 sebagian (0,82; CI 0,63–0,94), tanpa kutipan yang tidak mendukung.

Uji *engine* dan gerbang. Ke-12 uji resolusi konflik lolos. Semua 8.310 nilai keluaran dari 50 kasus GT3 punya jejak lengkap sampai kutipan sumber. SHACL menangkap 16/16 mutasi uji dan G3 menangkap 11/11. Semua $\Delta^\star$ pengembangan, uji, fiktif, dan kebijakan lolos G1–G5, sehingga laju penolakan keliru gerbang atas emas nol. Penyesuaian gerbang yang diperlukan untuk mencapainya dibuat atas emas, bukan atas keluaran LLM uji.

B. Adaptivitas representasi (RQ1)

Ke-16 perubahan tak terlihat dapat dinyatakan sebagai Δ tanpa mengubah *engine*. Seluruh 100 contoh dan 2.609 nilai tereproduksi persis, sehingga RA $= 16/16$ (CP 95% [0,794; 1,000], batas bawah satu sisi 0,829), dan H1 diterima. Kode *engine*, bahasa ekspresi, dan semantik rekaman sama dengan *tag* `engine-v1`, dan segel bahan tetap utuh sebelum dan sesudah pengujian. Lima belas perubahan berhasil pada percobaan pertama.

Hasil ini bergantung pada satu penyelarasan (Tabel IX). Contoh hitungan penulis perubahan membulatkan hasil TER dan premi ke bawah sebagai konvensi tertulis, sedangkan KB emas membulatkan ke rupiah terdekat sejak 2025 sesuai PER-11/PJ/2025. Pelaksana E1 karena itu menerapkan satu Δ konvensi sebelum setiap Δ perubahan. Bagian premi dari konvensi ini baru ditambahkan sesudah percobaan pertama U15 gagal karena selisih Rp1, sehingga varian konservatif tanpa bagian itu menghasilkan 15/16 (batas bawah 0,736), masih di atas θ_1. Tanpa Δ konvensi sama sekali, hanya 8/16 yang lolos (batas bawah 0,279). Semua selisih pada varian itu berasal dari pembulatan, paling besar Rp11 pada masa pajak terakhir. Peninjau independen mereproduksi ketiga angka dan tidak menemukan Δ yang meniru angka contoh.

Walaupun contoh lolos, E1 menyingkap batas representasi. Tidak ada aritmetika tanggal, sehingga usia dan hari kerja dihitung dari bagian tanggal yang dipecah di data kasus. Tidak ada pembentukan teks, sehingga status K/n ke TK/n dinyatakan lewat tabel. Lapis perusahaan tidak dapat mengganti fakta wajib, sesuai rancangan *lex superior*. Satu Δ hanya mengutip satu tanggal pencatatan, tidak ada operasi ringkas untuk memperpanjang masa berlaku, dan komponen penghasilan baru hanya diperingatkan bila belum dikenal.

Untuk perubahan nyata, semua peristiwa uji, pengembangan, dan fiktif dapat dinyatakan tanpa perubahan *engine*, dan semua $\Delta^\star$ lolos G1–G5. Bukti ini lemah karena bias pandangan belakang: kedua *engine* ditulis sesudah semua peristiwa uji terbit, dan 16 kemampuan *engine* dapat dipetakan ke regulasi pemicunya, misalnya tabel *bracket* berkunci kategori untuk PP 58/2023 dan relasi `overrides` untuk DTP pariwisata. Untuk kebijakan, sebagian klausul tidak diformalkan dan alasannya dicatat per PKB. Pada saat emas disusun, klausul WIKA yang diformalkan penuh, sebagian, dan tidak diformalkan berjumlah 25/2/16, Centex 20/2/12, AVCO 29/5/10, Taekwang 17/3/14, dan Sansan 12/1/11. Batas yang ditemukan antara lain penanggungan pajak sebagian terhadap aturan wajib *gross-up* penuh, iterasi per hari, dan ketentuan "paling sedikit sebesar ketentuan" yang terbaca sebagai konflik walaupun sah.

C. Akuisisi satu langkah (RQ2)

Tabel X melaporkan semua kondisi atas 18 dokumen nyata. Usulan salah-diterapkan pada 3/18 dokumen (SER 0,167; CI 0,036–0,414; batas atas satu sisi 0,377), sehingga H2a tidak diterima. CAR usulan 8/18 (0,444; CI 0,215–0,692), sama dengan B3 dan satu dokumen di bawah B4, sehingga H2b CAR tidak diterima. Non-inferioritas SER terpenuhi terhadap B3 (selisih $-0{,}222$, CI Newcombe $-0{,}428$ sampai 0,004), tetapi tidak terhadap B4 (selisih 0, CI $-0{,}153$ sampai 0,153).

Tabel VIII
HIPOTESIS DAN HASIL

Hipotesis	Hasil	Putusan
H1: RA perubahan tak terlihat $\geq 0{,}70$	16/16, batas bawah 0,829. Varian konservatif 15/16 (0,736); tanpa konvensi pembulatan contoh 8/16 (0,279)	diterima, bergantung pada konvensi pembulatan
H2a: batas atas SER $\leq 0{,}25$	SER 3/18, batas atas 0,377	tidak diterima
H2b: CAR usulan $>$ B3 dan B4	8/18 lawan 8/18 (B3) dan 9/18 (B4); McNemar $p = 0{,}75$ dan 1,0; Holm $p = 1$	tidak diterima
H2b: non-inferioritas SER ($\delta_S = 0{,}10$)	terhadap B3 selisih $-0{,}222$, batas atas 0,004; terhadap B4 selisih 0, batas atas 0,153	terpenuhi terhadap B3, tidak terhadap B4
H3a: OAR $\geq 0{,}75$	rantai transplantasi (analisis terdaftar, amandemen 1) 31/33, batas bawah 0,821; rantai pembangkitan ulang 23/33, batas bawah 0,540	diterima pada analisis terdaftar, tidak kokoh
H3b: kesalahan terpicu $\leq$ batas derau	29 tupel (E03, E09, E10, E11) lawan batas derau 0	tidak didukung
H4a: *recall* $\geq 0{,}70$	0,91, CI klaster 0,75–1,00	diterima
H4b: F_2 detektor $>$ B5(i) dan B5(ii)	$+0{,}193$ (CI 0,062–0,400) terhadap B5(ii); $-0{,}006$ (CI $-0{,}110$–0,058) terhadap B5(i)	tidak diterima

Tabel IX
VARIAN E1 PADA 16 PERUBAHAN TAK TERLIHAT

Varian	RA	CP 95%	Batas bawah	H1
Utama: Δ konvensi pembulatan PPh dan premi ke bawah	16/16	[0,794; 1,000]	0,829	diterima
Konservatif: tanpa bagian premi	15/16	[0,698; 0,998]	0,736	diterima
Tanpa Δ konvensi	8/16	[0,247; 0,753]	0,279	ditolak

Tabel X
KONDISI E2 ATAS 18 DOKUMEN NYATA (13 REGULASI DAN 5 PKB). CAKUPAN = CAR + SER; RISIKO SELEKTIF = SER/CAKUPAN

Kondisi	SER	CAR	ABS	Cakupan	Risiko sel.
Usulan	3/18	8/18	7/18	11/18	0,27
B3 (pertama lolos G1–G2)	7/18	8/18	3/18	15/18	0,47
B4 (mayoritas tanpa gerbang)	3/18	9/18	6/18	12/18	0,25
AB2 tanpa konteks KB	5/18	6/18	7/18	11/18	0,45
AB3 tanpa G5	3/18	9/18	6/18	12/18	0,25
AB3 tanpa G4	3/18	8/18	7/18	11/18	0,27
AB3 tanpa perbaikan	3/18	7/18	8/18	10/18	0,30
AB4 pertama lolos	8/18	8/18	2/18	16/18	0,50
AB4 seleksi sempurna (batas atas)	0/18	8/18	10/18	8/18	0
Sensitivitas $m = 5$	3/18	8/18	7/18	11/18	0,27
Model kedua, usulan	3/18	7/18	8/18	10/18	0,30
Model kedua, B3	7/18	6/18	5/18	13/18	0,54

Per lapisan dan per jenis. Pada 13 regulasi, usulan benar 8, salah 3, dan *abstain* 2. Pada perubahan parameter (T1), 4 dari 5 benar dan E07 salah. Pada jenis struktural (T2–T9), 4 dari 8 benar, 2 salah (E02, E11), dan 2 *abstain* (E04, E06). Kesalahan senyap usulan adalah E02 (nilai natura bingkisan dan perumahan pada bruto, 52 tupel), E07 (premi JKK keringanan untuk sebagian kelompok risiko, 42 tupel), dan E11 (natura kendaraan tidak masuk uji penghasilan tetap DTP, 2 tupel). E04 *abstain* karena tidak ada kandidat yang lolos, dan E06 karena tiga kandidat yang lolos berperilaku berbeda. Pada 5 PKB, usulan *abstain* pada kelima dokumen, juga bila kunci konflik diselaraskan. B3 salah-diterapkan pada 3 PKB. Tidak ada PKB yang benar pada kondisi mana pun.

Jalan kedua dan $m = 5$. Jalan terisolasi kedua pada 13 regulasi menghasilkan 8 benar, 2 salah, dan 3 *abstain*. E07 dan E11 salah di kedua jalan dengan jumlah tupel salah yang sama, sehingga kesalahan itu sistematis, bukan derau. Dengan $m = 5$, E02 berubah dari salah menjadi *abstain*, tetapi Taekwang berubah dari *abstain* menjadi salah.

Model kedua. Dengan `gpt-6.1-sol`, usulan pada regulasi benar 7, salah 2 (E06, E10), dan *abstain* 4. Pada PKB, satu salah (Sansan) dan empat *abstain*. Pola gerbang dan konsensus terhadap B3 sama dengan model utama, yaitu SER 3/18 lawan 7/18.

Diagnostik. Pada regulasi, *pass@1* 0,667, *pass@m* 0,692, dan *1@m* 0,615, sehingga efisiensi pemilihan $\eta \approx -2{,}0$. Nilai negatif berarti *1@m* lebih rendah daripada *pass@1*: konsensus tidak lebih baik daripada memilih satu kandidat acak, antara lain karena konsensus *abstain* pada dokumen yang punya kandidat benar, misalnya E04. Semua 18 dokumen nyata dinilai relevan, sehingga tidak ada pembaruan yang terlewat karena relevansi. Pada 20 pengecoh, 7 dinilai relevan (positif palsu 0,35; CI 0,15–0,59), dan hanya satu yang salah-diterapkan, yaitu P01 (PP 49/2023). Pada P01 LLM menurunkan premi JKK di bruto karena membaca rekomposisi iuran JKP sebagai pengurangan iuran. Enam lainnya menghasilkan pembaruan yang tidak mengubah hasil S^E mana pun. Pada empat kontrafaktual, hasilnya 1 benar, 1 salah (CF-E11, 2 tupel), dan 2 *abstain*. Dari 6 kandidat yang membawa nilai kontrafaktual, tidak ada yang memakai nilai asli, sehingga laju hafalan 0/6. Pada 14 kebijakan buatan, usulan benar 5 (2 di antaranya tidak teruji pada S^E sesudah koreksi emas), salah 6, dan *abstain* 3. B3 salah 7 dan B4 salah 2. Semua peristiwa uji terbit sebelum *cutoff* kedua model, sehingga perbandingan sebelum dan sesudah *cutoff* tidak dapat dilakukan. Bukti tidak langsung terhadap hafalan datang dari kontrafaktual dan dari regulasi fiktif FR01, yang ketiga kandidatnya benar saat kalibrasi.

D. Adaptivitas operasional berantai (RQ3)

Tabel XI melaporkan kedua rantai. Pada rantai transplantasi, analisis yang ditetapkan sebagai uji H3a dalam amandemen 1, 31 dari 33 peristiwa tidak menambah kesalahan baru (OAR 0,939; batas bawah satu sisi 0,821), sehingga H3a diterima. Hasil interim pada 24 peristiwa adalah 22/24 (batas bawah 0,760). Kesalahan baru hanya muncul pada E02 (15 tupel) dan P01 (264 tupel). Kesalahan P01 bertahan sampai akhir, sehingga 579 dari 600 tupel pada peristiwa terakhir salah. Varian peninjau sempurna memberi hasil yang persis sama, karena E04 dan E06 hanya menyentuh tupel yang sudah salah.

Tabel XI
HASIL E3 PADA 33 PERISTIWA (13 UJI DAN 20 PENGECOH), VARIAN *abstain* TETAP

	Transplantasi (terdaftar)	**Pembangkitan ulang**
OAR	31/33 = 0,939	23/33 = 0,697
CI 95%	[0,798; 0,993]	[0,513; 0,844]
Batas bawah satu sisi	0,821	0,540
OAR regulasi	12/13	5/13
Kesalahan baru (tupel)	E02 (15), P01 (264)	E02 (15), E03 (1), E04 (8), E06 (19), E07 (4), P06 (4), E09 (2), E10 (2), E11 (24), P15 (24)
Tupel salah akhir	579 dari 600	93 dari 600
Kesalahan terpicu	tidak diukur	29 tupel, batas derau 0

Rantai transplantasi tidak kokoh. Pada rantai pembangkitan ulang, yang mengikuti Definisi 8 sepenuhnya, OAR turun menjadi 23/33 (batas bawah 0,540), di bawah θ_3. Sebabnya, pada rantai transplantasi kesalahan P01 membuat H_n besar, sehingga kesalahan sesudahnya tersembunyi di balik tupel yang sudah salah. Pada rantai pembangkitan ulang P01 tidak salah, dan *abstain* pada E04, E06, E10, dan E11 tampak sebagai kesalahan baru karena KB tidak diperbarui. Kesalahan akhir rantai pembangkitan ulang jauh lebih kecil (93 tupel), justru karena pengecoh paling merusak tidak diterapkan. Kesalahan terpicu, yaitu kesalahan yang muncul di mode berantai tetapi tidak di mode terisolasi, berjumlah 29 tupel pada E03, E09, E10, dan E11. Batas derau dari dua jalan terisolasi bernilai 0, karena keduanya identik pada sampel rantai. H3b karena itu tidak didukung.

B1. Dari dua kalkulator sumber terbuka yang sudah ada sebelum PP 58/2023, satu memasukkan TER 26 hari sesudah peraturan terbit (15 berkas, 163 baris, 7 fungsi, disusul 2 *commit* perbaikan) dan satu lagi 915 hari sesudahnya (3 berkas, 504 baris, 8 fungsi). Tiga repositori lain lahir sudah dengan TER (340–1.411 baris). Pada sisi KB, peristiwa yang sama adalah $\Delta^\star$ E03 dengan 7 unsur baru dan E04 dengan 1 unsur baru dan 13 unsur diubah, tanpa perubahan *engine*. Perbandingan ini deskriptif.

B2. LLM yang menghitung langsung dari 26 dokumen yang berlaku tepat pada 76/100 kasus operasional 2025 (CI 0,66–0,84) dan dalam Rp1 pada 97/100, dengan biaya USD 0,068 per kasus per perhitungan, tanpa jejak, dan tidak deterministik.

E. Analisis dampak lintas lapis (RQ4)

Dari 134 pasangan kebijakan dan peristiwa, 33 positif (prevalensi 0,25). Pola labelnya abc 16, a 7, ac 7, dan b 3. Tabel XII melaporkan semua pendeteksi. *Recall* detektor beku 0,91 dengan CI klaster 0,75–1,00, sehingga H4a diterima. F_2 detektor lebih tinggi daripada pemindaian teks datar B5(ii) ($+0{,}193$, CI 0,062–0,400), tetapi tidak lebih tinggi daripada B5(i) ($-0{,}006$, CI $-0{,}110$ sampai 0,058), sehingga H4b tidak diterima.

Detektor melewatkan tiga pasangan, yaitu SP01×E05, SP01×E08, dan SP03×E10. Contohnya SP01 dan peristiwa batas upah JP E05. Kebijakan SP01 *menghasilkan* fakta yang termasuk F_Δ, dan fakta itu berubah lewat parameter batas upah di hulu. Detektor beku hanya mencari aturan kebijakan yang

Tabel XII
PENDETEKSI DAMPAK LINTAS LAPIS PADA 134 PASANGAN (33 POSITIF)

Pendeteksi	**Presisi**	***Recall*** **(CI)**	F_2 **(CI)**
Detektor statis (beku)	0,71	0,91 (0,75–1,00)	0,862 (0,683–0,951)
Detektor v2 (eksploratori)	0,57	1,00	0,868 (0,745–0,939)
B5(i) tandai yang menyentuh F_Δ	0,57	1,00	0,868 (0,745–0,939)
B5(ii) pindai teks datar	0,84	0,64 (0,31–0,82)	0,669 (0,341–0,833)
Tandai semuanya (rujukan)	0,25	1,00	0,620

membaca fakta yang berubah, sehingga pasangan ini terlewat. Detektor v2 menambah jenis (d), yaitu aturan kebijakan yang menghasilkan fakta di F_Δ. Jenis ini menutup celah *recall*, tetapi detektor v2 lalu menandai pasangan yang persis sama dengan B5(i) dan kehilangan keunggulan presisinya. Kesepakatan label eksekusi dengan label konflik manual hampir nol ($\kappa = -0{,}018$). Penyebabnya, kedua label memakai pengertian dampak yang berbeda: label manual menandai kebijakan yang membaca fakta yang berubah, sedangkan label eksekusi menuntut nilai yang benar-benar berubah.

F. Ablasi

Konteks KB berperan besar. Tanpa konteks (AB2), SER naik dari 3/18 menjadi 5/18 dan CAR turun dari 8/18 menjadi 6/18. Formalisasi dari nol (AB1) pada keadaan 2023 dan 2024 gagal total. Tidak ada kandidat yang lolos gerbang, dan dari 6 kandidat hanya satu yang dapat diterapkan, lalu salah pada 150/150 kasus. Keadaan 2025 tidak dijalankan untuk menghemat kredit. Di antara gerbang, G5 dan G4 tidak mengubah SER pada dokumen nyata. Tanpa G5, CAR naik satu dokumen dan *abstain* turun satu, sehingga G5 menolak satu pembaruan yang ternyata benar. Tanpa putaran perbaikan, CAR turun satu dokumen. Yang menekan SER adalah kombinasi gerbang dan konsensus: pemilihan pertama lolos (AB4) memberi SER 8/18, sedangkan seleksi sempurna atas kandidat yang sama memberi SER 0/18 dengan CAR tetap 8/18. Untuk AB5, SHACL menolak 7 dari 319 draf yang lolos skema JSON, yaitu 6 draf Taekwang dengan tanggal akhir yang bukan hari terakhir bulan dan 1 draf dengan nama fakta tidak sah.

VIII. PEMBAHASAN

A. Jawaban atas pertanyaan penelitian

RQ1. Representasi temporal dua lapis menyatakan semua perubahan tak terlihat tanpa mengubah *engine*, dengan batas bawah 0,829. Kesimpulan ini bergantung pada penyelarasan konvensi pembulatan contoh. Tanpa penyelarasan itu, separuh perubahan berselisih paling banyak Rp11. Selisih itu mencerminkan perbedaan asumsi dasar, bukan kegagalan menyatakan perubahan. Batas yang ditemukan, terutama tidak adanya aritmetika tanggal, menunjukkan fungsi yang perlu ditambahkan ke bahasa ekspresi.

RQ2. Gerbang dan konsensus menekan pembaruan salah dibanding pemilihan pertama yang lolos (SER 3/18 lawan 7/18), dan pola ini sama pada model kedua. Penurunan itu dibayar dengan *abstain*, bukan dengan kenaikan pembaruan benar, dan

SER usulan tidak lebih rendah daripada suara terbanyak tanpa gerbang. Batas atas SER 0,377 berarti, dengan keyakinan 95%, hingga lebih dari sepertiga dokumen dapat berakhir dengan pembaruan salah bila sistem berjalan tanpa peninjau. Seleksi sempurna menunjukkan ruang perbaikan: kandidat yang benar ada, tetapi aturan pemilihan belum menemukannya.

RQ3. Pada rangkaian nyata, rantai transplantasi menghasilkan 31 dari 33 peristiwa tanpa kesalahan baru. Angka ini tidak kokoh. Bila pembaruan dibangkitkan ulang dari basis sistem sendiri, OAR menjadi 23/33, dan kesalahan terpicu muncul di atas batas derau. Kesalahan memang merambat, dan *abstain* di mode berantai berubah menjadi kesalahan karena peristiwa berikutnya mewarisi KB yang tidak diperbarui. Ukuran berantai juga harus memisahkan efek *masking*. Pada rantai transplantasi, satu kesalahan besar menyembunyikan kesalahan berikutnya.

RQ4. Detektor statis menemukan 91% pasangan terdampak dengan presisi 0,71. Keunggulannya atas penandaan sederhana berbasis F_Δ tidak terbukti, dan celah *recall*-nya hanya dapat ditutup dengan mengorbankan presisi. Nilai tambah graf pada RQ4 dalam data ini terbatas pada presisi.

B. Analisis kesalahan LLM

Taksonomi kesalahan LLM (L1–L12) ditetapkan sebelum ada keluaran. Pemetaan berikut kualitatif, dari uraian kesalahan pada log. Kesalahan senyap yang dominan adalah kondisi atau cakupan salah dan pengecualian terlewat. E07 menerapkan keringanan premi JKK pada sebagian kelompok risiko dengan cakupan yang salah. E11 melewatkan natura kendaraan dalam uji penghasilan tetap DTP. E02 salah memperlakukan natura bingkisan dan perumahan pada bruto. Gerbang tidak dirancang menangkap jenis ini. G2 memeriksa bahwa nilai dan tanggal berpijak pada kutipan, dan G5 memeriksa bahwa unsur berefek, tetapi tidak ada gerbang yang memeriksa kelengkapan. Kesalahan E07 dan E11 muncul di dua jalan dengan kandidat yang sepakat, sehingga konsensus tidak dapat menangkapnya. Gejala yang sama sudah terlihat saat kalibrasi pada D05 dan PKB Koja. Perubahan pada pengecoh yang menimbulkan kesalahan (L9) hanya terjadi sekali di mode terisolasi, tetapi P01 menjadi sumber kerusakan terbesar di rantai transplantasi, dan pada rantai pembangkitan ulang P06 dan P15 menambah kesalahan baru. Penilaian relevansi karena itu adalah titik rawan. Kutipan karangan (L8) dan nilai hafalan (L10) tidak teramati pada sampel yang diperiksa. PKB adalah titik lemah utama. Tidak ada PKB yang benar pada kondisi mana pun, dan usulan aman hanya karena *abstain*.

C. Implikasi

Bagi pengembang sistem *payroll*, memisahkan aturan dari kode dan menyimpannya dengan dua sumbu waktu memungkinkan perubahan seperti TER dinyatakan sebagai data, dengan hasil masa lampau terjaga dan jejak sampai pasal. LLM berguna sebagai penyusun draf pembaruan, bukan sebagai penghitung. B2 cukup akurat untuk kasus sederhana, tetapi biayanya berulang per perhitungan, tidak deterministik, dan tanpa jejak. Akuisisi inkremental dengan konteks KB jauh lebih mudah daripada formalisasi dari nol. Namun, dengan SER setinggi ini, peninjau manusia tetap diperlukan, dan peninjauan itu harus didukung mekanisme lain seperti laporan dampak dan perbedaan hasil pada kasus uji, bukan sekadar persetujuan [51], [52]. Bagi formalisasi peraturan yang sering berubah, hasil RQ3 menunjukkan bahwa evaluasi satu langkah tidak cukup. Kinerja berantai harus diukur dengan memisahkan kesalahan bawaan, baru, dan terpicu. Terakhir, *holdout* dan keluaran LLM menemukan kesalahan emas yang lolos semua acuan pengembangan, yaitu kriteria DTP menurut kontrak, pegawai pensiun 2016, dan aturan metode kebijakan buatan. Ini bukti nilai protokol koreksi emas.

D. Ancaman terhadap validitas

- **Validitas internal.** *Ground truth*, *engine*, dan tafsir disusun pihak yang sama. Emas regulasi, emas kebijakan buatan, perubahan tak terlihat, dan bahan pakar lainnya hanya ditinjau agen AI independen, bukan pakar *payroll* atau praktisi pajak manusia. Penyusun emas dan model yang diuji juga berasal dari keluarga model yang sama. Mitigasinya adalah acuan yang tidak disusun penyusun emas (GT1 resmi dan GT2 kalkulator DJP), *holdout* sekali pakai, uji *engine* terpisah, dan pembacaan kedua secara buta. Kesepakatan pembaca kedua dibaca sebagai kesepakatan di bawah basis dan tafsir yang sama. Pelabel kutipan sempat membuka spesifikasi tafsir proyek, sehingga dua label mungkin terpengaruh.
- **Analisis yang tidak buta.** Amandemen 1 ditulis sesudah hasil awal terlihat. Status setiap jalan dinyatakan, dan H3a dilaporkan pada dua rantai. Pra-registrasi dikunci dengan *tag* git, yang lebih lemah daripada registrasi pihak ketiga. Pemeriksaan awal pemilihan segmen sempat dilakukan pada beberapa dokumen uji sebelum disadari. Perubahan yang dibuat bersifat umum, tetapi tetap merupakan kebocoran desain kecil. Penyelarasan kunci konflik pada penilai tidak ada di konsensus alur beku, dan kondisi sensitivitas menunjukkan hasilnya sama.
- **Bias pandangan belakang.** Representasi dirancang sesudah perubahan nyata diketahui. Mitigasinya adalah perubahan tak terlihat yang disegel. Perubahan itu ditulis agen, bukan pakar manusia, dan hasilnya bergantung pada konvensi pembulatan contoh. Belum ada peristiwa prospektif.
- **Validitas konstruk.** Kecocokan dengan acuan tidak sama dengan kesesuaian hukum [28]. Nilai yang dinilai untuk regulasi berlaku surut adalah nilai seharusnya, bukan mekanisme penyelesaiannya.
- **Validitas eksternal.** Satu yurisdiksi, satu jenis pajak, satu rangkaian perubahan, dan lima PKB.
- **Validitas kesimpulan.** $N = 18$ memberi daya rendah untuk H2b (efek minimum sekitar 0,45). LLM tidak deterministik dan E3 memakai $R = 1$. m utama hanya 3 dan 2 karena anggaran, dan AB1 hanya dua keadaan hukum.
- **Kontaminasi data.** Semua peristiwa uji terbit sebelum *cutoff* kedua model, sehingga kontaminasi tidak dapat diuji dengan pemisahan *cutoff*. Buktinya hanya tidak langsung, yaitu kontrafaktual tanpa hafalan dan regulasi fiktif. Bahan tersegel disimpan di repositori publik, sehingga dapat masuk data latih model di masa depan.

E. Keterbatasan

Di luar lingkup penelitian ini adalah pegawai tidak tetap, PPh 26, hubungan antar-pemberi kerja, perhitungan lintas tahun, dan kewajiban prosedural. Jenis pencabutan tanpa pengganti (T8) tidak punya contoh nyata di rentang uji dan hanya diwakili perubahan tak terlihat dan data pengembangan. Beberapa metrik diagnostik dalam rancangan tidak dilaporkan di sini, yaitu upaya koreksi peninjau, *drift* dalam rupiah, rasio perambatan, matriks konfusi per gerbang, dan anomali KB per versi. Pembanding B5(iii), yaitu penilaian dampak oleh LLM, tidak dilaporkan. Model kedua bukan model *open-weight* seperti rencana awal, tetapi model penyedia lain, dan satu draf panjangnya bisa memakan 24 menit.

IX. Kesimpulan dan penelitian lanjutan

Penelitian ini menguji KBS PPh 21 dengan *knowledge base* bitemporal dua lapis dan akuisisi pengetahuan berbantuan LLM yang dijaga lima gerbang dan konsensus perilaku. Representasinya terbukti cukup ekspresif. RA perubahan tak terlihat 16/16 (batas bawah 0,829), dengan catatan bahwa hasil ini bergantung pada konvensi pembulatan contoh. Akuisisi satu langkah aman terhadap pemilihan naif tetapi belum cukup aman untuk berjalan tanpa peninjau. SER usulan 3/18 (batas atas 0,377), CAR 8/18 (CI 0,215–0,692), dan keunggulannya atas pembanding hanya berupa SER yang lebih rendah daripada B3. Pada rangkaian nyata, kesalahan merambat. OAR 31/33 (batas bawah 0,821) pada rantai transplantasi turun menjadi 23/33 (batas bawah 0,540) bila pembaruan dibangkitkan ulang, dengan 29 tupel kesalahan terpicu di atas batas derau nol. Detektor dampak lintas lapis menemukan sebagian besar kebijakan terdampak (*recall* 0,91, CI 0,75–1,00), tetapi tidak lebih baik daripada penandaan sederhana.

Penelitian lanjutan diturunkan dari keterbatasan tersebut. Pertama, validasi emas dan bahan pakar oleh praktisi pajak manusia, serta registrasi pihak ketiga sebelum analisis berikutnya. Kedua, pengujian pada peristiwa prospektif yang terbit sesudah *cutoff* model. Ketiga, gerbang kelengkapan yang memeriksa pengecualian dan cakupan, karena jenis kesalahan inilah yang lolos. Keempat, aturan pemilihan yang lebih mendekati seleksi sempurna. Kelima, penilaian relevansi yang lebih ketat terhadap pengecoh sulit. Keenam, penanganan *abstain* pada mode berantai, misalnya antrean peninjauan yang menahan peristiwa berikutnya. Ketujuh, penambahan aritmetika tanggal ke bahasa ekspresi. Kedelapan, pengulangan E3 dengan $R > 1$.

Daftar Pustaka

[1] Republik Indonesia, "Peraturan Pemerintah Nomor 58 Tahun 2023 tentang Tarif Pemotongan Pajak Penghasilan Pasal 21 atas Penghasilan Sehubungan dengan Pekerjaan, Jasa, atau Kegiatan Wajib Pajak Orang Pribadi," https://peraturan.bpk.go.id/Download/332609/PP%20Nomor%2058%20Tahun%202023.pdf, 2023, diakses 1 Oktober 2026.

[2] Menteri Keuangan Republik Indonesia, "Peraturan Menteri Keuangan Nomor 168 Tahun 2023 tentang Petunjuk Pelaksanaan Pemotongan Pajak atas Penghasilan Sehubungan dengan Pekerjaan, Jasa, atau Kegiatan Orang Pribadi," https://peraturan.bpk.go.id/Download/346093/2023pmkeuangan168.pdf, 2023, diakses 1 Oktober 2026.

[3] E. N. Ramadhani, W. Wiranto, and M. K. Giffary, "Perancangan Sistem Perhitungan Pajak Penghasilan Berbasis Web dengan Metode Gross Up," *Riset dan E-Jurnal Manajemen Informatika Komputer (REMIK)*, vol. 6, no. 1, pp. 16–23, 2021, doi: 10.33395/remik.v6i1.11180.

[4] N. L. T. Yulistyawati, N. M. Estiyanti, and S. Lavianto, "Analisis dan Perancangan Sistem Informasi Penggajian Karyawan serta Perhitungan PPh Pasal 21 pada CV Seni Echo," *Jurnal Teknologi Informasi dan Komputer*, vol. 8, no. 4, pp. 306–317, 2022, doi: 10.36002/jutik.v8i4.2084.

[5] M. J. A. B. Kusuma, D. Armeliza, and T. E. Jaya, "Perancangan Sistem Terintegrasi untuk Otomatisasi Perhitungan PPh Pasal 21," *Jurnal Akuntansi, Perpajakan dan Auditing*, vol. 7, no. 1, pp. 85–96, 2026, doi: 10.21009/japa.0701.07.

[6] A. Mowbray, P. Chung, and G. Greenleaf, "Representing legislative Rules as Code: Reducing the problems of 'scaling up'," *Computer Law & Security Review*, vol. 48, p. 105772, 2023, doi: 10.1016/j.clsr.2022.105772.

[7] D. Merigoux, N. Chataing, and J. Protzenko, "Catala: a programming language for the law," *Proceedings of the ACM on Programming Languages*, vol. 5, no. ICFP, pp. 1–29, 2021, doi: 10.1145/3473582.

[8] P. Compton and B. H. Kang, *Ripple-Down Rules: The Alternative to Machine Learning*, 1st ed. Boca Raton: Chapman and Hall/CRC, 2021, doi: 10.1201/9781003126157.

[9] S. Janatian, H. Westermann, J. Tan, J. Savelka, and K. Benyekhlef, "From Text to Structure: Using Large Language Models to Support the Development of Legal Expert Systems," in *Legal Knowledge and Information Systems (JURIX 2023)*, ser. Frontiers in Artificial Intelligence and Applications, vol. 379. IOS Press, 2023, doi: 10.3233/faia230962.

[10] M. Makowski and J. Trabka, "Dynamic generation of Decision Model and Notation rules for tax regulations – case study from Swiss accounting offices," in *International Conference on Information Systems Development*. University of Gdansk, Department of Business Informatics & University of Belgrade, Faculty of Organizational Sciences, 2025, doi: 10.62036/isd.2025.98.

[11] A. Blair-Stanek, N. Holzenberger, and B. Van Durme, "Can GPT-3 Perform Statutory Reasoning?" in *Proceedings of the Nineteenth International Conference on Artificial Intelligence and Law*. ACM, 2023, pp. 22–31, doi: 10.1145/3594536.3595163.

[12] J. J. Nay, D. Karamardian, S. B. Lawsky, W. Tao, M. Bhat, R. Jain, A. T. Lee, J. H. Choi, and J. Kasai, "Large language models as tax attorneys: a case study in legal capabilities emergence," *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, vol. 382, no. 2270, p. 20230159, 2024, doi: 10.1098/rsta.2023.0159.

[13] M. Dahl, V. Magesh, M. Suzgun, and D. E. Ho, "Large Legal Fictions: Profiling Legal Hallucinations in Large Language Models," *Journal of Legal Analysis*, vol. 16, no. 1, pp. 64–93, 2024, doi: 10.1093/jla/laae003.

[14] A. Gupta, A. Rao, and G. Anumanchipalli, "Model Editing at Scale leads to Gradual and Catastrophic Forgetting," in *Findings of the Association for Computational Linguistics ACL 2024*. Association for Computational Linguistics, 2024, pp. 15 202–15 232, doi: 10.18653/v1/2024.findings-acl.902.

[15] Republik Indonesia, "Undang-Undang Nomor 7 Tahun 2021 tentang Harmonisasi Peraturan Perpajakan," https://peraturan.bpk.go.id/Download/178620/UU%20Nomor%207%20Tahun%202021.pdf, 2021, diakses 1 Oktober 2026.

[16] Menteri Keuangan Republik Indonesia, "Peraturan Menteri Keuangan Nomor 101/PMK.010/2016 tentang Penyesuaian Besarnya Penghasilan Tidak Kena Pajak," https://peraturan.bpk.go.id/Download/111866/PMK%20Nomor%20101%20Tahun%202016.pdf, 2016, diakses 1 Oktober 2026.

[17] Direktur Jenderal Pajak, "Peraturan Direktur Jenderal Pajak Nomor PER-16/PJ/2016 tentang Pedoman Teknis Tata Cara Pemotongan, Penyetoran dan Pelaporan Pajak Penghasilan Pasal 21 dan/atau Pajak Penghasilan Pasal 26 Sehubungan dengan Pekerjaan, Jasa, dan Kegiatan Orang Pribadi," 2016, salinan pindaian; diakses 1 Oktober 2026.

[18] Menteri Keuangan Republik Indonesia, "Peraturan Menteri Keuangan Nomor 10 Tahun 2025 tentang Pajak Penghasilan Pasal 21 atas Penghasilan Tertentu yang Ditanggung Pemerintah dalam rangka Stimulus Ekonomi Tahun Anggaran 2025," https://peraturan.bpk.go.id/Download/374407/2025pmkeuangan10.pdf, 2025, diakses 1 Oktober 2026.

[19] ——, "Peraturan Menteri Keuangan Nomor 72 Tahun 2025 tentang Perubahan atas Peraturan Menteri Keuangan Nomor 10 Tahun 2025," https://peraturan.bpk.go.id/Download/394197/72%20TH%202025.pdf, 2025, diakses 1 Oktober 2026.

[20] ——, "Peraturan Menteri Keuangan Nomor 105 Tahun 2025 tentang Pajak Penghasilan Pasal 21 atas Penghasilan Tertentu yang Ditanggung Pemerintah Tahun Anggaran 2026," https://peraturan.bpk.go.id/Download/404917/2025pmkeuangan105.pdf, 2025, diakses 1 Oktober 2026.

[21] L. Huttner and D. Merigoux, "Catala: Moving towards the future of legal expert systems," *Artificial Intelligence and Law*, 2022, doi: 10.1007/s10506-022-09328-5.

[22] D. Merigoux, R. Monat, and J. Protzenko, "A modern compiler for the French tax code," in *Proceedings of the 30th ACM SIGPLAN International Conference on Compiler Construction*. ACM, 2021, pp. 71–82, doi: 10.1145/3446804.3446850.

[23] R. Monat, A. Fromherz, and D. Merigoux, "Formalizing Date Arithmetic and Statically Detecting Ambiguities for the Law," in *Programming Languages and Systems (ESOP 2024)*, ser. Lecture Notes in Computer Science. Springer Nature Switzerland, 2024, pp. 421–450, doi: 10.1007/978-3-031-57267-8_16.

[24] P. Goutagny, A. Fromherz, and R. Monat, "CUTECat: Concolic Execution for Computational Law," in *Programming Languages and Systems (ESOP 2025)*, ser. Lecture Notes in Computer Science. Springer Nature Switzerland, 2025, pp. 31–61, doi: 10.1007/978-3-031-91121-7_2.

[25] A. Mowbray, P. Chung, and G. Greenleaf, "Explainable AI (XAI) in Rules as Code (RaC): The DataLex approach," *Computer Law & Security Review*, vol. 48, p. 105771, 2023, doi: 10.1016/j.clsr.2022.105771.

[26] R. Kowalski and A. Datoo, "Logical English meets legal English for swaps and derivatives," *Artificial Intelligence and Law*, vol. 30, no. 2, pp. 163–197, 2022, doi: 10.1007/s10506-021-09295-3.

[27] P. N. Meessen, "On Normative Arrows and Comparing Tax Automation Systems," in *Proceedings of the Nineteenth International Conference on Artificial Intelligence and Law*. ACM, 2023, pp. 432–436, doi: 10.1145/3594536.3595160.

[28] A. Witt, A. Huggins, G. Governatori, and J. Buckley, "Encoding legislation: a methodology for enhancing technical validation, legal alignment and interdisciplinarity," *Artificial Intelligence and Law*, vol. 32, no. 2, pp. 293–324, 2024, doi: 10.1007/s10506-023-09350-1.

[29] S. Dumancic, W. Meert, S. Goethals, T. Stuyckens, J. Huygen, and K. Denies, "Automated Reasoning and Learning for Automated Payroll Management," *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, no. 17, pp. 15 107–15 116, 2021, doi: 10.1609/aaai.v35i17.17774.

[30] F. Al-Hawari, A. Alufeishat, M. Habahbeh, and A. Alfalayleh, "Scrum-guided development of an intelligent payroll management system with rule-based automation and RAG chatbot support," *Knowledge-Based Systems*, vol. 347, p. 116301, 2026, doi: 10.1016/j.knosys.2026.116301.

[31] A. M. Sherra and N. Fitriani, "Evaluasi Risiko Lebih Bayar PPh 21 Akibat Implementasi Tarif Efektif Rata-Rata (TER) Di CV. X," *Jurnal Wahana Akuntansi*, vol. 20, no. 1, pp. 25–35, 2025, doi: 10.21009/wahana.20.013.

[32] M. O. Moguillansky, D. C. Martinez, L. H. Tamargo, and A. Rotolo, "An approach to temporalised legal revision through addition of literals," *Artificial Intelligence and Law*, vol. 32, no. 3, pp. 621–666, 2024, doi: 10.1007/s10506-023-09363-w.

[33] F. Olivieri, M. Cristani, G. Governatori, L. Pasetto, A. Rotolo, S. Scannapieco, C. Tomazzoli, and T. Chekole Workneh, "Revising non-monotonic theories with sufficient and necessary conditions: the case of Defeasible Logic," *Journal of Logic and Computation*, vol. 35, no. 7, p. exae044, 2025, doi: 10.1093/logcom/exae044.

[34] W. Fungwacharakorn, K. Tsushima, and K. Satoh, "Resolving counterintuitive consequences in law using legal debugging," *Artificial Intelligence and Law*, vol. 29, no. 4, pp. 541–557, 2021, doi: 10.1007/s10506-021-09283-7.

[35] D. Srinivas, R. Das, S. Tizpaz-Niari, A. Trivedi, and M. L. Pacheco, "On the Potential and Limitations of Few-Shot In-Context Learning to Generate Metamorphic Specifications for Tax Preparation Software," in *Proceedings of the Natural Legal Language Processing Workshop 2023*. Association for Computational Linguistics, 2023, pp. 230–243, doi: 10.18653/v1/2023.nllp-1.23.

[36] S. Gogani Khiabani, A. Trivedi, D. Saha, and S. Tizpaz-Niari, "An LLM Agentic Approach for Legal-Critical Software: A Case Study for Tax Prep Software," in *Proceedings of the 2026 IEEE/ACM 48th International Conference on Software Engineering*. ACM, 2026, pp. 272–283, doi: 10.1145/3744916.3764575.

[37] V. Magesh, F. Surani, M. Dahl, M. Suzgun, C. D. Manning, and D. E. Ho, "Hallucination-Free? Assessing the Reliability of Leading AI Legal Research Tools," *Journal of Empirical Legal Studies*, vol. 22, no. 2, pp. 216–242, 2025, doi: 10.1111/jels.12413.

[38] Y. Li, D. Choi, J. Chung, N. Kushman, J. Schrittwieser, R. Leblond, T. Eccles, J. Keeling, F. Gimeno, A. Dal Lago, T. Hubert, P. Choy, C. de Masson d'Autume, I. Babuschkin, X. Chen, P.-S. Huang, J. Welbl, S. Gowal, A. Cherepanov, J. Molloy, D. J. Mankowitz, E. Sutherland Robson, P. Kohli, N. de Freitas, K. Kavukcuoglu, and O. Vinyals, "Competition-level code generation with AlphaCode," *Science*, vol. 378, no. 6624, pp. 1092–1097, 2022, doi: 10.1126/science.abq1158.

[39] J. Xin, R. Tang, Y. Yu, and J. Lin, "The Art of Abstention: Selective Prediction and Error Regularization for Natural Language Processing," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics, 2021, pp. 1040–1051, doi: 10.18653/v1/2021.acl-long.84.

[40] H. de Martim, "An Ontology-Driven Graph RAG for Legal Norms: A Hierarchical, Temporal, and Deterministic Approach," in *Legal Knowledge and Information Systems (JURIX 2025)*, ser. Frontiers in Artificial Intelligence and Applications. IOS Press, 2025, doi: 10.3233/faia251598.

[41] K. Kharraz, G. Schneider, and M. Leucker, "On Conflicts and Satisfiability in Metric Timed Normative Logics," in *Legal Knowledge and Information Systems (JURIX 2024)*, ser. Frontiers in Artificial Intelligence and Applications. IOS Press, 2024, doi: 10.3233/faia241260.

[42] L. Robaldo, S. Batsakis, R. Calegari, F. Calimeri, M. Fujita, G. Governatori, M. C. Morelli, F. Pacenza, G. Pisano, K. Satoh, I. Tachmazidis, and J. Zangari, "Compliance checking on first-order knowledge with conflicting and compensatory norms: a comparison among currently available technologies," *Artificial Intelligence and Law*, vol. 32, no. 2, pp. 505–555, 2024, doi: 10.1007/s10506-023-09360-z.

[43] A. Khoja, M. Kölbl, S. Leue, and R. Wilhelmi, "Automated consistency analysis for legal contracts," *Artificial Intelligence and Law*, vol. 34, no. 3, pp. 881–922, 2026, doi: 10.1007/s10506-025-09456-8.

[44] A. Boujelben and I. Amous, "Treating Anomalies in Rule bases associated to Ontologies," *The Journal of Supercomputing*, vol. 81, no. 1, p. 243, 2025, doi: 10.1007/s11227-024-06688-4.

[45] S. Tizpaz-Niari, V. Monjezi, M. Wagner, S. Darian, K. Reed, and A. Trivedi, "Metamorphic Testing and Debugging of Tax Preparation Software," in *2023 IEEE/ACM 45th International Conference on Software Engineering: Software Engineering in Society (ICSE-SEIS)*. IEEE, 2023, pp. 138–149, doi: 10.1109/icse-seis58686.2023.00019.

[46] R. Li, H. Liu, P.-L. Poon, D. Towey, C.-A. Sun, Z. Zheng, Z. Q. Zhou, and T. Y. Chen, "Metamorphic Relation Generation: State of the Art and Research Directions," *ACM Transactions on Software Engineering and Methodology*, vol. 34, no. 5, pp. 1–25, 2025, doi: 10.1145/3708521.

[47] H. Goldstein, J. W. Cutler, D. Dickstein, B. C. Pierce, and A. Head, "Property-Based Testing in Practice," in *Proceedings of the IEEE/ACM 46th International Conference on Software Engineering*. ACM, 2024, pp. 1–13, doi: 10.1145/3597503.3639581.

[48] S. Ravi and M. Coblenz, "An Empirical Evaluation of Property-Based Testing in Python," *Proceedings of the ACM on Programming Languages*, vol. 9, no. OOPSLA2, pp. 3897–3923, 2025, doi: 10.1145/3764068.

[49] G. Petrovic, M. Ivankovic, G. Fraser, and R. Just, "Practical Mutation Testing at Scale: A view from Google," *IEEE Transactions on Software Engineering*, vol. 48, no. 10, pp. 3900–3912, 2022, doi: 10.1109/tse.2021.3107634.

[50] G. Petrović, M. Ivanković, G. Fraser, and R. Just, "Does Mutation Testing Improve Testing Practices?" in *2021 IEEE/ACM 43rd International Conference on Software Engineering (ICSE)*. IEEE, 2021, pp. 910–921, doi: 10.1109/icse43902.2021.00087.

[51] L. Enqvist, "'Human oversight' in the EU artificial intelligence act: what, when and by whom?" *Law, Innovation and Technology*, vol. 15, no. 2, pp. 508–535, 2023, doi: 10.1080/17579961.2023.2245683.

[52] B. Green, "The flaws of policies requiring human oversight of government algorithms," *Computer Law & Security Review*, vol. 45, p. 105681, 2022, doi: 10.1016/j.clsr.2022.105681.