Knowledge-Based System Adaptif untuk Perhitungan PPh 21 dengan Akuisisi Pengetahuan Berbantuan LLM dari Regulasi dan Kebijakan Perusahaan

1st Obi Kastanya
Program Studi Teknik Informatika
Institut Teknologi Sepuluh Nopember
Surabaya, Indonesia
6025252015@student.its.ac.id

2nd Mahathir Muhammad
Program Studi Teknik Informatika
Institut Teknologi Sepuluh Nopember
Surabaya, Indonesia
6025252008@student.its.ac.id

***Abstrak*—Perhitungan Pajak Penghasilan Pasal 21 harus mengikuti perubahan regulasi dan kebijakan perusahaan, tetapi aturannya tertanam di kode. Formalisasi pajak berbantuan *large language model* (LLM) umumnya membangun basis aturan dari nol untuk satu keadaan hukum, sehingga belum diketahui apakah pembaruan berulang menjaga hasil periode lama dan apakah kesalahan merambat. Penelitian ini mengusulkan *knowledge-based system* dengan *knowledge base* bitemporal dua lapis dan akuisisi inkremental berbantuan LLM yang diperiksa lima gerbang verifikasi dan konsensus perilaku, dengan *abstain* bila tidak yakin. Evaluasinya memutar ulang 13 perubahan regulasi nyata 2023 sampai 2026 beserta 20 pengecoh dan menguji 16 perubahan yang tidak dilihat perancang. Rancangan inti dikunci sebelum eksperimen, sedangkan ablasi, model kedua, dan rantai pembangkitan ulang ditambahkan sesudah hasil awal terlihat. Data acuan emas dan perubahan uji hanya ditinjau agen AI, bukan pakar manusia. Representasi menyatakan 16 dari 16 perubahan tanpa mengubah *engine* (batas bawah satu sisi 95 persen 0,829), dengan syarat konvensi pembulatan contoh diselaraskan. Pada 18 dokumen nyata, pembaruan salah tanpa terdeteksi terjadi pada 3 (batas atas 0,377, di atas ambang 0,25) dan pembaruan benar pada 8 (selang kepercayaan 0,215 sampai 0,692), tidak lebih tinggi daripada pembanding. Pada mode berantai, 31 dari 33 peristiwa tidak menambah kesalahan baru (batas bawah 0,821), tetapi pada rantai yang dibangkitkan ulang hanya 23 dari 33 (batas bawah 0,540). *Recall* deteksi dampak lintas lapis 0,91 (selang kepercayaan 0,75 sampai 1,00). LLM layak menjadi penyusun draf pembaruan, tetapi peninjau manusia tetap diperlukan.**

Kata Kunci*—akuisisi pengetahuan, *knowledge-based system*, *knowledge graph*, *large language model*, perubahan regulasi, PPh Pasal 21, *rules as code

I. Pendahuluan

Pajak Penghasilan (PPh) Pasal 21 dipotong setiap bulan dari penghasilan pegawai, sehingga kesalahan perhitungan langsung memengaruhi setiap slip gaji. Regulasinya sering berubah. Korpus penelitian ini mencatat 13 peristiwa yang mengubah perhitungan PPh 21 pegawai tetap pada 2023–2026, tujuh di antaranya terbit pada 2025. Jenisnya beragam: batas upah iuran Jaminan Pensiun, klasifikasi natura, fasilitas Pajak Ditanggung Pemerintah (DTP), aturan pembulatan, dan pada 2024 pergantian metode ke tarif efektif rata-rata (TER) [1], [2].

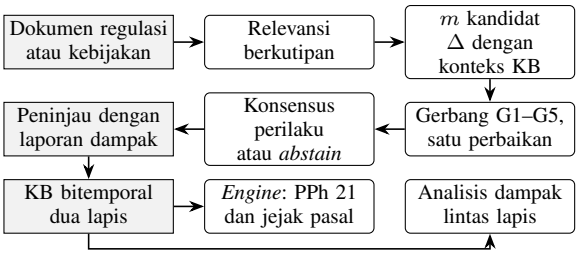
Pada praktik saat ini, aturan pajak tertanam di kode atau *spreadsheet* [3], [4]. Setiap perubahan menuntut pemrograman ulang. Sebagai ilustrasi dari dua repositori sumber terbuka, satu memasukkan TER 26 hari sesudah Peraturan Pemerintah (PP) 58/2023 terbit dan satu lagi 915 hari sesudahnya. Tidak ada bukti bahwa perubahan itu tidak menggeser hasil periode lama, dan kebijakan perusahaan yang menjadi melanggar tidak terdeteksi.

Knowledge-based system (KBS) memisahkan pengetahuan dari kode [5], tetapi memindahkan beban ke pemeliharaan *knowledge base* (KB). *Large language model* (LLM) dapat menerjemahkan teks hukum menjadi aturan [6], tetapi tidak andal untuk perhitungan yang menuntut ketepatan [7], [8]. Formalisasi pajak berbantuan LLM umumnya membangun basis aturan dari nol untuk keadaan hukum pada satu waktu. Sejauh penelusuran kami sampai November 2026, belum ada penelitian yang mengukur tiga hal pada basis aturan hukum yang dieksekusi: apakah pembaruan berulang dari LLM menjaga hasil periode lama, apakah kesalahan merambat dari satu perubahan ke perubahan berikutnya, dan bagaimana dampaknya terhadap lapisan kebijakan perusahaan.

Penelitian ini mengusulkan KBS yang pengetahuannya disimpan sebagai *knowledge graph* bitemporal dua lapis dan dijalankan *inference engine* deterministik (Gambar 1). LLM tidak menghitung pajak. LLM hanya menyusun kandidat pembaruan Δ, lima gerbang verifikasi menyaringnya, konsensus perilaku memilih satu, dan sistem *abstain* bila tidak ada kandidat yang meyakinkan.

Empat pertanyaan penelitian (*research question*, RQ) dijawab. RQ1, sejauh mana representasi dapat menyatakan perubahan regulasi dan kebijakan, termasuk yang tidak diketahui saat dirancang, tanpa mengubah kode *engine*? RQ2, seberapa sering akuisisi berbantuan LLM menerapkan pembaruan benar dan salah, dan apa peran gerbang? RQ3, berapa peristiwa nyata yang berhasil diterapkan otomatis, dan apakah kesalahan merambat? RQ4, seberapa lengkap sistem menemukan kebijakan perusahaan yang terdampak?

Kontribusinya adalah (K1) representasi temporal dua lapis dengan resolusi konflik dan analisis dampak lintas lapis,



Gambar 1. Ikhtisar sistem dan alur akuisisi. LLM hanya menyusun kandidat. Perhitungan dijalankan *engine* deterministik atas KB.

(K2) metode akuisisi inkremental dengan gerbang verifikasi, gerbang non-vakuitas, dan konsensus perilaku, (K3) definisi adaptivitas representasional dan operasional serta protokol *regulation replay* yang memisahkan kesalahan bawaan, baru, dan terpicu, dan (K4) artefak berupa KB, korpus, emas, *test suite*, dan kode evaluasi.

II. Latar belakang

PPh 21 pegawai tetap dihitung dari penghasilan bruto dikurangi biaya jabatan, iuran, dan penghasilan tidak kena pajak, lalu penghasilan kena pajak (PKP) setahun dikenakan tarif progresif Pasal 17 dalam lima lapisan 5%–35% [9], [10]. Sampai 2023, PPh setiap masa dihitung dengan menyetahunkan penghasilan [11]. Sejak 2024, masa Januari sampai November memakai TER bulanan dengan 125 lapisan pada kategori A, B, dan C, dan masa terakhir menghitung ulang setahun [1], [2]. Fasilitas DTP 2025–2026 menambah kriteria sektor dan batas penghasilan [12], [13].

Perusahaan menentukan komponen seperti prorata, tunjangan hari raya, dan siapa yang menanggung pajak, tetapi tidak boleh menyimpangi ketentuan wajib. Contohnya, perjanjian kerja bersama (PKB) PT Wijaya Karya 2025–2026 Pasal 22 ayat (3) menyatakan insentif pajak pemerintah tidak diberikan kepada pegawai, sedangkan Peraturan Menteri Keuangan (PMK) 10/2025 Pasal 5 ayat (1) mewajibkan PPh DTP dibayarkan tunai [12]. Konflik ini laten, karena perusahaan itu bukan sektor penerima DTP. Taksonomi jenis perubahan (T1–T10) dan jenis konflik (C1–C10) disusun sebelum ada keluaran LLM. Lingkup penelitian ini adalah pegawai tetap pada pemberi kerja swasta atau badan usaha milik negara.

III. Penelitian terkait

Rules as code seperti Catala [5] dan DataLex [14] memformalkan peraturan menjadi program, tetapi pengetahuannya ditulis manusia. *Ripple-Down Rules* menambah aturan secara inkremental dengan *cornerstone case* sebagai pengaman regresi [15], yang setara dengan gerbang G4, tetapi pakar tetap menulis setiap perubahan.

Kelompok terdekat memakai LLM. Veeramani dkk. menyimpan *Income Tax Act* India sebagai *knowledge graph* dan mencapai akurasi 80% pada 20 skenario [16]. Yadamsuren dkk. memformalkan satu pasal *Internal Revenue Code* Amerika Serikat (AS) ke Prolog [17]. Lorenzo dkk. menerjemahkan

Tabel I
Posisi terhadap karya terdekat (Inkr. = pembaruan inkremental, Ramb. = perambatan kesalahan diukur, Prs. = lapisan perusahaan)

Karya	Representasi	Penyusun	Inkr.	Ramb.	Prs.
Catala [5]	bahasa khusus domain	manusia	–	–	–
Ripple-Down Rules [15]	aturan, pengecualian	pakar	ya	–	–
Veeramani dkk. [16]	graf, aturan simbolik	LLM, pakar	gagasan	–	–
Yadamsuren dkk. [17]	Prolog	LLM	–	–	–
Lorenzo dkk. [18]	Catala	LLM	–	–	–
Jurayj dkk. [19]	Prolog	LLM	–	–	–
Gogani-Khiabani dkk. [20]	kode Python	LLM	satu langkah	–	–
Prior dkk. [23]	teks XML	LLM	teks	sebagian	–
Penelitian ini	graf bitemporal dan aturan dieksekusi	LLM, gerbang	ya	ya	ya

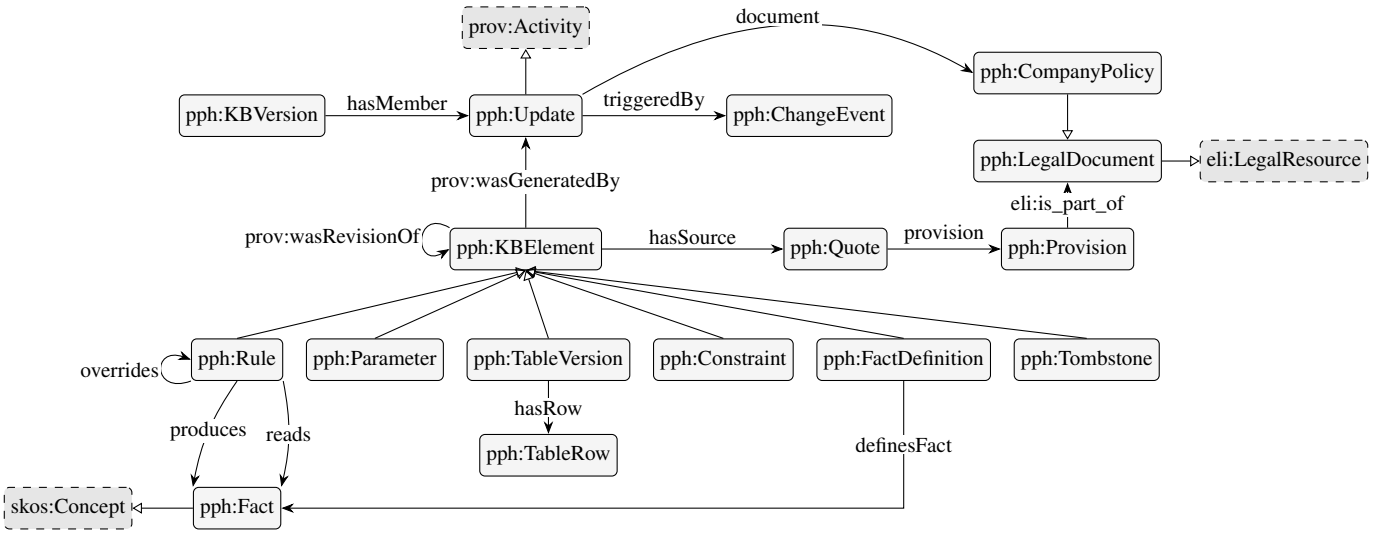
provisi pajak Prancis ke Catala tanpa mengeksekusi hasilnya [18]. Jurayj dkk. menggabungkan LLM dengan *solver* Prolog pada 100 kasus, dan o3 menghasilkan 75 benar, 15 salah, dan 10 *abstain* [19]. Karya-karya ini memformalkan satu keadaan hukum. Pengecualian terdekat adalah Gogani-Khiabani dkk., yang meminta LLM memperbarui kode pajak AS dari 2020 ke 2021 dan memilih kandidat dengan suara mayoritas perilaku [20], tetapi hanya satu langkah dan tanpa uji periode lama.

Penyuntingan pengetahuan LLM secara berurutan merusak kemampuan model [21], walaupun KoLEG mempertahankan kinerja di atas 95% sesudah empat suntingan atas amandemen hukum Korea [22]. Yang disunting di sana adalah model, bukan basis aturan. Prior dkk. mengonsolidasikan undang-undang Jerman dengan LLM, dan *exact match* turun dari 50,3% pada satu langkah menjadi 20,51% pada rantai amandemen [23], tetapi objeknya teks, bukan aturan yang dieksekusi. Metrik RQ2 dan RQ3 berakar pada *pass@k* [24], *n@k* [25], dan prediksi selektif [26]. Tabel I merangkum posisi penelitian ini.

IV. Representasi dan *inference engine*

Pengetahuan struktural, yaitu dokumen, pasal, aturan, parameter, tabel, kebijakan, versi, dan relasinya, disimpan sebagai *knowledge graph Resource Description Framework* (RDF) dan *Web Ontology Language* (OWL) di GraphDB, dengan validasi *Shapes Constraint Language* (SHACL) [27] dan kueri SPARQL. Ontologinya memakai ulang *European Legislation Identifier* (ELI) [28], OWL-Time [29], dan PROV-O [30]. Ekspresi perhitungan disimpan sebagai atribut aturan dan dijalankan *engine*, karena aritmetika pajak menuntut ketepatan rupiah, pecahan eksak, dan iterasi titik tetap. Dengan pembagian ini, perubahan regulasi hanya menyentuh data graf. Gambar 2 menunjukkan ontologinya.

Definisi 1 (*Knowledge base*)**.** *$\mathcal{K}$ berisi rekaman aturan, parameter berversi, versi tabel, batasan wajib, dan dokumen sumber. Aturan $r = \langle id, \ell, \sigma, [t_s, t_e], t_c, \varphi, f := e, ov, src\rangle$ memuat lapisan ℓ (regulasi atau perusahaan), sifat σ (wajib, default, opsional), masa berlaku, tanggal pencatatan t_c*



Gambar 2. Ontologi *knowledge base*. Kelas utama adalah dokumen hukum, pasal, kutipan, unsur KB, konsep fakta, kebijakan perusahaan, peristiwa perubahan, pembaruan, dan versi KB.

(tanggal terbit dokumen), kondisi, fakta beserta ekspresinya, aturan yang dikalahkannya, dan kutipan sumber. Rekaman tidak pernah disunting di tempat.

Definisi 2 (Hasil perhitungan)**.** $hasil(\mathcal{K}, x, t, \omega)$ *adalah nilai fakta keluaran kasus* x *pada masa pajak* t*, dihitung dengan regulasi yang diketahui pada tanggal* ω *ditambah kebijakan kasus itu. Kasus adalah satu pegawai pada satu pemberi kerja untuk satu tahun pajak, dan fakta utamanya PPh 21 terutang per masa.*

Masa berlaku $[t_s, t_e]$ dan waktu pengetahuan t_c membuat $\mathcal{K}$ bitemporal, karena pertanyaan pada ω hanya melihat rekaman dengan $t_c \leq \omega$. Untuk regulasi berlaku surut, pertanyaan dengan $\omega \geq t_c$ menghasilkan nilai seharusnya. Bila beberapa aturan aktif untuk fakta yang sama, *engine* memakai *lex superior* (regulasi wajib, aturan perusahaan, regulasi opsional yang diadopsi, lalu *default*), *lex specialis* lewat relasi eksplisit `overrides`, dan *lex posterior*. Aturan perusahaan yang kalah dari aturan wajib dengan nilai berbeda dicatat sebagai konflik. *Engine* menghitung satu kasus setahun penuh dengan evaluasi berbasis permintaan dan iterasi titik tetap untuk *gross-up*, dan mencatat jejak setiap fakta sampai pasal. Ekspresi dibatasi pada 27 fungsi terdaftar dan semua aritmetika eksak, sehingga perubahan pembulatan adalah pembaruan data.

V. Akuisisi pengetahuan berbantuan LLM

Pembaruan Δ atas peristiwa dengan tanggal terbit t_{terbit} dan tanggal berlaku $t_{berlaku}$ menambah, mengubah, atau mencabut unsur, dengan $\mathcal{K}' = \mathcal{K} \oplus \Delta$. Pembaruan emas memenuhi $\mathcal{K}^\star_n = \mathcal{K}^\star_{n-1} \oplus \Delta^\star_n$, dan Δ kosong adalah jawaban benar untuk pengecoh.

Definisi 3 (Syarat adaptif)**.** *Untuk himpunan kasus* S*: (A1) kode engine tidak berubah; (A2)* $hasil(\mathcal{K}', x, t, \omega) = hasil(\mathcal{K}^\star, x, t, \omega)$ *untuk* $x \in S$*,* $t \geq t_{berlaku}$*, dan* $\omega \geq t_{terbit}$*; (A3*$_t$*) hasil untuk* $t < t_{berlaku}$ *tidak berubah; (A3*$_\omega$*) hasil untuk* $\omega < t_{terbit}$ *tidak berubah; (A4) laporan konflik sama dengan laporan konflik* $\mathcal{K}^\star$*.*

Definisi 4 (Adaptivitas)**.** *Representasi adaptif terhadap suatu peristiwa bila* ada Δ *yang memenuhi A1–A4 (RQ1). Sistem adaptif secara operasional bila* $\hat{\Delta}$ *yang* dipilih alur *memenuhi A2, A3*$_t$*, dan A4 pada seluruh* S^E*, sehingga satu observasi salah sudah membuat* $\hat{\Delta}$ *salah (RQ2, RQ3).*

A1 dan A3$_\omega$ berlaku karena konstruksi dan diperiksa sebagai invarian, sedangkan A2, A3$_t$, dan A4 diuji.

Alur. Teks dokumen dikunci dengan SHA-256 dan dipotong per pasal. LLM menilai relevansi dengan kutipan, lalu menyusun m kandidat independen dengan konteks KB dari SPARQL dan kutipan per unsur. Kandidat yang lolos gerbang, dengan satu putaran perbaikan, dikelompokkan menurut nilai fakta keluaran dan laporan konflik pada kasus gerbang S^G. Kelompok terbesar menang, dan seri atau tidak adanya kandidat yang lolos berarti *abstain*. Dalam operasi, peninjau memeriksa pembaruan sebelum berlaku.

Gerbang. G1 memeriksa skema, penerapan ketat, dan 15 *shape* serta 12 batasan SHACL-SPARQL. G2 mewajibkan kutipan ada di teks sumber, setiap bilangan dan tanggal baru muncul di kutipan unsurnya, dan $t_c = t_{terbit}$. G3 memeriksa ekspresi, graf dependensi, dan rujukan. G4 adalah regresi pada S^G, yaitu hasil masa sebelum efek dan hasil dengan $\omega < t_{terbit}$ tidak berubah. G5 menuntut non-vakuitas, yaitu

setiap unsur yang ditambah atau diubah mengubah minimal satu fakta keluaran atau laporan konflik pada S^G, dan unsur yang dicabut pernah menyala. Tanpa G5, pembaruan kosong lolos semua gerbang. S^G dibangkitkan per kandidat tanpa membaca emas atau S^E, paling banyak 300 kasus, dan tidak beririsan dengan S^E.

Analisis dampak. Kebijakan P *terdampak* bila nilai fakta aturan P berubah, aturan pemenang fakta yang dibaca atau dihasilkan P berubah, atau muncul konflik baru. Label ini diturunkan dari eksekusi, sedangkan detektor bekerja statis. Detektor menghitung F_Δ, yaitu fakta yang disentuh Δ beserta penutup hilirnya, lalu menandai aturan P yang membaca fakta itu atau menghasilkan fakta yang sama dengan aturan Δ. Kuerinya dibekukan sebelum E4.

Konfigurasi. Model utama adalah Claude Opus 5.5, dan model kedua `gpt-6.1-sol`. Panggilan eksperimen dijalankan pada 28–29 Oktober 2026 dan dicatat lengkap, sehingga analisis dapat diulang tanpa LLM. Pengeluaran sekitar USD 81,6 untuk Claude dan USD 8,1 untuk OpenAI.

VI. Metodologi evaluasi

Metrik. RQ1 memakai adaptivitas representasional (*representational adaptability*, RA), yaitu proporsi perubahan tak terlihat yang Δ-nya mereproduksi seluruh contoh tanpa mengubah *engine*. RQ2 memakai laju kesalahan senyap (*silent error rate*, SER) dan laju penerapan benar (*correct application rate*, CAR) atas 13 regulasi dan 5 PKB nyata, satu hasil per dokumen. RQ3 memakai laju adaptivitas operasional (*operational adaptability rate*, OAR), yaitu proporsi peristiwa yang tidak menambah kesalahan baru, dan kesalahan terpicu I_n, yaitu kasus yang salah pada mode berantai tetapi tidak salah pada mode terisolasi dan belum salah sebelumnya. RQ4 memakai *recall* dan F_2 atas pasangan kebijakan dan peristiwa. Tabel IV memuat hipotesis dan ambangnya.

Desain dan pra-registrasi. Penelitian ini mengikuti *design science research*. Hipotesis, ambang, pembagian data, kasus uji utama, rencana analisis, alur akuisisi, dan *engine* dikunci pada *commit* `c5983ff` (*tag* `prareg`, `alur-beku`, `engine-v1`) sebelum peristiwa uji pertama dijalankan. Emas juga sudah tetap pada *commit* itu. Penguncian ini memakai git, yang lebih lemah daripada registrasi pihak ketiga. Analisis mutan dan 17 kasus terarah masuk di `d9c2886`, 42 menit sesudah panggilan E2 pertama, padahal pra-registrasi memintanya sebelum E2. Keduanya diturunkan dari emas saja dan masuk sebelum E2 dinilai. Anggaran awal USD 15 habis sesudah strata utama E2 dan E3, sehingga amandemen 1 (`2df0727`) ditulis sesudah hasil awal terlihat, tanpa mengubah alur, *engine*, emas, S^E, atau ambang. Selain sembilan pengecoh sisa, jalan terisolasi kedua, dan rantai pembangkitan ulang, semua jalan amandemen eksploratori.

Data. Pengembangan memakai 13 peristiwa 2012–2022, lima regulasi fiktif, dan satu PKB. Data uji berisi 13 peristiwa nyata (E01–E13), 20 pengecoh yang jawabannya pembaruan kosong, lima PKB nyata, 14 kebijakan buatan, empat dokumen kontrafaktual, dan 16 perubahan tak terlihat (U01–U16).

Tabel II
Korpus uji dan hasil E2 usulan (B benar, S salah, A *abstain*). Baris SP dan CF lewat amandemen 1; 2 dari 5 B pada SP tidak teruji

No.	Dokumen	Jenis	$\lvert\Delta^\star\rvert$	E2
E01	Surat batas upah Jaminan Pensiun 2023	T1	1	B
E02	PMK 66/2023 (natura)	T3	15	S
E03	PP 58/2023 (TER)	T2, T7	7	B
E04	PMK 168/2023 (juklak TER)	T7, T3	14	A
E05	Surat batas upah Jaminan Pensiun 2024	T1	1	B
E06	PMK 10/2025 (DTP padat karya)	T4	15	A
E07	PP 7/2025 (keringanan iuran)	T1	2	S
E08	Surat batas upah Jaminan Pensiun 2025	T1	1	B
E13	PER-11/PJ/2025 (pembulatan)	T9	1	B
E09	PP 36/2025 (perpanjangan keringanan)	T6	2	B
E10	PMK 72/2025 (DTP pariwisata)	T5	5	B
E11	PMK 105/2025 (DTP 2026)	T4	11	S
E12	Surat batas upah Jaminan Pensiun 2026	T1	1	B
P	20 pengecoh	–	0	1 S
PKB	5 PKB nyata	T10	14–35	5 A
SP	14 kebijakan buatan	T10	1–7	5 B, 6 S, 3 A
CF	4 kontrafaktual	T1, T3, T4	–	1 B, 1 S, 2 A

Tabel III
Ruang uji S^E dan cakupannya

Kriteria	Kasus/tahun	Cakupan
Batas Pasal 17	15	kelima tarif 5%–35%, 2023–2026
Batas TER ($b-1$, b, $b+1$)	321	107 dari 122 batas, 2024–2026
Kombinasi berbatasan	42–45	2-arah 100%, 3-arah 62–64%
Sampel operasional	300	2023–2026

Tabel II merinci peristiwa uji. Sampai 3 November 2026 penelusuran kami belum menemukan peristiwa prospektif yang terbit.

Bias pandangan belakang. Representasi dikembangkan sesudah perubahan uji terbit. Karena itu, 16 perubahan sintetis ditulis agen terpisah, disegel dengan manifes *hash* sebelum representasi dibekukan, dan dikerjakan agen lain yang tidak ikut merancang.

Instrumen (E0). Semua angka bergantung pada emas $\mathcal{K}^\star$ dan kasus uji S^E, sehingga keduanya divalidasi lebih dulu terhadap contoh resmi (GT1, dengan *holdout*), kalkulator Direktorat Jenderal Pajak (DJP, GT2), 50 kasus yang dihitung terpisah dari *engine* (GT3), dan contoh kebijakan (GT5). Setiap selisih diadjudikasi. Kecukupan S^E diukur dengan *mutation score*, dengan ambang 0,80. Penelitian ini tanpa kolaborator di luar penulis. Peran independen, termasuk pembaca kedua emas, diisi agen AI, dan tidak ada pakar *payroll* manusia yang memvalidasi emas.

Ruang uji. S^E berisi 2.398 kasus pegawai-tahun dari sampel operasional Badan Pusat Statistik, kombinasi berbatasan, dan batas lapisan (Tabel III), ditambah 120–180 kasus per kebijakan. Batas Pasal 17 diuji pada lima nilai PKP di $b-1000$, b, dan $b+1000$, karena PKP dibulatkan ke ribuan. Lima batas TER teratas setiap kategori (Rp454 juta sampai Rp1,419 miliar) tidak tercapai generator, sehingga tarif TER 30%–34% tidak muncul di kasus mana pun.

Eksperimen dan pembanding. E1 menguji perubahan tak

terlihat. E2 memakai mode terisolasi, yaitu $\hat{\Delta}_n$ diterapkan pada $\mathcal{K}^{\star}_{n-1}$, dengan $m = 3$ untuk regulasi dan $m = 2$ untuk PKB. E3 memakai mode berantai, yaitu $\hat{\Delta}_n$ diterapkan pada $\mathcal{K}^{\text{sis}}_{n-1}$, dengan 150 kasus per tahun dan $R = 1$. Rantai *transplantasi* memindahkan hasil E2, sedangkan rantai *pembangkitan ulang* membangkitkan $\hat{\Delta}_n$ dengan $\mathcal{K}^{\text{sis}}_{n-1}$ sebagai konteks. Keduanya tanpa peninjau. E4 menilai detektor dampak. Pembandingnya B1 (riwayat kalkulator sumber terbuka), B2 (LLM menghitung langsung), B3 (kandidat pertama yang lolos G1–G2), B4 (suara terbanyak tanpa gerbang), dan B5 untuk RQ4, yaitu (i) menandai kebijakan yang menyentuh F_{Δ} dan (ii) memindai teks ekspresi tanpa graf. Ablasi AB1–AB5 menguji formalisasi dari nol, konteks KB, gerbang, pemilihan, dan SHACL.

Statistik. Proporsi dilaporkan dengan selang kepercayaan (*confidence interval*, CI) eksak Clopper–Pearson dan batas satu sisi 95%. Perbandingan berpasangan memakai McNemar eksak dan selisih risiko dengan CI Newcombe, dengan koreksi Holm. RQ4 memakai *bootstrap* klaster per peristiwa. Dengan $N = 18$, McNemar baru mencapai daya 80% pada selisih CAR sekitar 0,45, sehingga kegagalan menolak H2b bukan bukti kesetaraan.

VII. Hasil

Tabel IV merangkum putusan semua hipotesis.

Validasi instrumen. KB emas cocok dengan GT3 pada 50/50 kasus dan 2.107/2.107 observasi. GT1 pengembangan cocok pada 22/26 kasus, dan selisihnya ralat contoh resmi. GT2 cocok pada 15/20 kasus bulanan, dengan selisih Rp1 karena kalkulator DJP membuang pecahan, dan pada 90/90 baris masa terakhir. GT5 cocok pada 67/79 observasi, dan selisihnya dijelaskan. GT1 *holdout* semula 6/10 kasus dan menyingkap dua kesalahan emas, dan sesudah koreksi menjadi 8/10 kasus dan 232/235 observasi. Protokol koreksi emas dipakai tiga kali. Koreksi kebijakan buatan dibuat sesudah keluaran LLM terlihat dan mengubah hasil usulan dari 3 benar, 8 salah, dan 3 *abstain* menjadi 5, 6, dan 3. *Mutation score* atas mutan tidak setara naik dari 0,90 ke 1,00 sesudah 17 kasus terarah. Pembaca kedua sepakat atas nilai pada 90% satuan, dengan Krippendorff's α tanggal mulai 0,79.

RQ1. Ke-16 perubahan tak terlihat dapat dinyatakan tanpa mengubah *engine*, dengan 100 contoh dan 2.609 nilai tereproduksi persis (CI 0,794–1,000, batas bawah satu sisi 0,829). Hasil ini bergantung pada satu Δ konvensi, karena contoh membulatkan ke bawah, sama seperti kalkulator DJP, sedangkan KB membulatkan ke rupiah terdekat menurut tafsir kami atas Peraturan Direktur Jenderal Pajak PER-11/PJ/2025. Tanpa konvensi, 8/16 lolos, dengan selisih paling besar Rp11, dan sebagian kegagalan U14 berasal dari Δ yang tidak lengkap. E1 juga menyingkap batas representasi, terutama tidak adanya aritmetika tanggal. Semua peristiwa nyata dapat dinyatakan tanpa perubahan *engine*, tetapi bukti ini lemah karena bias pandangan belakang. Sebagian klausul PKB tidak diformalkan, dan alasannya dicatat per PKB.

RQ2. Tabel V melaporkan 18 dokumen nyata. SER usulan 3/18 (0,167; CI 0,036–0,414) dan CAR 8/18 (0,444; CI 0,215–0,692). SER usulan secara titik lebih rendah daripada B3 (3 lawan 7; McNemar satu sisi $p = 0{,}0625$), tetapi selisih itu belum bermakna, dan yang didukung data hanya non-inferioritas terhadap B3. Pada 13 regulasi, usulan benar 8, salah 3, dan *abstain* 2. Pada perubahan parameter (T1), 4 dari 5 benar, dan pada jenis struktural (T2–T9), 4 dari 8 benar. Kesalahan senyapnya adalah E02 (natura pada bruto), E07 (premi keringanan Jaminan Kecelakaan Kerja), dan E11 (natura kendaraan dalam uji DTP). Pada 5 PKB, usulan *abstain* semuanya, dan tidak ada PKB yang benar pada kondisi mana pun. Jalan kedua menghasilkan 8 benar, 2 salah, dan 3 *abstain*, dan E07 serta E11 salah lagi, sehingga kesalahan itu sistematis. Model kedua memberi SER 3/18 lawan 7/18 untuk B3, pola yang sama secara titik.

Pada regulasi, *pass@1* 0,667, *pass@m* 0,692, dan *1@m* 0,615, sehingga konsensus tidak lebih baik daripada memilih satu kandidat acak. Dari 49 kandidat awal, 17 gagal, terutama di G2 (8) dan G5 (5), dan 11 lolos sesudah perbaikan. Semua 18 dokumen nyata dinilai relevan. Pada 20 pengecoh, 7 dinilai relevan (0,35; CI 0,15–0,59), tetapi hanya P01 yang salah-diterapkan. Hasil berikut eksploratori. Pada 4 kontrafaktual hasilnya 1 benar, 1 salah, dan 2 *abstain*, dengan laju hafalan 0/6. Pada 14 kebijakan buatan, usulan benar 5 (2 tidak teruji), salah 6, dan *abstain* 3. Dari 28 kutipan yang dilabeli, 23 mendukung dan 5 sebagian. Formalisasi dari nol (AB1) pada dua keadaan hukum tidak menghasilkan kandidat yang lolos gerbang, tetapi hanya dari enam kandidat. SHACL menolak 7 dari 319 draf yang lolos skema JSON.

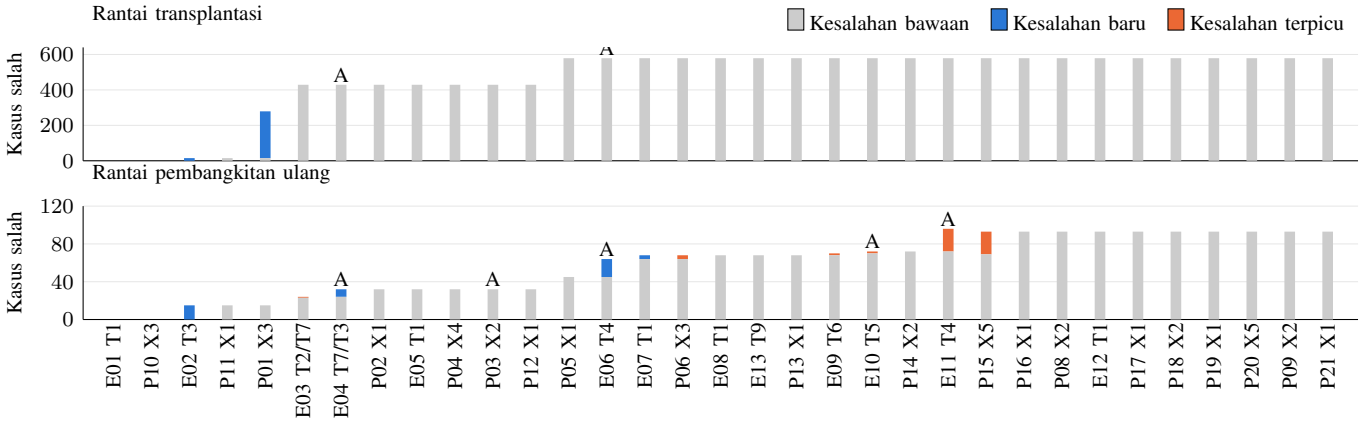
RQ3. Gambar 3 menunjukkan kedua rantai. Penetapan rantai transplantasi sebagai analisis terdaftar adalah tafsiran kami atas amandemen 1. Pada rantai itu, OAR 31/33 (CI 0,798–0,993), sehingga H3a diterima, tetapi kesalahan baru hanya muncul pada E02 (15 kasus) dan P01 (264 kasus). Sejak P05, 579 dari 600 kasus sudah salah, sehingga angka itu sebagian besar mencerminkan *masking*. Pada rantai pembangkitan ulang, yang mengikuti Definisi 4 sepenuhnya, OAR 23/33 (CI 0,513–0,844), OAR regulasi 5/13, dan kesalahan akhir 93 dari 600. Sebanyak 53 dari 103 kesalahan baru muncul pada peristiwa *abstain*. Kesalahan terpicu 29 kasus pada 13 peristiwa regulasi (57 termasuk pengecoh), dan 26 di antaranya di E10 dan E11, tempat rantai *abstain*. Jadi sebagian besar berasal dari KB yang tidak diperbarui, bukan dari pembaruan salah yang merambat.

Sebagai pembanding, TER di KB adalah 8 unsur baru dan 13 unsur diubah pada E03 dan E04, tanpa perubahan *engine*. Dua kalkulator sumber terbuka (B1) memasukkan TER 26 dan 915 hari sesudah peraturan terbit, dengan 163 dan 504 baris kode diubah. Perbandingan ini ilustrasi deskriptif. LLM yang menghitung langsung (B2, eksploratori) tepat pada 76/100 kasus operasional (CI 0,66–0,84) dan dalam Rp1 pada 97/100, tanpa jejak dan tidak deterministik.

RQ4. Dari 134 pasangan kebijakan dan peristiwa, 33 positif (prevalensi 0,25), dan 27 positif berasal dari kebijakan buatan. Detektor beku mencapai *recall* 0,91, presisi 0,71, dan F_2 0,862. F_2 itu lebih tinggi daripada pemindaian teks B5(ii) (0,669), tetapi tidak lebih tinggi daripada B5(i) (0,868). Detek-

Tabel IV
HIPOTESIS DAN HASIL. [a]DIJALANKAN LEWAT AMANDEMEN 1, SESUDAH HASIL AWAL TERLIHAT

Hipotesis	Hasil	Putusan
Invarian A1 dan A3$_\omega$	0 pelanggaran	terpenuhi
H1: batas bawah RA $\geq 0{,}70$	16/16 (0,829); konservatif 15/16 (0,736); tanpa konvensi pembulatan contoh 8/16 (0,279)	diterima, bergantung pada konvensi
H2a: batas atas SER $\leq 0{,}25$	SER 3/18, batas atas 0,377	tidak diterima
H2b: CAR usulan $>$ B3 dan B4	8/18 lawan 8/18 dan 9/18; McNemar $p = 0{,}75$ dan 1,0; Holm $p = 1$	tidak diterima
H2b: non-inferioritas SER ($\delta_S = 0{,}10$)	terhadap B3 selisih $-0{,}222$, batas atas 0,004 (Holm 0,036–0,064); terhadap B4 selisih 0, batas atas 0,153	terpenuhi terhadap B3, tidak terhadap B4
H3a: batas bawah OAR $\geq 0{,}75$	transplantasi 31/33 (0,821), sebagian besar karena *masking*; pembangkitan ulang[a] 23/33 (0,540)	diterima pada analisis terdaftar, tidak kokoh
H3b: kesalahan terpicu $\leq$ batas derau	29 kasus lawan batas derau 0, satu rantai[a]	tidak didukung
H4a: batas bawah *recall* $\geq 0{,}70$	0,91, CI klaster 0,75–1,00	diterima
H4b: F_2 detektor $>$ B5(i) dan B5(ii)	$+0{,}193$ (CI 0,062–0,400) terhadap B5(ii); $-0{,}006$ (CI $-0{,}110$–0,058) terhadap B5(i)	tidak diterima



Gambar 3. Hasil *regulation replay* per peristiwa, urut kronologis (E peristiwa uji, P pengecoh, diikuti kode jenis). Tinggi batang adalah kasus salah sesudah peristiwa itu. Huruf A menandai *abstain*. Kasus yang dinilai naik dari 300 ke 600 saat tahun pajak baru masuk. Karena $R = 1$, tidak ada rentang antarpengulangan.

Tabel V
KONDISI E2 ATAS 18 DOKUMEN NYATA. ABS = LAJU *abstain*, RISIKO SEL. = SER/(CAR + SER). [a]LEWAT AMANDEMEN 1, EKSPLORATORI

Kondisi	SER	CAR	ABS	Risiko sel.
Usulan	3/18	8/18	7/18	0,27
B3 (pertama lolos G1–G2)	7/18	8/18	3/18	0,47
B4 (mayoritas tanpa gerbang)	3/18	9/18	6/18	0,25
AB2 tanpa konteks KB[a]	5/18	6/18	7/18	0,45
AB3 tanpa G5	3/18	9/18	6/18	0,25
AB3 tanpa G4	3/18	8/18	7/18	0,27
AB3 tanpa perbaikan	3/18	7/18	8/18	0,30
AB4 pertama lolos	8/18	8/18	2/18	0,50
AB4 seleksi sempurna	0/18	8/18	10/18	0
Sensitivitas $m = 5$[a]	3/18	8/18	7/18	0,27
Model kedua, usulan[a]	3/18	7/18	8/18	0,30
Model kedua, B3[a]	7/18	6/18	5/18	0,54

tor melewatkan tiga pasangan, karena kebijakan *menghasilkan* fakta yang berubah lewat parameter hulu. Detektor v2, yang dibuat sesudah hasil terlihat, menutup celah itu, tetapi menjadi identik dengan B5(i).

VIII. PEMBAHASAN

Jawaban. H1 diterima, dengan syarat konvensi pembulatan diselaraskan. H2a dan H2b tidak diterima, kecuali non-inferioritas SER terhadap B3, sehingga penurunan SER secara titik dibayar dengan *abstain*, bukan kenaikan pembaruan benar. Dengan batas atas SER 0,377, sistem belum dapat berjalan tanpa peninjau. H3a diterima pada analisis terdaftar tetapi tidak kokoh, dan H3b tidak didukung. Bukti bahwa pembaruan salah merambat lemah, sedangkan *abstain* jelas berubah menjadi kesalahan di mode berantai, karena peristiwa berikutnya mewarisi KB yang tidak diperbarui. H4a diterima dan H4b tidak, dan temuan ini belum dapat digeneralisasi ke PKB nyata.

Kesalahan LLM. Kesalahan senyap yang dominan adalah cakupan salah dan pengecualian terlewat. Tidak ada gerbang yang memeriksa kelengkapan, dan E07 serta E11 salah dengan kandidat yang sepakat, sehingga konsensus tidak menangkapnya. Kutipan karangan dan nilai hafalan tidak teramati. Pengecoh sulit P01 paling merusak di rantai transplantasi.

Implikasi. Dua sumbu waktu memungkinkan perubahan seperti TER dinyatakan sebagai data, dengan hasil masa lampau terjaga dan jejak sampai pasal. LLM berguna sebagai penyusun draf, bukan penghitung. Peninjau manusia tetap diperlukan dan perlu didukung laporan dampak [31]. Seleksi sempurna memberi SER 0/18 dengan CAR tetap 8/18, sehingga kandidat benar sering ada, tetapi aturan pemilihan belum menemukannya.

Ancaman validitas. Pada validitas internal, emas, *engine*,

dan tafsir disusun pihak yang sama, bahan yang semula untuk pakar hanya ditinjau agen AI, dan penyusun emas serta model uji sekeluarga. Mitigasinya GT1, GT2, *holdout*, dan uji *engine* terpisah. Analisis tidak sepenuhnya buta, karena amandemen 1 ditulis sesudah hasil awal terlihat, gerbang disesuaikan sampai emas peristiwa uji lolos sehingga ada kebocoran desain, dan koreksi emas kebijakan buatan menguntungkan usulan. Bias pandangan belakang ditekan perubahan tak terlihat, tetapi perubahan itu ditulis agen, belum diperiksa manusia, dan bergantung pada konvensi pembulatan. Pada validitas konstruk, kecocokan dengan acuan tidak sama dengan kesesuaian hukum [32]. Validitas eksternal terbatas pada satu yurisdiksi, satu jenis pajak, dan lima PKB. Validitas kesimpulan dibatasi $N = 18$, $R = 1$, dan m yang hanya 3 dan 2 karena anggaran. Kontaminasi tidak dapat diuji dengan pemisahan *cutoff*, karena semua peristiwa uji terbit sebelum *cutoff* kedua model, sehingga buktinya hanya kontrafaktual tanpa hafalan dan regulasi fiktif.

Keterbatasan. Sebanyak 15 batas TER tidak teruji, sehingga hasil tidak mencakup bruto bulanan di atas sekitar Rp450 juta pada masa Januari sampai November. Pencabutan tanpa pengganti (T8) tidak punya contoh nyata. RQ4 hanya memakai masukan $\Delta^\star$, sehingga mengukur detektor, bukan alur penuh. Beberapa metrik diagnostik rancangan tidak dilaporkan, antara lain upaya koreksi, *drift* dalam rupiah, dan matriks konfusi per gerbang.

IX. Kesimpulan

Representasi bitemporal dua lapis cukup ekspresif untuk 16 perubahan tak terlihat (RA 16/16, batas bawah 0,829), bergantung pada konvensi pembulatan contoh. Akuisisi satu langkah belum cukup aman tanpa peninjau, dengan SER 3/18 (batas atas 0,377) dan CAR 8/18 (CI 0,215–0,692). OAR 31/33 (batas bawah 0,821) pada rantai transplantasi turun menjadi 23/33 (batas bawah 0,540) bila pembaruan dibangkitkan ulang. Detektor dampak menemukan sebagian besar kebijakan terdampak (*recall* 0,91, CI 0,75–1,00), tetapi tidak lebih baik daripada penandaan sederhana. Penelitian lanjutan mencakup validasi emas oleh praktisi pajak manusia, pengujian 15 batas TER yang tersisa, gerbang kelengkapan, antrean peninjauan untuk *abstain*, aritmetika tanggal, dan E3 dengan $R > 1$ serta gerbang yang dikalibrasi tanpa emas uji.

Ketersediaan data

Kode, KB emas, korpus, ruang uji, log eksperimen, skrip analisis, dan versi lengkap naskah ini tersedia di https://github.com/obikastanya/pph_payroll_with_knowledge_base. Teks PKB dan *prompt* yang memuatnya tidak disertakan karena milik pihak ketiga.

Ucapan terima kasih

Penelitian ini memakai asisten AI Claude Code dengan model Claude Opus 5.5 (Anthropic) untuk menulis kode sistem dan skrip evaluasi, menyusun draf emas dan bahan evaluasi, memeriksa angka, serta menyusun draf teks semua bagian naskah, tabel, gambar, dan kode LaTeX. Penulis bertanggung jawab atas seluruh isi naskah.

Daftar Pustaka

[1] Republik Indonesia, "Peraturan Pemerintah Nomor 58 Tahun 2023 tentang Tarif Pemotongan Pajak Penghasilan Pasal 21 atas Penghasilan Sehubungan dengan Pekerjaan, Jasa, atau Kegiatan Wajib Pajak Orang Pribadi," https://peraturan.bpk.go.id/Download/332609/PP%20Nomor%2058%20Tahun%202023.pdf, 2023, diakses 1 Oktober 2026.

[2] Menteri Keuangan Republik Indonesia, "Peraturan Menteri Keuangan Nomor 168 Tahun 2023 tentang Petunjuk Pelaksanaan Pemotongan Pajak atas Penghasilan Sehubungan dengan Pekerjaan, Jasa, atau Kegiatan Orang Pribadi," https://peraturan.bpk.go.id/Download/346093/2023pmkeuangan168.pdf, 2023, diakses 1 Oktober 2026.

[3] E. N. Ramadhani, W. Wiranto, and M. K. Giffary, "Perancangan sistem perhitungan pajak penghasilan berbasis web dengan metode gross up," *Riset dan E-Jurnal Manajemen Informatika Komputer (REMIK)*, vol. 6, no. 1, pp. 16–23, 2021, doi: 10.33395/remik.v6i1.11180.

[4] M. J. A. B. Kusuma, D. Armeliza, and T. E. Jaya, "Perancangan sistem terintegrasi untuk otomatisasi perhitungan PPh Pasal 21," *Jurnal Akuntansi, Perpajakan dan Auditing*, vol. 7, no. 1, pp. 85–96, 2026, doi: 10.21009/japa.0701.07.

[5] D. Merigoux, N. Chataing, and J. Protzenko, "Catala: A programming language for the law," *Proceedings of the ACM on Programming Languages*, vol. 5, no. ICFP, pp. 1–29, 2021, doi: 10.1145/3473582.

[6] S. Janatian, H. Westermann, J. Tan, J. Savelka, and K. Benyekhlef, "From text to structure: Using large language models to support the development of legal expert systems," in *Legal Knowledge and Information Systems (JURIX 2023)*, ser. Frontiers in Artificial Intelligence and Applications, vol. 379. IOS Press, 2023, doi: 10.3233/faia230962.

[7] J. J. Nay *et al.*, "Large language models as tax attorneys: a case study in legal capabilities emergence," *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, vol. 382, no. 2270, p. 20230159, 2024, doi: 10.1098/rsta.2023.0159.

[8] M. Dahl, V. Magesh, M. Suzgun, and D. E. Ho, "Large legal fictions: Profiling legal hallucinations in large language models," *Journal of Legal Analysis*, vol. 16, no. 1, pp. 64–93, 2024, doi: 10.1093/jla/laae003.

[9] Republik Indonesia, "Undang-Undang Nomor 7 Tahun 2021 tentang Harmonisasi Peraturan Perpajakan," https://peraturan.bpk.go.id/Download/178620/UU%20Nomor%207%20Tahun%202021.pdf, 2021, diakses 1 Oktober 2026.

[10] Menteri Keuangan Republik Indonesia, "Peraturan Menteri Keuangan Nomor 101/PMK.010/2016 tentang Penyesuaian Besarnya Penghasilan Tidak Kena Pajak," https://peraturan.bpk.go.id/Download/111866/PMK%20Nomor%20101%20Tahun%202016.pdf, 2016, diakses 1 Oktober 2026.

[11] Direktur Jenderal Pajak, "Peraturan Direktur Jenderal Pajak Nomor PER-16/PJ/2016 tentang Pedoman Teknis Tata Cara Pemotongan, Penyetoran dan Pelaporan Pajak Penghasilan Pasal 21 dan/atau Pajak Penghasilan Pasal 26 Sehubungan dengan Pekerjaan, Jasa, dan Kegiatan Orang Pribadi," 2016, salinan pindaian; diakses 1 Oktober 2026.

[12] Menteri Keuangan Republik Indonesia, "Peraturan Menteri Keuangan Nomor 10 Tahun 2025 tentang Pajak Penghasilan Pasal 21 atas Penghasilan Tertentu yang Ditanggung Pemerintah dalam rangka Stimulus Ekonomi Tahun Anggaran 2025," https://peraturan.bpk.go.id/Download/374407/2025pmkeuangan10.pdf, 2025, diakses 1 Oktober 2026.

[13] ——, "Peraturan Menteri Keuangan Nomor 105 Tahun 2025 tentang Pajak Penghasilan Pasal 21 atas Penghasilan Tertentu yang Ditanggung Pemerintah Tahun Anggaran 2026," https://peraturan.bpk.go.id/Download/404917/2025pmkeuangan105.pdf, 2025, diakses 1 Oktober 2026.

[14] A. Mowbray, P. Chung, and G. Greenleaf, "Representing legislative rules as code: Reducing the problems of 'scaling up'," *Computer Law & Security Review*, vol. 48, p. 105772, 2023, doi: 10.1016/j.clsr.2022.105772.

[15] P. Compton and B. H. Kang, *Ripple-Down Rules: The Alternative to Machine Learning*, 1st ed. Boca Raton: Chapman and Hall/CRC, 2021, doi: 10.1201/9781003126157.

[16] K. Veeramani, A. Joseph N, and P. M, "Neuro-symbolic reasoning engine for tax optimisation," *Frontiers in Artificial Intelligence*, vol. 9, May 2026, art. no. 1802755, doi: 10.3389/frai.2026.1802755.

[17] B. Yadamsuren, S. K. Platt, and M. Diaz, "LLM-assisted formalization for deterministic detection of statutory inconsistency in tax law," *Artificial Intelligence and Law*, Jul. 2026, doi: 10.1007/s10506-026-09525-6.

[18] G. Lorenzo, A. Pietromatera, and N. Holzenberger, "Translating tax law to code with LLMs: A benchmark and evaluation framework," in *Proceedings of the Natural Legal Language Processing Workshop 2025*.

Suzhou, China: Association for Computational Linguistics, 2025, pp. 31–47, doi: 10.18653/v1/2025.nllp-1.4.

[19] W. Jurayj, N. Holzenberger, and B. Van Durme, "Language models and logic programs for trustworthy tax reasoning," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 40, no. 45, 2026, pp. 38 688–38 698, doi: 10.1609/aaai.v40i45.41212.

[20] S. Gogani-Khiabani, V. Dewangan, N. Olson, A. Trivedi, and S. Tizpaz-Niari, "Technical challenges in maintaining tax prep software with large language models," arXiv preprint arXiv:2504.18693, 2025, doi: 10.48550/arXiv.2504.18693.

[21] A. Gupta, A. Rao, and G. Anumanchipalli, "Model editing at scale leads to gradual and catastrophic forgetting," in *Findings of the Association for Computational Linguistics ACL 2024*. Association for Computational Linguistics, 2024, pp. 15 202–15 232, doi: 10.18653/v1/2024.findings-acl.902.

[22] J. Seo *et al.*, "KoLEG: On-the-fly Korean legal knowledge editing with continuous retrieval," in *Findings of the Association for Computational Linguistics: EMNLP 2025*. Suzhou, China: Association for Computational Linguistics, 2025, pp. 9191–9217, doi: 10.18653/v1/2025.findings-emnlp.489.

[23] M. Prior, A. Hof, N. Wais, and M. Grabmair, "Risks and limits of automatic consolidation of statutes," in *Proceedings of the Natural Legal Language Processing Workshop 2025*. Suzhou, China: Association for Computational Linguistics, 2025, pp. 396–407, doi: 10.18653/v1/2025.nllp-1.29.

[24] M. Chen *et al.*, "Evaluating large language models trained on code," arXiv preprint arXiv:2107.03374, 2021, doi: 10.48550/arXiv.2107.03374.

[25] Y. Li *et al.*, "Competition-level code generation with AlphaCode," *Science*, vol. 378, no. 6624, pp. 1092–1097, 2022, doi: 10.1126/science.abq1158.

[26] J. Xin, R. Tang, Y. Yu, and J. Lin, "The art of abstention: Selective prediction and error regularization for natural language processing," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics, 2021, pp. 1040–1051, doi: 10.18653/v1/2021.acl-long.84.

[27] H. Knublauch and D. Kontokostas, "Shapes constraint language (SHACL)," W3C Recommendation, https://www.w3.org/TR/2017/REC-shacl-20170720/, Jul. 2017.

[28] Publications Office of the European Union, "ELI ontology (European Legislation Identifier), version V1.5," EU Vocabularies, https://op.europa.eu/en/web/eu-vocabularies/eli, 2026, diakses 27 Oktober 2026.

[29] S. Cox and C. Little, "Time ontology in OWL," W3C Recommendation, https://www.w3.org/TR/2017/REC-owl-time-20171019/, Oct. 2017.

[30] T. Lebo, S. Sahoo, and D. McGuinness, "PROV-O: The PROV ontology," W3C Recommendation, https://www.w3.org/TR/2013/REC-prov-o-20130430/, Apr. 2013.

[31] L. Enqvist, "'Human oversight' in the EU artificial intelligence act: what, when and by whom?" *Law, Innovation and Technology*, vol. 15, no. 2, pp. 508–535, 2023, doi: 10.1080/17579961.2023.2245683.

[32] A. Witt, A. Huggins, G. Governatori, and J. Buckley, "Encoding legislation: a methodology for enhancing technical validation, legal alignment and interdisciplinarity," *Artificial Intelligence and Law*, vol. 32, no. 2, pp. 293–324, 2024, doi: 10.1007/s10506-023-09350-1.