Knowledge-Based System Adaptif untuk Perhitungan PPh 21 dengan Akuisisi Pengetahuan Berbantuan LLM dari Regulasi dan Kebijakan Perusahaan

[Nama Penulis]

***Abstrak*—[Satu paragraf berisi 150–250 kata, tanpa rumus, tabel, atau rujukan. Urutan kalimatnya sebagai berikut. Masalahnya, perhitungan PPh 21 harus mengikuti perubahan regulasi dan kebijakan perusahaan, tetapi aturannya tertanam di kode, sehingga setiap perubahan menuntut pemrograman ulang. Celahnya, formalisasi hukum pajak berbantuan LLM yang ada membangun basis aturan dari nol untuk keadaan hukum pada satu waktu, sehingga belum diketahui apakah pembaruan berulang menjaga hasil periode lama dan apakah kesalahan merambat dari satu perubahan ke perubahan berikutnya. Usulannya adalah *knowledge-based system* dengan representasi temporal dua lapis dan akuisisi pengetahuan inkremental berbantuan LLM yang dijaga gerbang verifikasi. Evaluasinya memutar ulang seluruh perubahan regulasi PPh 21 yang nyata, menguji perubahan yang belum pernah dilihat perancang, dan membandingkan usulan dengan pembanding. Abstrak ditutup dengan hasil metrik utama beserta selang kepercayaannya, lalu implikasinya.]**

Kata Kunci*—Akuisisi pengetahuan, *knowledge-based system*, *knowledge graph*, *large language model*, perubahan regulasi, PPh Pasal 21, *rules as code

CARA MEMAKAI KERANGKA INI

Alur kerja
1) Tetapkan definisi di Bagian II, IV, dan V. Semua eksperimen bergantung pada definisi ini.
2) Daftarkan rancangan evaluasi (Bagian VI) ke layanan pra-registrasi pihak ketiga sebelum menjalankan eksperimen pada data uji.
3) Validasi instrumen ukur (Bagian VI-D) sebelum mengukur sistem.
4) Bangun dan uji sesuai daftar di Bagian X.
5) Isi Hasil dan Pembahasan dari keluaran eksperimen. Laporkan hipotesis yang terbantah sebagai terbantah.

Sistem yang sudah ada diperlakukan sebagai prototipe. Bagian yang sesuai dengan definisi di kerangka ini dipakai, dan bagian yang tidak sesuai diubah.

I. PENDAHULUAN

Tujuan
Dalam $\pm$1,5 halaman, pendahuluan harus meyakinkan pembaca bahwa masalahnya nyata dan terukur, bahwa solusi yang ada belum cukup, dan bahwa penelitian ini menjawab celah yang spesifik. Pendahuluan berakhir dengan RQ dan kontribusi yang persis sama dengan yang dievaluasi di Bagian VI.

PARAGRAF 1, konteks. [PPh 21 dipotong setiap bulan dari penghasilan pegawai, sehingga kesalahan perhitungan memengaruhi setiap slip gaji. Regulasinya sering berubah. Perubahannya berupa nilai parameter, klasifikasi penghasilan, dan pada 2024 pergantian metode perhitungan.]

Klaim & bukti
Klaim *sering berubah* harus didukung angka, yaitu jumlah peristiwa perubahan per tahun yang memengaruhi PPh 21 pegawai tetap beserta jenisnya. Angka ini diambil dari korpus perubahan (Tabel V). Bila tersedia, tambahkan bukti biaya perubahan pada praktik saat ini dari pembanding B1.

Paragraf 2, masalah. [Aturan pajak dan kebijakan payroll tertanam bercampur di kode atau *spreadsheet*. Akibatnya ada tiga masalah. Setiap perubahan regulasi menuntut pemrograman ulang. Tidak ada bukti bahwa perubahan itu tidak menggeser hasil periode lama. Kebijakan perusahaan yang menjadi melanggar setelah regulasi berubah tidak terdeteksi.]

LLM membaca dokumen regulasi atau kebijakan dan menyusun m kandidat pembaruan. Gerbang verifikasi, termasuk gerbang non-vakuitas, menyaring kandidat. Sistem memilih kandidat lewat konsensus, atau *abstain*. Pembaruan terpilih masuk ke *knowledge base* temporal dua lapis, lalu *inference engine* menghitung hasil beserta jejak sampai pasal. Laporan dampak lintas lapis dikirim ke peninjau.

Gambar 1. Ikhtisar sistem yang diusulkan.

Paragraf 3, mengapa KBS dan mengapa belum cukup. [*Knowledge-based system* memisahkan pengetahuan dari kode, tetapi memindahkan beban ke pemeliharaan *knowledge base*, yang dikenal sebagai *knowledge acquisition bottleneck*. Metode akuisisi inkremental seperti *Ripple-Down Rules* sudah lama ada, tetapi tetap membutuhkan pakar manusia untuk setiap perubahan.]

Paragraf 4, LLM dan celahnya. [LLM dapat menerjemahkan teks hukum menjadi aturan, tetapi tidak andal untuk perhitungan yang menuntut ketepatan dan sering salah memilih versi hukum yang berlaku. Penelitian formalisasi pajak berbantuan LLM membangun basis aturan dari nol untuk keadaan hukum pada satu waktu. Penelitian penyuntingan pengetahuan LLM menunjukkan bahwa suntingan berulang dapat merusak pengetahuan lama. Belum ada penelitian yang mengukur tiga hal pada basis aturan yang dieksekusi: apakah pembaruan berulang dari LLM menjaga hasil periode lama, apakah kesalahan merambat dari satu perubahan ke perubahan berikutnya, dan bagaimana dampaknya terhadap lapisan kebijakan perusahaan.]

Paragraf 5, pendekatan. [Ringkasan usulan dalam 3–4 kalimat, dengan merujuk Gambar 1.]

Paragraf 6, pertanyaan penelitian.

RQ1 **Adaptivitas representasi.** Sejauh mana representasi pengetahuan temporal dua lapis dapat menyatakan perubahan regulasi dan kebijakan, termasuk jenis perubahan yang tidak diketahui saat representasi dirancang, tanpa mengubah kode *engine*?

RQ2 **Akuisisi satu langkah.** Seberapa sering akuisisi berbantuan LLM menerapkan pembaruan yang benar, seberapa sering ia menerapkan pembaruan salah tanpa terdeteksi, dan berapa besar peran gerbang verifikasi pada kedua

Tabel I
DIMENSI PERHITUNGAN PPH 21 PEGAWAI TETAP YANG DICAKUP

Dimensi	Nilai
Rezim	Disetahunkan (sampai 2023); TER (sejak 2024); TER dengan fasilitas DTP
Lapisan Pasal 17	5%, 15%, 25%, 30%, 35% (4 lapisan sebelum UU HPP)
Kategori TER	A, B, C dengan lapisan tarif bulanan [jumlah per kategori, diverifikasi dari lampiran PP 58/2023]
Status PTKP	TK/0–TK/3, K/0–K/3; menentukan kategori TER
Metode	*Gross*, *gross-up*, ditanggung pemberi kerja
Pola kerja	Setahun penuh, masuk di tengah tahun, keluar di tengah tahun
Penghasilan	Teratur, tidak teratur (THR, bonus)

angka itu?

RQ3 **Adaptivitas operasional berantai.** Pada rangkaian perubahan regulasi yang nyata, berapa peristiwa yang berhasil diterapkan otomatis, dan apakah kesalahan merambat dari satu peristiwa ke peristiwa berikutnya?

RQ4 **Dampak lintas lapis.** Seberapa lengkap dan tepat sistem mengidentifikasi kebijakan perusahaan yang terdampak atau menjadi melanggar setelah regulasi berubah?

Paragraf 7, kontribusi.

K1 Representasi pengetahuan temporal dua lapis untuk perhitungan pajak penghasilan pegawai, dengan resolusi konflik antarlapis dan analisis dampak lintas lapis (RQ1, RQ4).

K2 Metode akuisisi pengetahuan inkremental berbantuan LLM dengan gerbang verifikasi, gerbang non-vakuitas, dan pemilihan kandidat berbasis konsensus perilaku (RQ2).

K3 Definisi adaptivitas representasional dan operasional, serta protokol *regulation replay* yang memisahkan kesalahan bawaan, kesalahan baru, dan kesalahan yang dipicu perambatan, beserta bukti empiris pada rangkaian perubahan PPh 21 yang nyata (RQ3).

K4 Artefak terbuka berupa *knowledge base*, korpus perubahan beserta pembaruan emas, *test suite* dengan *ground truth*, dan kode evaluasi.

Klaim & bukti
Tabel VII menghubungkan setiap kontribusi dengan RQ dan metrik utamanya. Kontribusi yang tidak punya bukti di Bagian VII dihapus.

Paragraf 8, organisasi. [Satu kalimat per bagian.]

II. LATAR BELAKANG DAN RUMUSAN MASALAH

Tujuan
Memberi pembaca dari luar Indonesia pengetahuan domain secukupnya untuk memahami mengapa perubahan PPh 21 sulit diikuti, lalu merumuskan masalahnya secara formal.

A. Perhitungan PPh 21 pegawai tetap

[Ringkasan struktur perhitungan, yaitu penghasilan bruto, pengurang, PTKP, tarif Pasal 17, tarif efektif rata-rata (TER) bulanan, dan perhitungan ulang di masa pajak terakhir. Tabel I merangkum dimensi yang menentukan besarnya pajak.]

Harus didefinisikan
Batas ruang lingkup beserta alasannya, dan batasan antardimensi. Contohnya, status PTKP menentukan kategori TER, dan DTP hanya ada sejak 2025. Ruang uji (Bagian VI-E) dibangun dari dimensi dan batasan ini.

B. Kebijakan perusahaan dan batas kewenangannya

[Perusahaan menentukan komponen penghasilan seperti prorata, THR, tunjangan, dan perlakuan iuran, tetapi tidak boleh menyimpangi ketentuan wajib seperti klasifikasi jenis penghasilan. Sertakan satu contoh konflik konkret.]

C. Jenis perubahan regulasi

Harus didefinisikan
Taksonomi jenis perubahan, minimal parameter, tabel tarif, klasifikasi, aturan atau fasilitas baru, pergantian metode perhitungan, pencabutan, regulasi berlaku surut, dan perubahan kebijakan perusahaan. Taksonomi ini dipakai untuk menyusun korpus dan melaporkan hasil per jenis. Saat melaporkan tingkat keberhasilan, jenis yang mudah seperti parameter tidak boleh digabung dengan jenis struktural.

D. Rumusan masalah

[Masukannya adalah sistem yang benar untuk keadaan hukum sebelum suatu perubahan, beserta dokumen perubahan itu. Keluarannya adalah sistem yang benar untuk keadaan hukum sesudahnya, tanpa perubahan kode dan tanpa perubahan pada hasil yang tidak seharusnya berubah. Definisi formalnya ada di Bagian V-A.]

III. PENELITIAN TERKAIT

Tujuan
Menunjukkan bahwa celah di Pendahuluan memang ada. Setiap subbagian diakhiri satu kalimat tentang apa yang belum dikerjakan kelompok penelitian itu dan bagaimana penelitian ini berbeda.

A. Rules as code dan formalisasi peraturan pajak

[Catala, DataLex, Logical English, OpenFisca, dan formalisasi payroll [1]–[4] [rujukan: OpenFisca]. Celahnya, pengetahuan ditulis manusia. Parameter berversi sudah ada, tetapi pembaruan oleh mesin belum dievaluasi.]

B. Akuisisi pengetahuan inkremental

[*Ripple-Down Rules* dengan *cornerstone case* sebagai pengaman regresi [rujukan: Compton & Jansen]; perubahan hukum, abrogasi, dan anulasi dalam *defeasible logic* temporal [rujukan: Governatori & Rotolo]; revisi teori hukum [5], [6]. Gerbang regresi dalam penelitian ini setara dengan *cornerstone case*. Celahnya, pakar manusia tetap menulis setiap perubahan.]

C. LLM untuk formalisasi hukum dan pajak

[Ini kelompok karya terdekat. LLM menerjemahkan teks hukum ke Catala, Prolog, DMN, *knowledge graph* pajak, dan program dari formulir pajak [7], [8] [rujukan: NTOL 2026; formalisasi IRC 2026; LLM ke Catala NLLP 2025; Graus ICAIL 2026]. Celahnya, semua karya ini memformalkan dari nol untuk keadaan hukum pada satu waktu.]

D. Pembaruan berulang oleh LLM dan evaluasinya

[Penyuntingan pengetahuan LLM secara berurutan dan kerusakannya setelah banyak suntingan [rujukan: *sequential knowledge editing*]; pembaruan kode terhadap perubahan API [rujukan: CodeUpdateArena]; evaluasi berbasis eksekusi *pass@k* dan *n@k* [rujukan: Chen 2021; AlphaCode]; prediksi selektif

dan kurva risiko–cakupan [rujukan: Geifman & El-Yaniv]. Kelompok ini menjadi dasar metrik RQ2 dan RQ3. Celahnya, metrik tersebut belum diterapkan pada basis aturan hukum yang dieksekusi dan berversi waktu.]

E. Representasi temporal dan knowledge graph hukum

[*Knowledge graph* norma berversi [9]; standar ELI, OWL-Time, PROV-O, dan LegalRuleML [rujukan: standar]; LLM dan penalaran hukum temporal [rujukan: benchmark temporal 2026].]

F. Konflik norma, verifikasi knowledge base, dan pengujian perangkat lunak pajak

[Deteksi konflik norma [10], [11]; anomali *rule base* [12]; sulitnya menentukan acuan kebenaran dalam pengujian perangkat lunak pajak, dan *mutation analysis* [13], [14]. Penelitian ini memakai karya-karya tersebut sebagai dasar rancangan *ground truth*, bukan sebagai kontribusi.]

Keputusan terbuka
(1) Beberapa karya terdekat dari 2026 masih berupa *preprint*. Apakah dikutip sebagai *preprint*, atau tidak dikutip? (2) Karya terdekat harus dibaca utuh sebelum Tabel II diisi.

IV. Representasi pengetahuan dan *inference engine*

Tujuan
Menjawab secara formal pertanyaan dosen tentang representasi final *knowledge base*. Bagian ini menjadi dasar K1.

A. Model pengetahuan

[Pengetahuan struktural, yaitu regulasi, pasal, konsep, kebijakan, relasi amandemen, dan relasi konflik, disimpan sebagai *knowledge graph*. Pengetahuan komputasional berupa ekspresi perhitungan disimpan sebagai atribut aturan, dan *inference engine* yang menjalankannya. Jelaskan alasan pembagian ini.]

Definisi 1 (*Knowledge base*). *[$\mathcal{K} = \langle \mathcal{O}, \mathcal{R}, \mathcal{P}, \mathcal{T} \rangle$ terdiri atas ontologi konsep, himpunan aturan, parameter berversi, dan tabel. Setiap unsur berada pada lapisan $\ell \in \{reg, prs\}$.]*

Definisi 2 (Aturan). *[$r = \langle id, \ell, \sigma, [t_s, t_e], t_c, \varphi, f := e, src \rangle$ memuat identitas, lapisan, sifat σ (wajib, default, atau opsional), masa berlaku, tanggal pencatatan t_c, kondisi, fakta yang dihasilkan beserta ekspresinya, dan sumber hukum.]*

Definisi 3 (Hasil perhitungan). *[$hasil(\mathcal{K}, x, t, \omega)$ adalah nilai fakta keluaran untuk kasus x pada masa pajak t, yang dihitung dengan knowledge base sebagaimana diketahui pada tanggal ω. Fakta keluaran utama adalah PPh 21 yang dipotong per pegawai per masa. Fakta pendukung seperti PPh setahun, bruto, PKP, dan take home pay ditetapkan di sini.]*

Harus didefinisikan
- Kelas, relasi, dan standar yang dipakai ulang dalam ontologi (Gambar 2).
- Fungsi yang diizinkan dalam bahasa ekspresi beserta sistem tipenya. Batasan ini juga membatasi keluaran LLM.
- Semantik temporal, yaitu arti $[t_s, t_e]$ dan t_c serta sumbu waktu yang menentukan aturan mana yang berlaku pada suatu masa.
- Bentuk kanonik unsur, yaitu normalisasi aturan agar unsur dapat dicocokkan pada metrik diagnostik.
- Batas ekspresivitas, yaitu jenis ketentuan yang sengaja tidak dapat dinyatakan.

Kelas ontologi: Regulasi, Pasal, Aturan, Konsep (jenis penghasilan dan kategori pajak), Parameter, Tabel, Kebijakan Perusahaan, dan Versi. Relasinya: memuat, bersumber, mengubah, mencabut, menghasilkan, membaca, dan berkonflik.

Gambar 2. Ontologi *knowledge base*.

Algoritma 1 Inferensi untuk satu pegawai dan satu tahun pajak

Require: $\mathcal{K}$, data pegawai, tanggal pengetahuan ω
1: [seleksi aturan yang berlaku]
2: [bangun graf dependensi, lalu urutkan]
3: [evaluasi, resolusi konflik, dan penyelesaian definisi melingkar]
4: [keluarkan nilai dan jejak]

B. Resolusi konflik antarlapis

[Bila lebih dari satu aturan menghasilkan fakta yang sama pada waktu yang sama, *engine* memilih satu aturan berdasarkan relasi superioritas yang diturunkan dari asas *lex superior*, *lex specialis*, dan *lex posterior*. *Engine* selalu mencatat konflik antara aturan wajib dan kebijakan perusahaan.]

Harus didefinisikan
Relasi superioritas secara formal, ukuran *lebih spesifik* untuk *lex specialis*, dan perilaku *engine* bila tidak ada pemenang tunggal.

Keputusan terbuka
Apakah ukuran *lex specialis* dihitung dari sintaks kondisi, atau dari relasi superioritas eksplisit antaraturan?

C. Inference engine

[Langkahnya adalah seleksi aturan menurut waktu, pembentukan graf dependensi fakta, penentuan urutan evaluasi, resolusi konflik, penyelesaian definisi melingkar, dan pembentukan jejak penjelasan sampai sumber hukum (Algoritma 1). Jelaskan aritmetika eksak dan aturan pembulatan sebagai syarat ketepatan.]

V. Akuisisi pengetahuan inkremental berbantuan LLM

Tujuan
Mendefinisikan pembaruan dan adaptivitas secara operasional, lalu menjelaskan metode yang menjaganya. Bagian ini menjadi dasar K2 dan K3.

A. Pembaruan dan adaptivitas

Definisi 4 (Peristiwa perubahan). *[$\epsilon = \langle d, t_{terbit}, t_{berlaku}, \tau \rangle$ terdiri atas dokumen sumber, tanggal terbit, tanggal mulai berlaku, dan jenis perubahan. Sebuah regulasi berlaku surut bila $t_{berlaku} < t_{terbit}$. Rangkaian $\epsilon_1, \ldots, \epsilon_N$ diurutkan menurut t_{terbit}.]*

Definisi 5 (Pembaruan). *[$\Delta = \langle \Delta^+, \Delta^\sim, \Delta^- \rangle$ berisi unsur yang ditambah, diubah, dan dicabut, dengan $\mathcal{K}' = \mathcal{K} \oplus \Delta$. Pembaruan emas memenuhi $\mathcal{K}^\star_n = \mathcal{K}^\star_{n-1} \oplus \Delta^\star_n$.]*

Definisi 6 (Syarat adaptif). *[Untuk $\mathcal{K}' = \mathcal{K} \oplus \Delta$ dan himpunan kasus S:*

Tabel II
POSISI PENELITIAN TERHADAP KARYA TERKAIT

Karya	Domain	Representasi	Penyusun pengetahuan	Pembaruan inkremental	Perambatan kesalahan diukur	Lapisan perusahaan	Evaluasi
[karya 1] […]							
Penelitian ini	PPh 21	*knowledge graph* temporal dua lapis dan aturan yang dapat dieksekusi	LLM dengan gerbang	ya	ya	ya	*regulation replay*

(A1) Invariansi kode. Kode engine tidak berubah.
(A2) Kesesuaian. $hasil(\mathcal{K}', x, t, \omega) = hasil(\mathcal{K}^\star, x, t, \omega)$ *untuk* $x \in S$, $t \geq t_{berlaku}$, *dan* $\omega \geq t_{terbit}$.
(A3$_t$) Isolasi masa. Hasil untuk $t < t_{berlaku}$ *tidak berubah, untuk semua* ω.
(A3$_\omega$) Isolasi pengetahuan. Hasil untuk $\omega < t_{terbit}$ *tidak berubah.*
(A4) Konsistensi lintas lapis. Setiap kebijakan yang berkonflik dengan aturan wajib di $\mathcal{K}'$ *dilaporkan.]*

Definisi 7 (Adaptivitas representasional)**.** *[Representasi adaptif terhadap* ϵ *bila* ada Δ *dalam bahasa representasi yang memenuhi A1–A4. Ini sifat representasi, dan peneliti membuktikannya dengan menyusun* $\Delta^\star$ *(RQ1).]*

Definisi 8 (Adaptivitas operasional)**.** *[Sistem adaptif secara operasional terhadap* ϵ *bila pembaruan* $\hat{\Delta}$ *yang* dipilih alur akuisisi *memenuhi A2, A3$_t$, dan A4 pada* S^E*. Ini sifat alur akuisisi, dan diukur sebagai laju atas peristiwa (RQ2, RQ3).]*

Klaim & bukti
A1 berlaku karena arsitekturnya, sebab LLM hanya menyunting *knowledge base*. A3$_\omega$ berlaku karena konstruksi bila $t_c = t_{terbit}$. Karena itu peneliti memeriksa keduanya sebagai invarian, bukan mengujinya sebagai hipotesis. Syarat yang bergantung pada LLM, yaitu A2, A3$_t$, dan A4, yang diuji.

Harus didefinisikan
Semantik berlaku surut menurut mekanisme hukumnya. Contohnya, fasilitas DTP yang terbit sesudah masa yang dicakupnya diselesaikan lewat pengembalian atau perhitungan ulang di masa pajak terakhir, bukan dengan menghitung ulang potongan bulan yang sudah lewat. Nilai *sebagaimana seharusnya* untuk $t < t_{terbit}$ harus mengikuti mekanisme itu. Tanpa definisi ini, *ground truth* untuk peristiwa berlaku surut tidak terdefinisi.

B. Alur akuisisi

[Gambar 3 menunjukkan delapan tahap. (1) Sistem memotong dokumen per pasal. (2) LLM menilai relevansi, yaitu apakah dokumen mengubah perhitungan PPh 21 pegawai tetap, dan menyertakan kutipan teks pendukung. Bila dokumen dinilai tidak relevan dan kutipannya lolos G2, sistem menerapkan pembaruan kosong dan berhenti. (3) Sistem menyusun konteks dari bagian *knowledge base* yang relevan. (4) LLM menyusun m kandidat Δ secara independen, dan setiap unsur disertai kutipan sumber. (5) Setiap kandidat melewati gerbang, dengan putaran perbaikan berdasarkan umpan balik gerbang. (6) Sistem mengelompokkan kandidat yang lolos menurut hasilnya pada S^G dan memilih wakil kelompok terbesar, yang disebut konsensus perilaku. Bila tidak ada kandidat yang lolos, sistem *abstain* dan meminta peninjauan manusia. (7) Peninjau manusia memeriksa pembaruan dengan bantuan laporan dampak. (8) Pembaruan berlaku sebagai versi baru *knowledge base*.]

Dokumen masuk ke penilaian relevansi. Dokumen yang tidak relevan menghasilkan pembaruan kosong. Untuk dokumen yang relevan, sistem menyusun konteks, lalu LLM menyusun m kandidat. Kandidat melewati G1–G5, dan kandidat yang gagal mendapat umpan balik. Sistem memilih lewat konsensus perilaku, atau *abstain*. Peninjau memeriksa dengan laporan dampak, dan pembaruan menghasilkan $\mathcal{K}'$.

Gambar 3. Alur akuisisi pengetahuan inkremental.

Tabel III
GERBANG VERIFIKASI DAN SYARAT YANG DIJAGANYA

ID	Pemeriksaan	Syarat
G1	Struktur dan batasan graf (*shape constraint*)	validitas
G2	Kutipan sumber ada di dokumen	keberadaan kutipan
G3	Konsistensi statis atas tipe, dependensi, konflik, dan anomali	A4
G4	Regresi pada S^G. Hasil sebelum $t_{berlaku}$ tidak berubah	A3$_t$
G5	Non-vakuitas, hanya untuk Δ yang tidak kosong. Setiap unsur yang ditambah atau diubah harus mengubah minimal satu fakta keluaran pada kasus S^G sesudah $t_{berlaku}$, termasuk fakta selain PPh 21. Setiap unsur yang dicabut tidak lagi menyala. Tanggal dan subjek yang disebut dokumen harus tercermin	menolak pembaruan tanpa efek

Keputusan terbuka
Tabel tarif di lampiran regulasi bisa berisi ratusan baris, misalnya tarif TER. Apakah LLM menyalinnya sendiri, atau boleh memanggil alat ekstraksi tabel PDF yang deterministik? Usulannya, alat diizinkan dan dicatat di pra-registrasi. Cara ini realistis dan memisahkan kemampuan memahami aturan dari kemampuan menyalin angka.

C. Gerbang verifikasi

Klaim & bukti
Tanpa G5, pembaruan kosong atau aturan yang tidak pernah menyala lolos semua gerbang, karena keduanya tidak menimbulkan regresi. Putaran perbaikan yang hanya menerima umpan balik regresi malah mendorong kandidat ke arah itu. G5 menutup celah ini. Pembaruan kosong hanya dapat diterapkan lewat penilaian relevansi yang berkutipan, sehingga G5 tidak bertentangan dengan dokumen pengecoh.

Harus didefinisikan
(1) Daftar *constraint* G1. (2) Cara G2 mencocokkan kutipan. (3) Cara membangkitkan S^G secara otomatis. Generatornya membangkitkan kasus dari $\mathcal{K}_{n-1} \oplus \hat{\Delta}$ dengan menyasar kondisi φ setiap unsur yang berubah, sehingga pengetahuan manusia tentang dokumen tidak bocor ke alur. S^G dan S^E tidak boleh beririsan. (4) Nilai m dan batas putaran perbaikan. (5) Cara mengelompokkan kandidat menurut hasilnya pada S^G. (6) Syarat pembekuan. G5 harus menerima $\Delta^\star$ dari seluruh peristiwa pengembangan, artinya laju penolakan kelirunya nol.

D. Analisis dampak lintas lapis

[Diberikan Δ, sistem menelusuri graf secara statis untuk menemukan kebijakan perusahaan yang terdampak, termasuk kebijakan yang menjadi berkonflik dengan aturan wajib.]

Harus didefinisikan
Arti *terdampak*, dengan tiga jenis: (a) nilai fakta keluaran berubah untuk minimal satu kasus, (b) aturan pemenang berubah, dan (c) kebijakan menjadi berkonflik dengan aturan wajib. Label (a) dan (b) diturunkan dari eksekusi $\mathcal{K}^\star$ pada S^E, sedangkan detektor bekerja statis pada graf. Karena sumbernya berbeda, label tidak tautologis.

E. Konfigurasi LLM

[Catat model dan versinya, tanggal akses dan *training cutoff*, parameter pembangkitan, format keluaran terstruktur, isi *prompt*, serta seluruh masukan dan keluaran.]

VI. Metodologi Evaluasi

Tujuan
Evaluasi memakai lima prinsip. (1) Setiap RQ punya satu metrik utama yang ditetapkan sebelum eksperimen. (2) Kebenaran diukur dari perilaku hasil perhitungan, bukan dari kemiripan bentuk aturan. (3) Data yang dipakai sistem selalu terpisah dari data yang dipakai untuk menilainya. (4) Alat ukur divalidasi sebelum dipakai mengukur sistem. (5) Jumlah peristiwa nyata kecil, sehingga hasil dilaporkan sebagai estimasi dengan selang kepercayaan eksak, bukan sebagai keputusan signifikan atau tidak. Bagian ini menjawab feedback no. 3, 4, dan 5.

A. Desain penelitian dan pra-registrasi

[Penelitian ini mengikuti *design science research*. Sebelum eksperimen, peneliti mendaftarkan hipotesis, metrik utama, ambang, pembagian data, kasus uji evaluasi, dan rencana analisis ke layanan pra-registrasi pihak ketiga yang memberi stempel waktu [rujukan: OSF atau AsPredicted], lalu menautkannya dengan git *tag*. Analisis terdiri atas tiga jenis. Pemeriksaan invarian mencakup A1 dan A3$_\omega$, dan pelanggarannya harus nol. Analisis konfirmatori memakai metrik utama untuk menguji hipotesis. Analisis eksploratori memakai metrik diagnostik.]

B. Pembagian data dan kronologi

[

- **Pengembangan.** Regulasi fiktif dan perubahan historis sebelum rentang penelitian, misalnya perubahan PTKP dan lapisan Pasal 17 sebelum 2023. Peneliti memakainya untuk merancang *prompt*, gerbang, dan aturan pemilihan, lalu membekukan ketiganya.
- **Uji.** Seluruh peristiwa nyata dalam rentang penelitian, termasuk pergantian ke TER. Peneliti tidak melihat peristiwa uji selama mengembangkan alur LLM, yaitu *prompt*, gerbang, dan aturan pemilihan. Representasi, *engine*, dan $\mathcal{K}^\star$ memang disusun dengan mengetahui peristiwa ini, dan akibatnya ditangani di Bagian VI-C.
- **Uji prospektif.** Setiap regulasi PPh 21 yang terbit sesudah tanggal pra-registrasi. Peristiwa ini bebas kontaminasi data latih LLM dan tidak pernah dilihat perancang.

]

C. Bias pandangan belakang

[Representasi dan *engine* dikembangkan ketika perubahan dalam rentang penelitian sudah diketahui, sehingga klaim *tanpa mengubah kode* untuk peristiwa itu lemah. Ada tiga mitigasi. Pertama, peneliti mempublikasikan riwayat pengembangan *engine* dan menghitung setiap perubahan *engine* yang dipicu suatu regulasi sebagai pelanggaran A1 pada representasi. Kedua, orang lain menulis perubahan struktural sintetis dari taksonomi perubahan, yang disebut perubahan tak terlihat, untuk diuji di RQ1. Ketiga, penelitian ini memakai peristiwa uji prospektif.
Untuk perubahan tak terlihat, penulisnya menyerahkan teks perubahan beserta 5–10 contoh perhitungan yang sudah dihitung, sebelum peneliti melihatnya. Perubahan itu dihitung berhasil (RA $= 1$) hanya bila Δ yang disusun peneliti mereproduksi seluruh contoh tanpa mengubah *engine*, dalam batas waktu yang ditetapkan. Dengan cara ini peneliti tidak menilai pekerjaannya sendiri.]

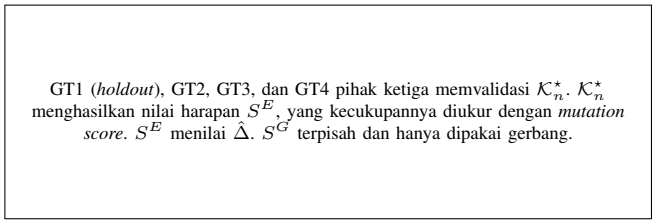
Keputusan terbuka
Siapa penulis perubahan tak terlihat, dan berapa banyak perubahannya? Jumlah ini menentukan kekuatan klaim RQ1. Bila 8 perubahan semuanya berhasil, batas bawah eksak RA hanya $0{,}05^{1/8} \approx 0{,}69$. Dengan 15 perubahan, batasnya $\approx 0{,}82$. Usulannya minimal 15.

D. Rantai kepercayaan dan validasi instrumen

Tujuan
Semua angka RQ2–RQ4 bergantung pada $\mathcal{K}^\star$ dan S^E. Karena itu keduanya divalidasi lebih dulu sebagai instrumen, bukan sebagai hasil penelitian.

[Gambar 4 menunjukkan rantainya. Acuan independen memvalidasi $\mathcal{K}_n^\star$, lalu $\mathcal{K}_n^\star$ menghasilkan nilai harapan S^E, dan S^E menilai pembaruan dari LLM.

1) **Acuan.** Ada empat sumber. GT1 adalah contoh perhitungan resmi, dibagi menjadi contoh yang sudah dipakai selama pengembangan dan subset *holdout* yang tidak pernah dipakai. GT2 adalah kalkulator otoritas pajak, bila tersedia untuk rezim tersebut. GT3 adalah perhitungan manual oleh penghitung independen. GT4 adalah implementasi pihak ketiga, yaitu kalkulator *open source* dan kalkulator publik, dengan versi dan tanggal yang dicatat.
2) **Pelaporan selisih.** Peneliti melaporkan semua selisih menurut hasil adjudikasi, yaitu *knowledge base* salah, acuan salah, atau hukum ambigu. Pengadjudikasi kedua memeriksa ulang sampel acak secara buta.
3) **Matriks acuan dan sel ruang uji.** Matriks ini menunjukkan sel yang punya acuan independen dan sel yang tidak.
4) **Uji *engine*.** *Engine* diuji terpisah dari *knowledge base* dengan uji unit terhadap aritmetika yang diperiksa tangan, karena S^E juga dihitung dengan *engine* yang sama.
5) **Kecukupan S^E.** Peneliti mengukur *mutation score* global dan *mutation score* terfokus-Δ untuk setiap peristiwa, yang hanya memutasi unsur $\Delta_n^\star$. Keduanya harus mencapai ambang minimum sebelum E2 dan E3. Kesalahan nyata LLM pada data pengembangan ditambahkan sebagai mutan realistis.
6) **Keandalan $\Delta^\star$.** Penyusun pertama menyusun $\Delta^\star$, lalu pembaca kedua yang independen memeriksanya. Kesepakatan atas keputusan unsur dilaporkan dengan Krippendorff's α. $\Delta^\star$ dikunci dengan stempel waktu sebelum LLM dijalankan.
7) **Syarat lulus E0.** Tidak ada selisih berstatus *knowledge base salah* yang belum diselesaikan, dan kedua *mutation score* mencapai ambang. E2–E4 baru dijalankan setelah E0 lulus.
8) **Protokol koreksi emas.** Bila keluaran LLM menyingkap kesalahan pada $\mathcal{K}^\star$ atau $\Delta^\star$, peneliti memperbaikinya,



Gambar 4. Rantai kepercayaan *ground truth*.

Tabel IV
RUANG UJI DAN CAKUPANNYA

Kriteria	Sel	Teruji	Acuan
Batas lapisan Pasal 17 per rezim	[]		
Batas lapisan TER per kategori			
Kombinasi 2-arah berbatasan			
Kombinasi 3-arah berbatasan			
Sampel operasional acak			

menilai ulang seluruh kondisi dengan emas yang sudah diperbaiki, dan melaporkan jumlah koreksi. Tanpa protokol ini, emas dapat dicurigai disunting secara selektif.
]

Keputusan terbuka
(1) Apakah ada praktisi pajak bersertifikat, misalnya dari *tax center* universitas, yang dapat dibayar beberapa jam untuk memeriksa $\Delta^\star$ peristiwa TER dan sekitar 50 kasus bertingkat? Ini mengurangi kelemahan terbesar penelitian ini, yaitu tidak adanya *domain expert*. (2) Siapa pembaca kedua $\Delta^\star$?

E. Ruang uji

Tujuan
Menjawab feedback no. 3 dengan jumlah skema yang dapat dihitung.

[
- **Cakupan kombinatorial berbatasan.** Kombinasi 2-arah harus tercakup penuh, dan cakupan 3-arah dilaporkan. Keduanya hanya dihitung atas kombinasi yang sah menurut batasan antardimensi.
- **Cakupan batas.** Setiap batas lapisan Pasal 17 dan TER diuji di $b-1$, b, dan $b+1$. Batas Pasal 17 berada pada PKP sesudah pembulatan, sehingga generator membangkitkan kasusnya secara terbalik, dari PKP ke penghasilan bruto. Jumlah titik per rezim sama dengan jumlah batas dikali tiga.
- **Sampel operasional.** Generator mengambil kasus pegawai-tahun secara acak sederhana dari distribusi upah dan status PTKP menurut data statistik resmi. Sampel ini dipakai untuk memperkirakan laju kegagalan dalam pemakaian nyata.

]

Harus didefinisikan
Generator kasus untuk ketiga kriteria, sumber distribusi sampel operasional, dan ukuran sampel operasional yang diturunkan dari batas laju kegagalan yang ingin diklaim.

F. Korpus

1) Peristiwa perubahan nyata: [Seluruh peristiwa dalam rentang penelitian yang memengaruhi PPh 21 pegawai tetap, termasuk perubahan parameter tahunan yang memengaruhi perhitungan, misalnya batas upah iuran pensiun sebagai pengurang. Hasilnya dilaporkan per jenis perubahan.]

Tabel V
KORPUS PERISTIWA PERUBAHAN

No.	Dokumen	Berlaku	Jenis	$\lvert\Delta^\star\rvert$	Bagian
1	[]				uji
…					
P1	[pengecoh]	–	tidak relevan	0	uji

2) Dokumen pengecoh: [Korpus juga memuat pengecoh sulit, yaitu regulasi yang menyebut PPh 21 tetapi tidak mengubah perhitungan pegawai tetap, misalnya ketentuan pegawai tidak tetap atau ketentuan administrasi pelaporan. Jawaban yang benar untuk pengecoh adalah pembaruan kosong.]

3) Dokumen kontrafaktual: [Generator membuat dokumen kontrafaktual dengan mengubah nilai, tanggal, atau ambang di dokumen nyata secara konsisten, lalu menurunkan $\Delta^\star$ kontrafaktual secara terprogram dari $\Delta^\star$ asli. Varian kontrafaktual tetap dihitung satu kelompok dengan dokumen sumbernya. Varian ini menambah presisi, bukan jumlah sampel independen.]

4) Perubahan tak terlihat: [Perubahan struktural sintetis dari penulis lain (Bagian VI-C), misalnya kategori TER keempat, jenis pengurang baru, tunjangan berplafon, aturan pembulatan baru, atau tarif harian.]

5) Kebijakan perusahaan: [Intinya diambil dari dokumen nyata yang terbuka untuk umum, misalnya perjanjian kerja bersama atau peraturan perusahaan yang dipublikasikan. Kebijakan buatan melengkapi jenis konflik yang tidak muncul di dokumen nyata. Orang lain menulis konflik buatan dari taksonomi konflik sebelum detektor dibekukan. Kedua kelompok dilaporkan terpisah.]

G. Mode evaluasi dan hasil per dokumen

[
- **Mode terisolasi (RQ2).** $\hat{\Delta}_n$ diterapkan pada $\mathcal{K}_{n-1}^\star$.
- **Mode berantai (RQ3).** $\hat{\Delta}_n$ diterapkan pada $\mathcal{K}_{n-1}^{\mathrm{sis}}$, yaitu hasil pembaruan sistem sendiri pada langkah sebelumnya.
- Kedua mode berjalan tanpa peninjau manusia, sehingga kandidat terpilih langsung diterapkan. Hasilnya adalah batas bawah kinerja, dan peran peninjau diukur lewat upaya koreksi. Peneliti tidak bertindak sebagai peninjau karena mengetahui jawaban emas.
- Setiap dokumen relevan berakhir pada satu dari tiga hasil: benar-diterapkan, salah-diterapkan (kesalahan senyap), atau *abstain*. $\hat{\Delta}$ benar bila A2, A3$_t$, dan A4 terpenuhi pada seluruh S^E, sesuai Definisi 8. Dokumen relevan yang dinilai tidak relevan oleh sistem dihitung salah-diterapkan.
- Dokumen pengecoh tidak masuk SER dan CAR. Penilaian relevansi diukur terpisah lewat laju *false positive* pada pengecoh dan laju pembaruan terlewat pada dokumen relevan.
- ***Abstain* pada mode berantai.** Ada dua varian yang didaftarkan sebelumnya. Pada varian pertama, *knowledge base* lama dipertahankan, sehingga peristiwa berikutnya mewarisi kekosongan itu. Pada varian kedua, peninjau sempurna menyisipkan $\Delta_n^\star$, sehingga perambatan kesalahan dapat diukur tanpa tercampur akibat *abstain*.
- **Satu hasil per dokumen.** Analisis konfirmatori memakai jalan pertama alur pada setiap dokumen sumber nyata. Jalan

Tabel VI
PEMBANDING DAN ABLASI

ID	Kondisi	RQ
Pembanding		
B1	Praktik saat ini, diukur dari riwayat *commit* kalkulator PPh 21 *open source* di sekitar pergantian ke TER, yaitu waktu sampai diperbarui, baris yang berubah, dan *bug* regresi	motivasi, RQ3
B2	LLM menghitung PPh 21 langsung dari dokumen pada ± 100 kasus operasional dengan satu model	motivasi
B3	Satu kandidat dengan gerbang G1–G2 saja (*pass@1*)	RQ2, RQ3
B4	$m(1+\bar{r})$ kandidat, sama dengan jumlah panggilan usulan termasuk putaran perbaikan, dipilih dengan suara terbanyak tanpa gerbang	RQ2
B5	Analisis dampak dengan tiga cara, yaitu menandai semua kebijakan yang menyentuh fakta yang berubah, menelusuri dependensi tanpa eksekusi, dan meminta penilaian LLM	RQ4
Ablasi (satu model)		
AB1	Formalisasi dari nol pada 2–3 keadaan hukum terpilih, misalnya sebelum TER, sesudah TER, dan masa DTP. *Knowledge base* awalnya kosong, masukannya seluruh dokumen yang berlaku, dan gerbang serta modelnya sama. Keluarannya *knowledge base* utuh, dinilai dengan A2 pada masa terpilih dan dengan hilangnya riwayat, yaitu hasil masa lampau yang berubah. Studi kasus deskriptif	RQ2, RQ3
AB2	Tanpa konteks *knowledge base*	RQ2
AB3	Tanpa G5, tanpa G4, atau tanpa putaran perbaikan	RQ2
AB4	Pemilihan kandidat dengan cara pertama lolos, konsensus, atau pilihan sempurna	RQ2
AB5	Validasi skema biasa dibanding *shape constraint* graf, dan pemindaian dependensi datar dibanding *query* graf	RQ2, RQ4

tambahan dan varian kontrafaktual dilaporkan sebagai strata terpisah.
]

H. Pembanding dan ablasi

Klaim & bukti
B3 dan B4 memakai anggaran komputasi yang setara atau dibandingkan secara eksplisit, sehingga keunggulan usulan tidak dapat dijelaskan oleh jumlah sampel saja. AB5 menjawab dengan angka pertanyaan mengapa *knowledge graph* diperlukan (feedback no. 1).

Keputusan terbuka
B2 bertentangan dengan keputusan awal untuk tidak memakai LLM sebagai pembanding. Usulannya, B2 tetap disertakan dalam skala kecil sebagai pembanding motivasi, karena reviewer akan menanyakannya.

I. Hipotesis dan metrik utama

Tujuan
Menjawab feedback no. 4. Setiap RQ punya satu metrik utama yang langsung mengukur klaimnya.

1) Definisi metrik utama: [
- **RA (RQ1).** Untuk setiap perubahan nyata dan tak terlihat, RA mencatat apakah ada Δ dalam bahasa representasi yang memenuhi A1–A4. Perubahan nyata dan tak terlihat dilaporkan terpisah, dan hanya perubahan tak terlihat yang menguji H1.
- **SER dan CAR (RQ2).** Keduanya dihitung atas himpunan D dokumen sumber nyata yang relevan, satu hasil per dokumen. Varian kontrafaktual dan pengecoh tidak termasuk. $\mathrm{SER} = \frac{1}{|D|}\sum_d \mathbb{1}[\text{salah-diterapkan}]$, $\mathrm{CAR} = \frac{1}{|D|}\sum_d \mathbb{1}[\text{benar-diterapkan}]$, dan $\mathrm{ABS} = 1 - \mathrm{SER} - \mathrm{CAR}$. SER mengukur keamanan, dan CAR mengukur kegunaan. Keduanya dilaporkan bersama karena sistem yang selalu *abstain* punya SER nol tetapi tidak berguna. Batas atas eksak untuk f kesalahan dari $|D|$ dokumen adalah kuantil Beta $(1-\alpha;\, f+1,\, |D|-f)$, yang untuk $f=0$ menjadi $1-\alpha^{1/|D|}$.
- **OAR (RQ3).** Proporsi peristiwa yang tidak memperkenalkan kesalahan baru dalam mode berantai. A2, $\mathrm{A3}_t$, dan A4 dinilai pada $S^E_{\le n}$, yaitu gabungan kasus seluruh keadaan sampai peristiwa n termasuk masa lampau, di luar tupel H_n yang sudah salah sebelumnya. Tanpa pengecualian H_n, satu kesalahan lama terhitung ulang di setiap peristiwa berikutnya. Keadaan kumulatif dilaporkan terpisah lewat *drift* akhir D_N.
- **Kesalahan terpicu (RQ3).** Untuk peristiwa n, E_n^{ber} dan E_n^{iso} adalah tupel salah pada mode berantai dan mode terisolasi, dan H_n adalah tupel yang sudah salah di $\mathcal{K}^{\mathrm{sis}}_{n-1}$. Kesalahan terpicu $I_n = E_n^{\mathrm{ber}} \setminus (E_n^{\mathrm{iso}} \cup H_n)$ dipecah menjadi dua komponen. Komponen mekanis diperoleh dengan menerapkan $\hat{\Delta}_n$ dari mode terisolasi pada $\mathcal{K}^{\mathrm{sis}}_{n-1}$, sehingga yang terukur hanya perambatan lewat basis yang salah. Komponen kontekstual diperoleh dengan membangkitkan ulang $\hat{\Delta}_n$ memakai $\mathcal{K}^{\mathrm{sis}}_{n-1}$ sebagai konteks. Pembangkitan ulang memuat derau acak, sehingga batas derau diperkirakan dari selisih dua jalan terisolasi yang independen. H3b diuji terhadap batas itu, bukan terhadap nol.
- ***Recall* dan F_2 (RQ4).** Keduanya dihitung atas pasangan kebijakan dan peristiwa, dengan $F_2 = 5PR/(4P+R)$. *Recall* diutamakan karena kebijakan terdampak yang terlewat lebih berbahaya daripada peringatan palsu. Bila semua n_+ positif terdeteksi, batas bawah eksak *recall* adalah α^{1/n_+}, misalnya $0{,}905$ untuk $n_+ = 30$. Pembanding *tandai semua* menghasilkan $F_2 = 5\pi/(4\pi+1)$ untuk prevalensi π, sehingga F_2 baru bermakna di atas angka itu.
]

Harus didefinisikan
Ambang θ_1–θ_4, margin δ_S, dan alasannya, dikunci sebelum eksperimen. Ambang harus dapat dicapai oleh jumlah sampel yang direncanakan. Contohnya, dengan 10 dokumen uji tanpa satu pun kesalahan, batas atas eksak SER hanya $1-0{,}05^{1/10} \approx 0{,}26$, dan klaim SER $\le 5\%$ baru mungkin dengan minimal 59 dokumen tanpa kesalahan. Untuk setiap hipotesis, pra-registrasi mencantumkan batas terbaik yang dapat dicapai oleh N yang direncanakan, lalu menetapkan θ pada atau di atas batas itu. Bila tidak ada ambang yang bermakna, hipotesis diganti dengan estimasi dan CI saja. Klaim keamanan lalu dinyatakan apa adanya, misalnya SER paling tinggi 26% dengan keyakinan 95% pada $N = 10$, dan diperketat lewat peristiwa prospektif.

2) Metrik diagnostik: [Metrik pada Tabel VIII menjelaskan mengapa metrik utama bernilai seperti itu. Metrik ini eksploratori dan tidak dipakai untuk menguji hipotesis.]

J. Analisis statistik

Tujuan
Jumlah peristiwa nyata kecil. Karena itu penelitian ini tidak memakai uji yang membutuhkan sampel besar, dan melaporkan hasil sebagai estimasi dengan selang kepercayaan eksak beserta efek minimum yang dapat dideteksi.

[
- **Unit analisis.** Unitnya adalah dokumen sumber nyata untuk RQ2, dan peristiwa untuk RQ3 dan RQ4. Jalan LLM, kandidat, dan varian kontrafaktual bersarang di dalam dokumen sumbernya dan tidak dihitung sebagai sampel independen. Analisis konfirmatori memakai satu hasil per dokumen dari jalan pertama, dan strata lain dilaporkan terpisah.
- **RQ3 bersyarat pada satu rangkaian nyata.** R pengulangan hanya menangkap keragaman pembangkitan LLM.

Tabel VII
KETERLACAKAN RQ, HIPOTESIS, DAN METRIK UTAMA

RQ	Hipotesis	Metrik utama	Analisis	Eksperimen
–	Invarian A1 dan A3$_\omega$ tanpa pelanggaran selama evaluasi	jumlah pelanggaran	pemeriksaan	semua
RQ1	H1: laju adaptivitas representasional pada perubahan tak terlihat $\geq [\theta_1]$	RA, yaitu proporsi perubahan yang dapat dinyatakan tanpa mengubah *engine*	proporsi dengan CI eksak Clopper–Pearson	E1
RQ2	H2a: batas atas laju kesalahan senyap usulan $\leq [\theta_2]$. H2b: CAR usulan lebih tinggi daripada B3 dan B4, dan SER usulan tidak lebih buruk dari keduanya dengan margin δ_S	SER dan CAR atas dokumen sumber nyata	CI eksak; selisih risiko berpasangan dengan CI Newcombe; non-inferioritas SER	E2
RQ3	H3a: laju adaptivitas operasional berantai $\geq [\theta_3]$. H3b: kesalahan terpicu tidak melebihi batas derau pembangkitan	OAR, dihitung dari kesalahan yang diperkenalkan setiap langkah; kesalahan terpicu I	CI eksak; deskriptif atas R pengulangan, dibanding batas derau	E3
RQ4	H4a: *recall* $\geq [\theta_4]$. H4b: F_2 usulan lebih tinggi daripada setiap pembanding B5	*Recall* dan F_2	*bootstrap* klaster per peristiwa; batas Clopper–Pearson tingkat pasangan sebagai pelengkap	E4

Hasilnya dilaporkan secara deskriptif, dan kesimpulannya dinyatakan bersyarat pada rangkaian itu.

- **Efek minimum yang dapat dideteksi.** Peneliti menghitung dan melaporkan efek ini, misalnya bahwa dengan n dokumen hanya selisih minimal X poin persentase yang dapat dideteksi.
- **Keluarga Holm.** Keluarga koreksi didefinisikan per RQ dan hanya untuk hipotesis komparatif. Pemeriksaan nol-cacat dan invarian tidak termasuk.
- **Pelaporan per jenis perubahan.** Jenis mudah dan jenis struktural tidak digabung.

]

Harus didefinisikan
Nilai m (usulan 5), R (usulan 3), parameter pembangkitan, jumlah dokumen per bagian data, dan efek minimum yang dapat dideteksi.

K. Prosedur eksperimen

- **E0, validasi instrumen.** [Lihat Bagian VI-D. E0 menjadi prasyarat semua eksperimen lain.]
- **E1, adaptivitas representasi (RQ1).** [RA pada perubahan nyata dan tak terlihat, akurasi resolusi konflik, dan pemetaan riwayat *engine*.]
- **E2, akuisisi terisolasi (RQ2).** [Setiap dokumen uji dijalankan pada setiap kondisi, yaitu usulan, B3, B4, dan AB2–AB5. AB1 dijalankan pada keadaan hukum terpilih. Model utama dipakai untuk semua kondisi, dan model kedua (*open-weight*) hanya untuk usulan dan B3. Satu jalan terisolasi tambahan dipakai untuk batas derau.]
- **E3, *regulation replay* (RQ3).** [Mode berantai dari *knowledge base* awal sampai peristiwa terakhir, dalam dua varian *abstain* dan R pengulangan. Kesalahan didekomposisi menjadi bawaan, baru, terpicu mekanis, dan terpicu kontekstual. B1 menjadi pembanding praktik, dan peristiwa prospektif ditambahkan begitu terbit. Ini bukti utama untuk feedback no. 5.]
- **E4, analisis dampak (RQ4).** [Dua masukan, yaitu $\Delta^\star$ dan $\hat{\Delta}$, dibandingkan dengan pembanding B5.]
- **E5, motivasi.** [B2 pada ± 100 kasus operasional.]

L. Biaya dan kelayakan

[Jumlah panggilan LLM dihitung per eksperimen, dengan $\bar{r}$ rata-rata putaran perbaikan dan D' gabungan D, dokumen kontrafaktual, dan pengecoh.

- E2: $|D'| \times m(1+\bar{r})$ untuk usulan, $|D'|$ untuk B3, dan $|D'| \times m(1+\bar{r})$ untuk B4.
- AB2–AB5: $|D| \times m(1+\bar{r})$ per varian, dengan satu model.
- AB1: jumlah keadaan hukum terpilih dikali $m(1+\bar{r})$, dengan konteks seluruh dokumen yang berlaku. Ini panggilan termahal.
- E3: $2 \times R \times N \times m(1+\bar{r})$ untuk dua varian *abstain*. Dekomposisi mekanis memakai ulang $\hat{\Delta}$ dari E2 tanpa panggilan baru. Batas derau membutuhkan satu jalan terisolasi tambahan, yaitu $|D| \times m(1+\bar{r})$.
- Model kedua: usulan dan B3 pada D saja.
- E5 (B2): ± 100 panggilan.

Total panggilan dikalikan rata-rata token masuk dan keluar serta harga model, lalu dicantumkan dalam rupiah di pra-registrasi. Biaya ditekan dengan memotong dokumen per pasal, memakai *prompt caching*, membangkitkan kontrafaktual secara otomatis, dan menjalankan ablasi pada satu model.]

M. Kolaborator dan rencana cadangan

[Beberapa langkah membutuhkan orang selain peneliti, yaitu penulis perubahan tak terlihat dan konflik buatan, pembaca kedua $\Delta^\star$, pengadjudikasi kedua, pelabel kedua RQ4, dan praktisi pajak. Peran-peran ini digabung ke paling banyak dua kolaborator bernama, dan jam kerjanya dicatat. Untuk setiap peran yang tidak terisi, pra-registrasi mencantumkan apa yang dihapus dan bagaimana hal itu dilaporkan sebagai keterbatasan. Contohnya, tanpa penulis perubahan tak terlihat, RQ1 hanya melaporkan perubahan nyata, dan klaimnya turun menjadi kemampuan menyatakan perubahan yang sudah diketahui.]

N. Reproduksibilitas

[Catat versi perangkat lunak dan model serta tanggal akses, dan arsipkan seluruh *prompt* dan keluaran LLM, sehingga semua analisis dapat diulang tanpa memanggil LLM lagi.]

VII. HASIL

Tujuan
Urutannya mengikuti Tabel VII. Validasi instrumen dilaporkan lebih dulu. Setiap RQ dibuka dengan metrik utama dan keputusan atas hipotesisnya, lalu metrik diagnostik.

Tabel VIII
METRIK DIAGNOSTIK (EKSPLORATORI)

RQ	Metrik	Definisi	Pertanyaan yang dijawab
Instrumen	Selisih per hasil adjudikasi; batas atas laju kegagalan	semua selisih $\mathcal{K}^\star$ terhadap GT1–GT4; untuk n kasus operasional tanpa kegagalan, $p_U = 1-\alpha^{1/n}$, sehingga $n \geq 2.995$ dibutuhkan untuk $< 0{,}1\%$ pada $\alpha = 0{,}05$	seberapa dapat dipercaya *ground truth*
Instrumen	*Mutation score* global dan terfokus-Δ	mutan terdeteksi dibagi mutan tak setara	apakah S^E cukup tajam
RQ1	Akurasi resolusi konflik	pasangan aturan dengan pemenang hukum yang diketahui per asas, dinilai benar atau salah	apakah resolusi konflik bekerja
RQ1	Kelengkapan jejak	fakta keluaran yang jejaknya sampai ke sumber hukum, dibagi seluruh fakta keluaran	kelengkapan fasilitas penjelasan
RQ2	*pass@1*, *pass@m*, *1@m*, dan efisiensi pemilihan	dihitung pada kandidat sebelum perbaikan, yang independen dan berdistribusi identik: pass@$j = 1 - \binom{m-c}{j}/\binom{m}{j}$. Efisiensi dihitung pada agregat korpus dan pada kumpulan kandidat yang sama tanpa perbaikan: $\eta = (1@m - \text{pass@1})/(\text{pass@}m - \text{pass@1})$, tidak terdefinisi bila penyebutnya nol	seberapa baik gerbang memilih dibanding pemilihan sempurna
RQ2	Laju diterapkan tetapi tidak lengkap	$\hat{\Delta}$ diterapkan yang tidak memuat minimal satu unsur $\Delta^\star$	apakah kelalaian adalah kesalahan dominan
RQ2	Matriks konfusi gerbang	per gerbang, kebocoran $= \mathrm{FN}/(\mathrm{TP}+\mathrm{FN})$, penolakan keliru $= \mathrm{FP}/(\mathrm{FP}+\mathrm{TN})$, dan MCC, dengan kandidat salah sebagai kelas positif	gerbang mana yang efektif
RQ2	Kesepakatan perilaku dan kebenaran per unsur	proporsi tupel S^E yang sama dengan $\mathcal{K}_n^\star$; sebuah unsur salah bila menukarnya dengan unsur emas mengubah hasil S^E	seberapa dekat pembaruan yang salah, terutama pada dokumen tersulit
RQ2	Laju hafalan dan kesetiaan kontrafaktual	proporsi nilai yang diubah di mana $\hat{\Delta}$ memuat nilai asli, dan proporsi yang memuat nilai kontrafaktual	apakah LLM membaca dokumen atau mengingat
RQ2	Kontaminasi	SER dan CAR untuk peristiwa sebelum dan sesudah *training cutoff* model	pengaruh data latih
RQ2	Penilaian relevansi	laju *false positive*, yaitu pengecoh yang dinilai relevan, dan laju pembaruan terlewat, yaitu dokumen relevan yang dinilai tidak relevan	perubahan tanpa alasan dan perubahan yang terlewat
RQ2	Strata kontrafaktual	SER dan CAR pada varian kontrafaktual, dengan CI *bootstrap* klaster per dokumen sumber	ketahanan terhadap nilai yang tidak dikenal LLM
RQ2	Ketepatan kutipan	unsur yang kutipannya ada dan mendukung unsur itu	dasar hukum karangan
RQ2	Upaya koreksi	operasi sunting atribut dari $\hat{\Delta}$ ke $\Delta^\star$ setelah penyelarasan unsur (Hungarian), hanya pada unsur yang salah secara perilaku; penghematan $= 1 - \text{sunting}/\text{operasi}$ untuk menyusun $\Delta^\star$ dari kosong, dan nilainya boleh negatif	pekerjaan manusia yang dihemat
RQ2	Kurva biaya dan akurasi	CAR terhadap biaya per peristiwa	kelayakan praktis
RQ3	Rasio perambatan	$P(\hat{\Delta}_n \text{ salah} \mid \mathcal{K}_{n-1}^{\text{sis}} \text{ salah})/P(\hat{\Delta}_n \text{ salah} \mid \mathcal{K}_{n-1}^\star)$	apakah basis yang salah memperbesar kesalahan berikutnya
RQ3	Formalisasi dari nol (AB1)	A2 pada masa terpilih dan hilangnya riwayat, dibanding usulan pada keadaan yang sama	apa yang hilang bila *knowledge base* dibangun ulang
RQ3	Persistensi dan pemulihan	jumlah peristiwa yang dilalui sebuah kesalahan sebelum hilang, dan proporsi kesalahan yang pulih	apakah kesalahan menetap
RQ3	Penguncian kesalahan	kesalahan bawaan yang perbaikannya ditolak G4 pada peristiwa berikutnya	apakah gerbang regresi mengawetkan kesalahan
RQ3	*Drift* akhir	D_N, yaitu proporsi pegawai-bulan berbobot sampel operasional yang PPh 21-nya salah setelah seluruh rangkaian, beserta jumlah rupiahnya	akibat finansial akhir
RQ3	Anomali *knowledge base*	aturan redundan, berkonflik, tercakup, mati, dan rujukan menggantung per versi	apakah mutu *knowledge base* merosot
RQ3	Penerapan langsung	peristiwa yang diterapkan tanpa suntingan manusia, peristiwa dengan paling banyak k suntingan, dan waktu dari dokumen tersedia sampai *knowledge base* benar	jawaban langsung untuk feedback no. 5
RQ4	*Precision* dan MCC	dihitung dua kali, dengan masukan $\Delta^\star$ untuk detektor saja dan dengan masukan $\hat{\Delta}$ untuk alur penuh	sumber kesalahan analisis dampak
RQ4	AUPRC pembanding	untuk pembanding yang menghasilkan skor	posisi usulan pada kurva pembanding
RQ4	Cohen's κ	kesepakatan dua pelabel untuk dampak jenis (c)	keandalan label

A. Validasi instrumen

[Selisih per hasil adjudikasi, matriks acuan dan sel, Tabel IV yang sudah terisi, *mutation score*, dan Krippendorff's α untuk $\Delta^\star$.]

B. Adaptivitas representasi (RQ1)

[RA nyata dan tak terlihat dengan CI, perubahan yang gagal beserta alasannya, riwayat *engine*, dan akurasi resolusi konflik.]

C. Akuisisi satu langkah (RQ2)

[SER, CAR, dan ABS per kondisi dan per jenis perubahan dengan CI; selisih CAR dan non-inferioritas SER terhadap B3 dan B4; penilaian relevansi; strata kontrafaktual; *pass@1*, *1@m*, dan *pass@m*; dan metrik diagnostik.]

Setiap kondisi digambar sebagai titik dengan CI. Sumbu-x adalah cakupan, yaitu CAR + SER. Sumbu-y adalah risiko selektif, yaitu SER/(CAR + SER), atau laju kesalahan di antara pembaruan yang diterapkan.

Gambar 5. Keamanan dan kegunaan akuisisi per kondisi.

D. Adaptivitas operasional berantai (RQ3)

[OAR; kesalahan bawaan, baru, dan terpicu per peristiwa; rasio perambatan; penerapan langsung; *drift* akhir; anomali *knowledge base*; dan B1.]

Tabel IX
RENCANA ANALISIS STATISTIK

Jenis data	Contoh	Penaksir atau uji	Ukuran efek
Pemeriksaan nol-cacat	invarian A1 dan A3$_\omega$; selisih $\mathcal{K}^\star$	hitungan dan batas atas eksak	–
Proporsi per kondisi	RA, SER, CAR, OAR, *recall*	CI eksak Clopper–Pearson	proporsi
Biner berpasangan antarkondisi	benar-diterapkan, usulan dibanding B3 dan B4	selisih risiko berpasangan dengan CI Newcombe; McNemar eksak sebagai pelengkap	selisih risiko; *odds ratio* pasangan sumbang b/c
Non-inferioritas	SER usulan dibanding B3 dan B4	batas atas CI selisih SER berpasangan $< \delta_S$	selisih risiko
Kontinu berpasangan	kesepakatan perilaku, upaya koreksi	Wilcoxon bertanda	*rank-biserial* r
Antarpengulangan rangkaian	OAR dan I atas R pengulangan	median dan rentang dibanding batas derau; uji permutasi bila perlu	–
Proporsi berklaster	*recall* dan F_2 RQ4; strata kontrafaktual	*bootstrap* klaster per peristiwa atau per dokumen sumber; selisih F_2 berpasangan	selisih F_2
Kesepakatan	label RQ4 dan $\Delta^\star$	Cohen's κ; Krippendorff's α	κ, α

Satu batang bertumpuk per peristiwa, diurutkan kronologis di sumbu-x dan diberi label jenis perubahan. Batang menunjukkan kesalahan bawaan, baru, dan terpicu. Penanda menunjukkan status A2, A3$_t$, dan A4, dan garis menunjukkan rentang antarpengulangan.

Gambar 6. Hasil *regulation replay*.

E. Analisis dampak lintas lapis (RQ4)

[*Recall* dan F_2 dengan CI pada kedua masukan; perbandingan dengan B5, termasuk garis dasar *tandai semua*; κ; dan satu contoh dari graf.]

F. Ablasi

[Perubahan SER dan CAR untuk setiap ablasi. AB5 menjawab pertanyaan mengapa *knowledge graph* diperlukan.]

VIII. PEMBAHASAN

A. Jawaban atas pertanyaan penelitian

[Satu paragraf per RQ.]

B. Analisis kesalahan LLM

Harus didefinisikan
Taksonomi kesalahan ditetapkan sebelum pelabelan, yaitu nilai salah, masa berlaku salah, kondisi atau cakupan salah, pengecualian terlewat, pencabutan terlewat, lapisan atau sifat salah, kutipan karangan, dan perubahan pada pengecoh. Laporkan frekuensi per jenis dan gerbang yang menangkapnya.

C. Implikasi

[Implikasi bagi pengembang sistem payroll dan bagi formalisasi peraturan yang sering berubah.]

D. Ancaman terhadap validitas

[

- **Validitas internal.** *Ground truth* dan *engine* disusun tim yang sama. Mitigasinya acuan pihak ketiga, *holdout* contoh resmi, pengadjudikasi kedua, dan uji *engine* terpisah.
- **Bias pandangan belakang.** Representasi dirancang setelah perubahan nyata diketahui. Mitigasinya perubahan tak terlihat dan peristiwa prospektif.
- **Validitas konstruk.** Kecocokan dengan acuan tidak sama dengan kesesuaian hukum, dan upaya manusia diukur dengan proksi operasi sunting.
- **Validitas eksternal.** Penelitian ini mencakup satu yurisdiksi, satu jenis pajak, dan satu rangkaian perubahan.
- **Validitas kesimpulan.** Jumlah peristiwa kecil, LLM tidak deterministik, dan versi model berubah dari waktu ke waktu.
- **Kontaminasi data.** Mitigasinya dokumen kontrafaktual, analisis sebelum dan sesudah *training cutoff*, dan peristiwa prospektif.

]

E. Keterbatasan

[Hal di luar lingkup dan jenis perubahan yang belum terwakili.]

IX. KESIMPULAN DAN PENELITIAN LANJUTAN

[Jawaban RQ1–RQ4 dengan metrik utama dan CI, tanpa mengulang abstrak. Penelitian lanjutan diturunkan dari keterbatasan.]

X. RENCANA KERJA TURUNAN

Daftar ini diturunkan dari kerangka di atas. Hapus seluruh bagian ini sebelum naskah dikirim.

Tetapkan sebelum membangun apa pun

1) Ruang lingkup, dimensi, dan batasan antardimensi ruang pajak.
2) Taksonomi jenis perubahan, taksonomi konflik, dan taksonomi kesalahan LLM.
3) Definisi 1–8, fakta keluaran yang dinilai, semantik berlaku surut menurut mekanisme hukum, dan prosedur uji otomatis A1–A4.
4) Ontologi, bahasa ekspresi, semantik temporal, relasi superioritas, dan bentuk kanonik.
5) Arti *terdampak* untuk RQ4.
6) Pembagian data, hipotesis, ambang, margin δ_S, operasi sunting, operator mutasi, m, R, dan rencana analisis, yang lalu didaftarkan ke layanan pra-registrasi.

Bangun

1) *Knowledge graph* sesuai ontologi, dan *engine* yang membaca aturan darinya.
2) Penilaian relevansi berkutipan.

3) Gerbang G1–G5, dengan G5 untuk penambahan, perubahan, dan pencabutan, beserta putaran perbaikan, pemilihan konsensus, dan *abstain*.
4) Alur akuisisi dengan konteks dari graf, m kandidat, dan keluaran Δ terstruktur.
5) Analisis dampak lintas lapis.
6) Korpus peristiwa nyata, pengecoh termasuk pengecoh sulit, kontrafaktual otomatis, perubahan tak terlihat dari penulis lain, serta kebijakan perusahaan nyata dan buatan.
7) $\mathcal{K}_n^\star$ dan $\Delta_n^\star$, diperiksa pembaca kedua.
8) Generator ruang uji untuk S^E, yaitu kombinatorial berbatasan, batas terbalik dari PKP, dan operasional, serta generator S^G otomatis yang menyasar kondisi unsur yang berubah. Keduanya tidak beririsan.
9) Acuan berupa *holdout* contoh resmi, implementasi pihak ketiga, dan perhitungan manual.
10) Pembanding B1–B5 dan ablasi AB1–AB5.
11) Pencatat eksperimen untuk seluruh *prompt*, keluaran, biaya, dan waktu.

Uji

1) E0, yaitu validasi instrumen sampai ambang *mutation score* tercapai.
2) E1–E5 sesuai Bagian VI. E2–E4 dijalankan sekali pada data uji.
3) Peristiwa prospektif begitu terbit.
4) Pelabelan dampak oleh dua pelabel, dan adjudikasi ulang secara buta.

Dokumentasikan

1) Spesifikasi ontologi, bahasa ekspresi, dan bentuk kanonik.
2) Pra-registrasi dan tautannya.
3) Riwayat pengembangan *engine* yang dipetakan ke regulasi pemicunya.
4) Log adjudikasi, erratum, dan ketidaksepakatan pelabel.
5) *Prompt* lengkap dan konfigurasi model.
6) Arsip data dan kode yang dirilis.

Keputusan terbuka yang harus dijawab sebelum pra-registrasi

1) Target publikasi. Bila IEEE Access, naskah final harus berbahasa Inggris.
2) Apakah *preprint* boleh dikutip.
3) Ukuran *lex specialis*.
4) Model utama, model kedua, dan anggaran API.
5) Apakah pembanding B2 (LLM menghitung langsung) disertakan.
6) Apakah LLM boleh memakai alat ekstraksi tabel.
7) Kolaborator, paling banyak dua, untuk perubahan tak terlihat, konflik buatan, pembaca kedua, dan pelabel kedua, beserta rencana cadangan bila tidak ada.
8) Ambang hipotesis yang dapat dicapai oleh jumlah dokumen dan peristiwa yang tersedia.
9) Pembaca kedua $\Delta^\star$ dan praktisi pajak.

DAFTAR PUSTAKA

[1] D. Merigoux, N. Chataing, and J. Protzenko, "Catala: a programming language for the law," *Proceedings of the ACM on Programming Languages*, vol. 5, no. ICFP, pp. 1–29, 2021, doi: 10.1145/3473582.

[2] A. Mowbray, P. Chung, and G. Greenleaf, "Representing legislative Rules as Code: Reducing the problems of 'scaling up'," *Computer Law & Security Review*, vol. 48, p. 105772, 2023, doi: 10.1016/j.clsr.2022.105772.

[3] R. Kowalski and A. Datoo, "Logical English meets legal English for swaps and derivatives," *Artificial Intelligence and Law*, vol. 30, no. 2, pp. 163–197, 2022, doi: 10.1007/s10506-021-09295-3.

[4] S. Dumancic, W. Meert, S. Goethals, T. Stuyckens, J. Huygen, and K. Denies, "Automated Reasoning and Learning for Automated Payroll Management," *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, no. 17, pp. 15 107–15 116, 2021, doi: 10.1609/aaai.v35i17.17774.

[5] M. O. Moguillansky, D. C. Martinez, L. H. Tamargo, and A. Rotolo, "An approach to temporalised legal revision through addition of literals," *Artificial Intelligence and Law*, vol. 32, no. 3, pp. 621–666, 2024, doi: 10.1007/s10506-023-09363-w.

[6] F. Olivieri, M. Cristani, G. Governatori, L. Pasetto, A. Rotolo, S. Scannapieco, C. Tomazzoli, and T. Chekole Workneh, "Revising non-monotonic theories with sufficient and necessary conditions: the case of Defeasible Logic," *Journal of Logic and Computation*, vol. 35, no. 7, p. exae044, 2025, doi: 10.1093/logcom/exae044.

[7] S. Janatian, H. Westermann, J. Tan, J. Savelka, and K. Benyekhlef, "From Text to Structure: Using Large Language Models to Support the Development of Legal Expert Systems," in *Legal Knowledge and Information Systems (JURIX 2023)*, ser. Frontiers in Artificial Intelligence and Applications, vol. 379. IOS Press, 2023, doi: 10.3233/faia230962.

[8] M. Makowski and J. Trabka, "Dynamic generation of Decision Model and Notation rules for tax regulations – case study from Swiss accounting offices," in *International Conference on Information Systems Development*. University of Gdansk, Department of Business Informatics & University of Belgrade, Faculty of Organizational Sciences, 2025, doi: 10.62036/isd.2025.98.

[9] H. de Martim, "An Ontology-Driven Graph RAG for Legal Norms: A Hierarchical, Temporal, and Deterministic Approach," in *Legal Knowledge and Information Systems (JURIX 2025)*, ser. Frontiers in Artificial Intelligence and Applications. IOS Press, 2025, doi: 10.3233/faia251598.

[10] L. Robaldo, S. Batsakis, R. Calegari, F. Calimeri, M. Fujita, G. Governatori, M. C. Morelli, F. Pacenza, G. Pisano, K. Satoh, I. Tachmazidis, and J. Zangari, "Compliance checking on first-order knowledge with conflicting and compensatory norms: a comparison among currently available technologies," *Artificial Intelligence and Law*, vol. 32, no. 2, pp. 505–555, 2024, doi: 10.1007/s10506-023-09360-z.

[11] A. Khoja, M. Kölbl, S. Leue, and R. Wilhelmi, "Automated consistency analysis for legal contracts," *Artificial Intelligence and Law*, vol. 34, no. 3, pp. 881–922, 2026, doi: 10.1007/s10506-025-09456-8.

[12] A. Boujelben and I. Amous, "Treating Anomalies in Rule bases associated to Ontologies," *The Journal of Supercomputing*, vol. 81, no. 1, p. 243, 2025, doi: 10.1007/s11227-024-06688-4.

[13] S. Tizpaz-Niari, V. Monjezi, M. Wagner, S. Darian, K. Reed, and A. Trivedi, "Metamorphic Testing and Debugging of Tax Preparation Software," in *2023 IEEE/ACM 45th International Conference on Software Engineering: Software Engineering in Society (ICSE-SEIS)*. IEEE, 2023, pp. 138–149, doi: 10.1109/icse-seis58686.2023.00019.

[14] G. Petrović, M. Ivanković, G. Fraser, and R. Just, "Does Mutation Testing Improve Testing Practices?" in *2021 IEEE/ACM 43rd International Conference on Software Engineering (ICSE)*. IEEE, 2021, pp. 910–921, doi: 10.1109/icse43902.2021.00087.